

Relatório de análises - Movimenta UFPR

Ana Beatriz da Silva Marques

Alexandre Kobus

2026-08-12

Table of contents

Introdução	4
1 Análise exploratória de dados	5
2 Estrutura dos dados	6
2.0.1 Quantidade de atletas	6
2.0.2 Número de variáveis	6
2.0.3 Primeiras 6 linhas dos dados	6
2.0.4 Variáveis e seus tipos	6
2.0.5 Número de variáveis	13
2.0.6 Número de valores faltantes	13
2.0.7 Distribuição das variáveis mais importantes	18
3 Desempenho ao longo das semanas	36
3.1 TT (S0, S8 e S16)	36
3.2 Z1 (S4 e S12)	40
4 Validação dos dados	44
4.0.1 Quantidade de atletas com o treino válido	44
4.0.2 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S0	44
4.0.3 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S4	44
4.0.4 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S8	45
4.0.5 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S12	46
4.0.6 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S16	46
5 Perguntas	48
6 Bloco 1: Análises Perceptivas e Qualitativas ($N = 28$)	51
6.1 Pergunta 1: Como se comporta a percepção de desgaste entre os grupos? . . .	51
6.1.1 Gráfico da série temporal qualitativa	52
6.2 Pergunta 2: O mesmo atleta sente mais desgaste no 1º ou no 2º bloco de treinos?	53

6.3	Pergunta 3: Quais fatores perceptivos se associam ao tempo da maratona? . . .	54
7	Bloco 2: Análises de Desempenho Físico e Maratona ($N = 30$)	56
7.1	Perguntas 4 e 5: A ordem dos treinos altera o resultado da Maratona por nível de rendimento?	56
7.1.1	Gráfico de desempenho na maratona	57
7.2	Perguntas 6 e 7: Como evolui o ritmo no 21km Time Trial e qual o impacto da ordem?	58
7.2.1	Gráfico de Evolução de Todos os Atletas + Média Geral (Verde)	58
7.3	Pergunta 8: Como se comportam os limiares fisiológicos L_1 e L_2 ?	60
7.4	Perguntas 9 e 10: Avaliação de Durabilidade e Perda de Velocidade Pós-Teste (TT vs Z1)	61
7.4.1	Gráfico de Queda de Velocidade (Limite do Eixo Y em 30%)	62
8	Modelo Linear Misto das Velocidades nos 21km	64
8.1	Cálculo do Modelo Misto	64
8.1.1	TT (S0, S8 e S16)	64
8.1.2	Z1 (S4 e S12)	66
9	Achados e Recomendações	69

Introdução

O projeto Movimenta UFPR acompanhou atletas ao longo de um programa estruturado de preparação dividido em dois blocos principais de treinamento. O primeiro bloco compreende da Semana 1 a 8 e o segundo bloco abrange da Semana 9 a 16.

Os atletas foram divididos em duas sequências pedagógicas de treino:

- **Grupo 1 (G1):** Iniciou pela intervenção do Treino A no primeiro bloco e realizou o Treino B no segundo bloco.
- **Grupo 2 (G2):** Realizou a sequência inversa, aplicando o Treino B no primeiro bloco e o Treino A no segundo bloco.

Neste relatório, integramos os dados de desempenho quantitativo ($N = 30$ atletas) com os dados de percepção qualitativa semanal ($N = 28$ atletas com acompanhamento de questionários completo) para responder a **10 perguntas científicas norteadoras**.

1 Análise exploratória de dados

```
library(tidyverse)
library(janitor)
library(lme4)
library(lmerTest)
library(rstatix)
library(ggplot2)
library(readxl)
library(hms)
library(gt)
library(plotly)
dados <- read_xlsx("../projeto_movimenta_ufpr/Dados_06.07.xlsx") %>% clean_names() %>%
  type.convert(as.is = TRUE) %>% drop_na(codigo) |> select(-c(
    maratona_pace_km1,
    maratona_fc_km1,
    maratona_percent_vc_fc,
    starts_with("fazer_as"))) |> mutate(maratona_tempo = as.double(maratona_tempo),
                                         maratona_tempo = as_hms(maratona_tempo * 86400),
                                         maratona_tempo = format(as.POSIXct(maratona_tempo), "%Y-%m-%d %H:%M:%S"),
                                         maratona_menos_4h = ifelse(as_hms(maratona_tempo) < 4, "00:00:00", as_hms(maratona_tempo - 4)))
dicionario <- read_excel("../projeto_movimenta_ufpr/Dados_06.07.xlsx", sheet = 2)
```

2 Estrutura dos dados

2.0.1 Quantidade de atletas

```
nrow(dados)
```

```
[1] 30
```

2.0.2 Número de variáveis

```
ncol(dados)
```

```
[1] 237
```

2.0.3 Primeiras 6 linhas dos dados

```
dados |> head() |> gt() |>  
  cols_align(  
    align = "center",  
    columns = everything()  
  )
```

2.0.4 Variáveis e seus tipos

```
glimpse(dados)
```

grupo	codigo	nome	maratona_tempo	maratona_km_h_real	tt_3_tempo
G1	G1_01	Alcione	04:17:01	9.85	8.4560185185185183E-2
G1	G1_02	Alessandro	03:44:04	11.30	6.8275462962962968E-2
G1	G1_03	Amanda	04:08:30	10.19	8.1493055555555555E-2
G1	G1_04	Ana Munaro	03:00:28	14.03	5.8611111111111114E-2
G1	G1_05	Andreia Rosa	04:35:19	9.19	7.7187500000000006E-2
G1	G1_06	Carlos	03:41:48	11.41	7.3888888888888893E-2

Rows: 30

Columns: 237

```

$ grupo          <chr> "G1", "G1", "G1", "G1", "G1", "G1", "G1", "G1"~
$ codigo         <chr> "G1_01", "G1_02", "G1_03", "G1_04", "G1_05", "~
$ nome          <chr> "Alcione", "Alessandro", "Amanda", "Ana Munaro~
$ maratona_tempo <chr> "04:17:01", "03:44:04", "04:08:30", "03:00:28"~
$ maratona_km_h_real <dbl> 9.85, 11.30, 10.19, 14.03, 9.19, 11.41, 12.95,~
$ tt_3_tempo     <chr> "8.4560185185185183E-2", "6.8275462962962968E-
~
$ tt_3_km_h_real <dbl> 10.40, 12.88, 10.79, 15.00, 11.39, 11.90, 14.1~
$ tt_2_tempo     <chr> "1899-12-31 02:08:00", "1899-12-31 01:47:25", ~
$ tt_2_km_h_real <dbl> 9.89, 11.79, 10.29, 14.72, 11.08, 10.93, 13.87~
$ tt_1_tempo     <chr> "1899-12-31 02:11:10", "1899-12-31 01:49:06", ~
$ tt_1_km_h_real <dbl> 9.65, 11.60, 10.61, 14.10, 10.55, 9.06, 12.17,~
$ z1_2_tempo     <chr> "1899-12-31 02:10:21", "1899-12-31 01:47:25", ~
$ z1_2_km_h_real <dbl> 9.71, 11.79, 10.29, 12.57, 10.36, 9.71, 12.18,~
$ z1_1_tempo     <chr> "1899-12-31 02:14:00", "1899-12-31 01:54:32", ~
$ z1_1_km_h_real <dbl> 9.45, 11.05, 9.36, 12.20, 10.54, 9.42, 11.27, ~
$ t1000_s12_tempo_real <int> 265, 258, 281, 191, 271, 248, 199, 237, 204, 1~
$ t1000_s12_km_h <dbl> 13.33, 13.95, 12.81, 18.85, 13.28, 14.52, 18.0~
$ t1000_s12_pace <chr> "1899-12-31 04:25:00", "1899-12-31 04:18:00", ~
$ t2000_s12_tempo_real <int> 595, 528, 617, 419, 555, 570, 432, 531, 457, 4~
$ t2000_s12_km_h <dbl> 12.10, 13.64, 11.67, 17.18, 12.97, 12.63, 16.6~
$ t2000_s12_pace <chr> "1899-12-31 04:58:00", "1899-12-31 04:24:00", ~
$ t3000_s12_tempo_real <int> 927, 810, 848, 657, 855, 849, 655, 805, 704, 6~
$ t3000_s12_km_h <dbl> 11.65, 13.33, 12.74, 16.44, 12.63, 12.72, 16.4~
$ t3000_s12_pace <chr> "1899-12-31 05:09:00", "1899-12-31 04:30:00", ~
$ vc_s12_real    <dbl> 11.44, 13.40, 12.60, 15.40, 12.30, 12.40, 16.4~
$ d_s12_real     <dbl> 114.00, 72.80, 33.80, 182.10, 75.40, 171.80, 8~
$ r_s12          <dbl> 0.99980, 0.99984, 0.99786, 0.99996, 0.99992, 0~
$ rmse_s12       <dbl> 4.0, 2.8, 11.7, 1.3, 2.0, 4.6, 2.1, 2.1, 1.8, ~
$ t1000_s4_tempo_real <chr> "280", "253", "278", "208", "261", "271", "205~
$ t1000_s4_km_h  <dbl> 12.86, 14.23, 12.95, 17.31, 13.79, 13.28, 17.5~

```

```

$ t1000_s4_pace <chr> "1899-12-31 04:40:00", "1899-12-31 04:13:00", ~
$ t2000_s4_tempo_real <int> 617, 526, 593, 436, 574, 555, 444, 545, 465, 4~
$ t2000_s4_km_h <dbl> 11.67, 13.69, 12.14, 16.51, 12.54, 12.97, 16.2~
$ t2000_s4_pace <chr> "1899-12-31 05:09:00", "1899-12-31 04:23:00", ~
$ t3000_s4_tempo_real <int> 912, 810, 924, 676, 860, 845, 693, 822, 719, 6~
$ t3000_s4_km_h <dbl> 11.84, 13.33, 11.69, 15.98, 12.56, 12.78, 15.5~
$ t3000_s4_pace <chr> "1899-12-31 05:04:00", "1899-12-31 04:30:00", ~
$ vc_s4_real <dbl> 11.40, 12.90, 11.10, 15.40, 12.00, 12.54, 14.8~
$ d_s4_real <dbl> 94.6, 98.4, 140.0, 112.8, 124.8, 59.3, 158.4, ~
$ r_s4 <dbl> 0.99856, 0.99987, 0.99948, 0.99993, 0.99911, 0~
$ rmse_s4 <dbl> 9.9, 2.6, 6.3, 2.2, 7.1, 4.9, 2.9, 2.7, 2.5, 1~
$ x1km_fresco_tempo_s0 <int> 300, 251, 296, 199, 274, 301, 236, 255, 221, 2~
$ x1km_fresco_oficial_s0 <chr> "1899-12-31 05:00:00", "1899-12-31 04:11:00", ~
$ x1km_fresco_vm_s0 <dbl> 12.00, 14.35, 12.10, 18.07, 13.10, 11.98, 15.2~
$ d_21km_s0_real_tempo <chr> "1899-12-31 02:11:10", "1899-12-31 01:49:06", ~
$ d_21km_s0_real <dbl> 9.65, 11.60, 10.61, 14.10, 10.55, 9.06, 12.17,~
$ x1km_pos_tempo_s0 <int> 330, 316, 292, 236, 331, 316, 297, 287, 277, 2~
$ x1km_pos_original_s0 <chr> "1899-12-31 05:30:00", "1899-12-31 05:16:00", ~
$ x1km_pos_vm_s0 <dbl> 10.91, 11.39, 12.30, 15.25, 10.88, 11.39, 12.7~
$ queda_s0 <dbl> -9.1, -20.6, -1.7, -15.6, -17.0, -4.9, -
16.3, ~
$ x1km_fresco_tempo_s4 <int> 280, 253, 278, 208, 261, 271, 205, 255, 213, 1~
$ x1km_fresco_oficial_s4 <chr> "1899-12-31 04:40:00", "1899-12-31 04:13:00", ~
$ x1km_fresco_vm_s4 <dbl> 12.86, 14.23, 12.90, 17.31, 13.79, 13.28, 17.6~
$ d_21km_s4_real_tempo <chr> "1899-12-31 02:14:00", "1899-12-31 01:54:32", ~
$ d_21km_s4_real <dbl> 9.45, 11.05, 9.36, 12.20, 10.54, 9.42, 11.27, ~
$ x1km_pos_tempo_s4 <int> 297, 289, 296, 203, 289, 333, 209, 270, 234, 2~
$ x1km_pos_original_s4 <chr> "1899-12-31 04:57:00", "1899-12-31 04:49:00", ~
$ x1km_pos_vm_s4 <dbl> 12.12, 12.53, 12.10, 17.58, 12.53, 10.87, 17.2~
$ queda_s4 <dbl> -5.8, -11.9, -6.2, 2.0, -8.9, -17.9, -2.2, -
5.~
$ x1km_fresco_tempo_s8 <int> 271, 241, 278, 190, 263, 272, 196, 232, 203, 1~
$ x1km_fresco_oficial_s8 <chr> "1899-12-31 04:31:00", "1899-12-31 04:01:00", ~
$ x1km_fresco_vm_s8 <dbl> 13.25, 14.99, 12.90, 18.75, 13.62, 13.16, 18.2~
$ d_21km_s8_real_tempo <chr> "1899-12-31 02:08:00", "1899-12-31 01:47:25", ~
$ d_21km_s8_real <dbl> 9.89, 11.79, 10.29, 14.72, 11.08, 10.93, 13.87~
$ x1km_pos_tempo_s8 <int> 315, 313, 293, 216, 286, 293, 227, 264, 249, 2~
$ x1km_pos_original_s8 <chr> "1899-12-31 05:15:00", "1899-12-31 05:13:00", ~
$ x1km_pos_vm_s8 <dbl> 11.43, 11.51, 12.17, 16.67, 12.00, 12.22, 15.8~
$ queda_s8 <dbl> -13.7, -23.2, -5.7, -11.1, -11.9, -7.1, -
13.6,~
$ x1km_fresco_tempo_s12 <int> 265, 258, 281, 191, 271, 248, 199, 237, 204, 1~
$ x1km_fresco_oficial_s12 <chr> "1899-12-31 04:25:00", "1899-12-31 04:18:00", ~

```



```

$ x1km_fresco_vm_s12      <dbl> 13.33, 13.95, 12.84, 18.75, 13.30, 14.52, 17.4~
$ d_21km_s12_real_tempo  <chr> "1899-12-31 02:10:21", "1899-12-31 01:47:25", ~
$ d_21km_s12_real        <dbl> 9.71, 11.79, 10.29, 12.57, 10.36, 9.71, 12.18,~
$ x1km_pos_tempo_s12     <int> 303, 274, 296, 224, 297, 258, 226, 253, 227, 2~
$ x1km_pos_original_s12  <chr> "1899-12-31 05:03:00", "1899-12-31 04:34:00", ~
$ x1km_pos_vm_s12        <dbl> 11.95, 13.13, 12.10, 15.96, 12.12, 14.08, 15.5~
$ queda_s12              <dbl> -10.4, -5.9, -5.8, -14.9, -8.9, -3.0, -
11.2, --
$ x1km_fresco_tempo_s16  <int> 278, 249, 280, 201, 263, 247, 216, 258, 198, 1~
$ x1km_fresco_oficial_s16 <chr> "1899-12-31 04:38:00", "1899-12-31 04:09:00", ~
$ x1km_fresco_vm_s16     <dbl> 12.90, 14.46, 12.86, 17.91, 13.62, 14.62, 16.6~
$ d_21km_s16_real_tempo  <chr> "8.4560185185185183E-2", "6.8275462962962968E-
~
$ d_21km_s16_real_vm     <dbl> 10.40, 12.88, 10.79, 15.00, 11.39, 11.90, 14.1~
$ x1km_pos_tempo_s16     <int> 305, 279, 272, 218, 289, 255, 230, 275, 239, 2~
$ x1km_pos_original_s16  <chr> "1899-12-31 05:05:00", "1899-12-31 04:39:00", ~
$ x1km_pos_vm_s16        <dbl> 11.88, 13.64, 13.16, 17.31, 12.53, 14.12, 15.7~
$ queda_s16              <dbl> -7.9, -5.7, 2.3, -3.3, -8.0, -3.4, -5.3, -
5.7,~
$ pres_s1                <int> 44, 44, 44, 53, 44, 44, 53, 44, 44, 53, 53, 44~
$ reali_s1               <int> 0, 49, 39, 57, 36, 21, 56, 57, 54, 49, 62, 56,~
$ dif_s1                 <int> -44, 5, -5, 4, -8, -23, 3, 13, 10, -4, 9, 12, ~
$ z1_s1                  <int> 0, 42, 39, 50, 29, 21, 45, 50, 48, 42, 55, 49,~
$ z2_s1                  <int> 0, 6, 0, 6, 6, 0, 5, 6, 5, 6, 6, 6, 6, 0, 6~
$ z3_s1                  <int> 0, 1, 0, 1, 1, 0, 6, 1, 1, 1, 1, 1, 1, 5, 1~
$ percent_z1_s1          <int> NA, 86, 100, 88, 81, 100, 80, 88, 89, 86, 89, ~
$ percent_z2_s1          <int> NA, 12, 0, 11, 17, 0, 9, 11, 9, 12, 10, 11, 13~
$ percent_z3_s1          <int> NA, 2, 0, 2, 3, 0, 11, 2, 2, 2, 2, 2, 2, 10~
$ pres_s2                <int> 47, 47, 47, 56, 47, 47, 56, 47, 47, 56, 56, 47~
$ reali_s2               <int> 32, 57, 44, 65, 41, 65, 65, 33, 59, 65, 65, 57~
$ dif_s2                 <int> -15, 10, -3, 9, -6, 18, 9, -14, 12, 9, 9, 10, ~
$ z1_s2                  <int> 32, 40, 38, 48, 24, 48, 49, 16, 49, 48, 48, 40~
$ z2_s2                  <int> 0, 12, 6, 12, 12, 12, 11, 8, 8, 12, 12, 12, 12~
$ z3_s2                  <int> 0, 5, 0, 5, 5, 5, 5, 9, 2, 5, 5, 5, 5, 5, 11, ~
$ percent_z1_s2          <int> 100, 70, 86, 74, 59, 74, 76, 49, 82, 74, 74, 7~
$ percent_z2_s2          <int> 0, 21, 14, 19, 29, 19, 17, 24, 13, 19, 19, 21,~
$ percent_z3_s2          <int> 0, 8, 0, 7, 12, 7, 7, 27, 4, 7, 7, 8, 15, 7, 1~
$ pres_s3                <int> 50, 50, 50, 59, 50, 50, 59, 50, 50, 59, 59, 50~
$ reali_s3               <int> 68, 44, 29, 68, 68, 68, 56, 56, 65, 48, 68, 47~
$ dif_s3                 <int> 18, -6, -21, 9, 18, 18, -3, 6, 15, -11, 9, -
3,~
$ z1_s3                  <int> 51, 39, 16, 51, 51, 51, 37, 47, 51, 35, 51, 43~
$ z2_s3                  <int> 12, 0, 8, 12, 12, 12, 14, 4, 12, 8, 12, 4, 4, ~

```

\$ z3_s3	<int> 5, 5, 5, 5, 5, 5, 5, 5, 2, 5, 5, 0, 5, 5, 5, 0~
\$ percent_z1_s3	<int> 75, 89, 56, 75, 75, 75, 66, 84, 78, 73, 75, 91~
\$ percent_z2_s3	<int> 18, 0, 28, 18, 18, 18, 25, 7, 18, 17, 18, 9, 7~
\$ percent_z3_s3	<int> 7, 11, 17, 7, 7, 7, 9, 9, 3, 10, 7, 0, 9, 6, 8~
\$ pres_s4	<int> 37, 37, 37, 45, 37, 37, 45, 37, 37, 45, 45, 37~
\$ reali_s4	<int> 36, 37, 34, 37, 37, 36, 56, 37, 41, 37, 37, 37~
\$ dif_s4	<int> -1, 0, -3, -8, 0, -1, 11, 0, 4, -8, -8, 0, -
22~	
\$ z1_s4	<int> 29, 30, 27, 30, 30, 29, 49, 30, 34, 30, 30, 30~
\$ z2_s4	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
\$ z3_s4	<int> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 6, 7, 7, 7~
\$ percent_z1_s4	<int> 81, 81, 79, 81, 81, 81, 88, 81, 83, 81, 81, 81~
\$ percent_z2_s4	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
\$ percent_z3_s4	<int> 19, 19, 21, 19, 19, 19, 13, 19, 17, 19, 19, 19~
\$ pres_s5	<int> 51, 51, 51, 66, 51, 51, 66, 51, 51, 66, 66, 51~
\$ reali_s5	<int> 51, 51, 51, 66, 51, 51, 51, 51, 50, 66, 66, 51~
\$ dif_s5	<int> 0, 0, 0, 0, 0, 0, -15, 0, -1, 0, 0, 0, 0, 0, 0~
\$ z1_s5	<int> 39, 39, 39, 48, 39, 39, 18, 39, 38, 54, 54, 39~
\$ z2_s5	<int> 8, 8, 8, 13, 8, 8, 29, 8, 8, 8, 8, 8, 8, 13, 1~
\$ z3_s5	<int> 4, 4, 4, 5, 4, 4, 4, 4, 4, 4, 4, 4, 4, 5, 5, 4~
\$ percent_z1_s5	<int> 76, 0, 76, 73, 76, 76, 35, 76, 76, 82, 82, 76,~
\$ percent_z2_s5	<int> 16, 16, 16, 20, 16, 16, 57, 16, 16, 12, 12, 16~
\$ percent_z3_s5	<int> 8, 8, 8, 8, 8, 8, 8, 8, 8, 6, 6, 8, 8, 8, 8, 8~
\$ pres_s6	<int> 53, 53, 53, 68, 53, 53, 68, 53, 53, 68, 68, 53~
\$ reali_s6	<int> 53, 27, 52, 66, 53, 53, 53, 53, 35, 68, 68, 51~
\$ dif_s6	<int> 0, -26, -1, -2, 0, 0, -15, 0, -18, 0, 0, -
2, --	
\$ z1_s6	<int> 41, 15, 40, 51, 41, 41, 41, 41, 23, 53, 53, 39~
\$ z2_s6	<int> 8, 8, 8, 10, 8, 8, 8, 8, 8, 10, 10, 8, 8, 10, ~
\$ z3_s6	<int> 4, 4, 4, 5, 4, 4, 4, 4, 4, 5, 5, 4, 4, 0, 5, 4~
\$ percent_z1_s6	<int> 77, 56, 77, 77, 77, 77, 77, 77, 66, 78, 78, 76~
\$ percent_z2_s6	<int> 15, 30, 15, 15, 15, 15, 15, 15, 23, 15, 15, 16~
\$ percent_z3_s6	<int> 8, 15, 8, 8, 8, 8, 8, 8, 11, 7, 7, 8, 9, 0, 7,~
\$ pres_s7	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
\$ reali_s7	<int> 55, 12, 63, 70, 55, 22, 68, 55, 56, 55, 70, 45~
\$ dif_s7	<int> 0, -43, 8, 0, 0, -33, -2, 0, 1, -15, 0, -
10, --	
\$ z1_s7	<int> 43, 4, 51, 55, 43, 10, 48, 43, 44, 40, 55, 37,~
\$ z2_s7	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 8, 0, 10,~
\$ z3_s7	<int> 4, 0, 4, 5, 4, 4, 10, 4, 4, 5, 5, 0, 4, 5, 5, ~
\$ percent_z1_s7	<int> 78, 33, 81, 79, 78, 45, 71, 78, 79, 73, 79, 82~
\$ percent_z2_s7	<int> 15, 67, 13, 14, 15, 36, 15, 15, 14, 18, 14, 18~
\$ percent_z3_s7	<int> 7, 0, 6, 7, 7, 18, 15, 7, 7, 9, 7, 0, 24, 7, 7~

\$ pres_s8	<int> 37, 37, 37, 48, 37, 37, 48, 37, 37, 48, 48, 37~
\$ reali_s8	<int> 28, 35, 35, 39, 36, 33, 50, 35, 35, 39, 39, 7,~
\$ dif_s8	<int> -9, -2, -2, -9, -1, -4, 2, -2, -2, -9, -9, -
30~	
\$ z1_s8	<int> 7, 7, 7, 9, 7, 5, 20, 7, 7, 9, 9, 2, 7, 9, 9, ~
\$ z2_s8	<int> 20, 26, 26, 27, 26, 26, 27, 26, 26, 27, 27, 5,~
\$ z3_s8	<int> 1, 2, 2, 3, 3, 2, 3, 2, 2, 3, 3, 0, 2, 3, 2, 0~
\$ percent_z1_s8	<int> 25, 20, 20, 23, 19, 15, 40, 20, 20, 23, 23, 29~
\$ percent_z2_s8	<int> 71, 74, 74, 69, 72, 79, 54, 74, 74, 69, 69, 71~
\$ percent_z3_s8	<int> 4, 6, 6, 8, 8, 6, 6, 6, 6, 8, 8, 0, 6, 8, 5, 0~
\$ pres_s9	<int> 51, 51, 51, 66, 51, 51, 66, 51, 51, 66, 66, 51~
\$ reali_s9	<int> 51, 51, 51, 66, 51, 51, 68, 51, 43, 66, 46, 0,~
\$ dif_s9	<int> 0, 0, 0, 0, 0, 0, 2, 0, -8, 0, -20, -51, -
12, ~	
\$ z1_s9	<int> 39, 39, 39, 51, 39, 39, 48, 39, 31, 51, 41, 0,~
\$ z2_s9	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 5, 5, 0, 4, 5, 5, 0~
\$ z3_s9	<int> 8, 8, 8, 10, 8, 8, 15, 8, 8, 10, 0, 0, 0, 10, ~
\$ percent_z1_s9	<int> 76, 76, 76, 77, 76, 76, 71, 76, 72, 77, 89, NA~
\$ percent_z2_s9	<int> 8, 8, 8, 8, 8, 8, 7, 8, 9, 8, 11, NA, 10, 8, 7~
\$ percent_z3_s9	<int> 16, 16, 16, 15, 16, 16, 22, 16, 19, 15, 0, NA,~
\$ pres_s10	<int> 53, 53, 53, 68, 53, 53, 68, 53, 53, 68, 68, 53~
\$ reali_s10	<int> 53, 53, 53, 68, 53, 53, 70, 53, 54, 64, 73, 0,~
\$ dif_s10	<int> 0, 0, 0, 0, 0, 0, 2, 0, 1, -4, 5, -53, -
12, 0,~	
\$ z1_s10	<int> 41, 41, 41, 53, 41, 41, 55, 41, 42, 54, 58, 0,~
\$ z2_s10	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 0, 5, 0, 4, 5, 5, 4~
\$ z3_s10	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 0, 6, 10,~
\$ percent_z1_s10	<int> 77, 77, 77, 78, 77, 77, 79, 77, 78, 84, 79, NA~
\$ percent_z2_s10	<int> 8, 8, 8, 7, 8, 8, 7, 8, 7, 0, 7, NA, 10, 7, 7,~
\$ percent_z3_s10	<int> 15, 15, 15, 15, 15, 15, 14, 15, 15, 16, 14, NA~
\$ pres_s11	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
\$ reali_s11	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 8,~
\$ dif_s11	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, -47, 0, -
29, ~	
\$ z1_s11	<int> 43, 43, 43, 55, 43, 43, 55, 43, 43, 55, 55, 8,~
\$ z2_s11	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 5, 5, 0, 4, 5, 5, 4~
\$ z3_s11	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 0, 8, 6, ~
\$ percent_z1_s11	<int> 78, 78, 78, 79, 78, 78, 79, 78, 78, 79, 79, 10~
\$ percent_z2_s11	<int> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 0, 7, 12, 7, ~
\$ percent_z3_s11	<int> 15, 15, 15, 14, 15, 15, 14, 15, 15, 14, 14, 0,~
\$ pres_s12	<int> 37, 37, 37, 48, 37, 37, 48, 37, 37, 48, 48, 37~
\$ reali_s12	<int> 37, 37, 37, 48, 37, 37, 40, 37, 37, 48, 48, 37~
\$ dif_s12	<int> 0, 0, 0, 0, 0, 0, -8, 0, 0, 0, 0, 0, -7, -

```

10, ~
$ z1_s12 <int> 30, 30, 30, 36, 30, 30, 32, 30, 30, 36, 36, 30~
$ z2_s12 <int> 2, 2, 2, 4, 2, 2, 4, 2, 2, 4, 4, 2, 2, 0, 4, 2~
$ z3_s12 <int> 5, 5, 5, 8, 5, 5, 4, 5, 5, 8, 8, 5, 4, 5, 8, 5~
$ percent_z1_s12 <int> 81, 81, 81, 75, 81, 81, 80, 81, 81, 75, 75, 81~
$ percent_z2_s12 <int> 5, 5, 5, 8, 5, 5, 10, 5, 5, 8, 8, 5, 7, 0, 8, ~
$ percent_z3_s12 <int> 14, 14, 14, 17, 14, 14, 10, 14, 14, 17, 17, 14~
$ pres_s13 <int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
$ reali_s13 <int> 55, 55, 55, 70, 55, 55, 69, 53, 56, 33, 70, 47~
$ dif_s13 <int> 0, 0, 0, 0, 0, 0, -1, -2, 1, -37, 0, -8, 7, 6, ~
$ z1_s13 <int> 43, 43, 43, 55, 51, 43, 53, 43, 44, 33, 55, 35~
$ z2_s13 <int> 4, 4, 4, 5, 4, 4, 6, 4, 4, 0, 5, 4, 4, 5, 6, 4~
$ z3_s13 <int> 8, 8, 8, 10, 0, 8, 10, 6, 8, 0, 10, 8, 9, 13, ~
$ percent_z1_s13 <int> 78, 78, 78, 79, 93, 78, 77, 81, 79, 100, 79, 7~
$ percent_z2_s13 <int> 7, 7, 7, 7, 7, 7, 9, 8, 7, 0, 7, 9, 6, 7, 8, 7~
$ percent_z3_s13 <int> 15, 15, 15, 14, 0, 15, 14, 11, 14, 0, 14, 17, ~
$ pres_s14 <int> 57, 57, 57, 73, 57, 57, 73, 57, 57, 73, 73, 57~
$ reali_s14 <int> 55, 57, 57, 74, 57, 57, 78, 57, 57, 73, 65, 57~
$ dif_s14 <int> -2, 0, 0, 1, 0, 0, 5, 0, 0, 0, -8, 0, -
18, 0, ~
$ z1_s14 <int> 43, 45, 45, 61, 57, 45, 65, 45, 45, 60, 52, 45~
$ z2_s14 <int> 4, 4, 4, 5, 0, 4, 5, 4, 4, 5, 5, 4, 4, 5, 5, 4~
$ z3_s14 <int> 8, 8, 8, 8, 0, 8, 8, 8, 8, 8, 8, 8, 4, 8, 12, ~
$ percent_z1_s14 <int> 78, 79, 79, 82, 100, 79, 83, 79, 79, 82, 80, 7~
$ percent_z2_s14 <int> 7, 7, 7, 7, 0, 7, 6, 7, 7, 7, 8, 7, 10, 7, 9, ~
$ percent_z3_s14 <int> 15, 14, 14, 11, 0, 14, 10, 14, 14, 11, 12, 14,~
$ pres_s15 <int> 60, 60, 60, 77, 60, 60, 77, 60, 60, 77, 77, 60~
$ reali_s15 <int> 60, 60, 62, 77, 52, 60, 82, 53, 60, 77, 77, 60~
$ dif_s15 <int> 0, 0, 2, 0, -8, 0, 5, -7, 0, 0, 0, 0, 0, 0, -
2~
$ z1_s15 <int> 48, 48, 50, 64, 48, 48, 68, 49, 48, 64, 64, 48~
$ z2_s15 <int> 4, 4, 4, 5, 4, 4, 6, 4, 4, 5, 5, 4, 4, 5, 0, 4~
$ z3_s15 <int> 8, 8, 8, 8, 0, 8, 8, 0, 8, 8, 8, 8, 8, 8, 11, ~
$ percent_z1_s15 <int> 80, 80, 81, 83, 92, 80, 83, 92, 80, 83, 83, 80~
$ percent_z2_s15 <int> 7, 7, 6, 6, 8, 7, 7, 8, 7, 6, 6, 7, 7, 6, 0, 7~
$ percent_z3_s15 <int> 13, 13, 13, 10, 0, 13, 10, 0, 13, 10, 10, 13, ~
$ pres_s16 <int> 40, 40, 40, 51, 40, 40, 51, 40, 40, 51, 51, 40~
$ reali_s16 <int> 40, 39, 39, 51, 7, 40, 44, 40, 40, 45, 28, 40,~
$ dif_s16 <int> 0, -1, -1, 0, -33, 0, -7, 0, 0, -6, -23, 0, -
1~
$ z1_s16 <int> 35, 34, 34, 43, 7, 35, 37, 35, 35, 43, 26, 35,~
$ z2_s16 <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 12, ~
$ z3_s16 <int> 5, 5, 5, 8, 0, 5, 7, 5, 5, 2, 2, 5, 4, 2, 2, 5~

```

```

$ percent_z1_s16      <int> 88, 87, 87, 84, 100, 88, 84, 88, 88, 96, 93, 8~
$ percent_z2_s16      <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 10, 25, ~
$ percent_z3_s16      <int> 13, 13, 13, 16, 0, 13, 16, 13, 13, 4, 7, 13, 1~
$ l1_s0               <dbl> 9.70, 11.25, 9.80, 13.55, 10.25, 9.10, 11.80, ~
$ l2_s0               <dbl> 10.55, 12.35, 10.85, 14.65, 11.35, 10.35, 13.0~
$ l1_s8               <dbl> 9.95, 11.45, 10.50, 14.05, 10.70, 10.15, 14.10~
$ l2_s8               <dbl> 10.75, 12.55, 11.65, 15.10, 11.80, 11.35, 15.2~
$ l1_s16              <dbl> 10.05, 11.80, 10.65, 14.35, 11.00, 11.10, 14.0~
$ l2_s16              <dbl> 10.95, 12.80, 11.60, 15.30, 12.10, 12.10, 15.2~
$ maratona_menos_4h   <chr> "4h ou mais", "menos de 4h", "4h ou mais", "me~

```

2.0.5 Número de variáveis

```
ncol(select_if(dados, is.numeric))
```

```
[1] 205
```

2.0.6 Número de valores faltantes

```

na_count <- sapply(select_if(dados, is.numeric), function(y) sum(is.na(y)))
na_count <- data.frame(na_count)
na_count |> arrange(desc(na_count))

```

	na_count
percent_z1_s1	2
percent_z2_s1	2
percent_z3_s1	2
percent_z1_s4	2
percent_z2_s4	2
percent_z3_s4	2
reali_s1	1
dif_s1	1
z1_s1	1
z2_s1	1
z3_s1	1
reali_s2	1
dif_s2	1
z1_s2	1

z2_s2	1
z3_s2	1
percent_z1_s2	1
percent_z2_s2	1
percent_z3_s2	1
reali_s3	1
dif_s3	1
z1_s3	1
z2_s3	1
z3_s3	1
percent_z1_s3	1
percent_z2_s3	1
percent_z3_s3	1
reali_s4	1
z1_s4	1
z2_s4	1
z3_s4	1
pres_s5	1
reali_s5	1
z1_s5	1
z2_s5	1
z3_s5	1
percent_z1_s5	1
percent_z2_s5	1
percent_z3_s5	1
reali_s6	1
z1_s6	1
z2_s6	1
z3_s6	1
percent_z1_s6	1
percent_z2_s6	1
percent_z3_s6	1
reali_s7	1
z1_s7	1
z2_s7	1
z3_s7	1
percent_z1_s7	1
percent_z2_s7	1
percent_z3_s7	1
percent_z1_s9	1
percent_z2_s9	1
percent_z3_s9	1
percent_z1_s10	1

percent_z2_s10	1
percent_z3_s10	1
maratona_km_h_real	0
tt_3_km_h_real	0
tt_2_km_h_real	0
tt_1_km_h_real	0
z1_2_km_h_real	0
z1_1_km_h_real	0
t1000_s12_tempo_real	0
t1000_s12_km_h	0
t2000_s12_tempo_real	0
t2000_s12_km_h	0
t3000_s12_tempo_real	0
t3000_s12_km_h	0
vc_s12_real	0
d_s12_real	0
r_s12	0
rmse_s12	0
t1000_s4_km_h	0
t2000_s4_tempo_real	0
t2000_s4_km_h	0
t3000_s4_tempo_real	0
t3000_s4_km_h	0
vc_s4_real	0
d_s4_real	0
r_s4	0
rmse_s4	0
x1km_fresco_tempo_s0	0
x1km_fresco_vm_s0	0
d_21km_s0_real	0
x1km_pos_tempo_s0	0
x1km_pos_vm_s0	0
queda_s0	0
x1km_fresco_tempo_s4	0
x1km_fresco_vm_s4	0
d_21km_s4_real	0
x1km_pos_tempo_s4	0
x1km_pos_vm_s4	0
queda_s4	0
x1km_fresco_tempo_s8	0
x1km_fresco_vm_s8	0
d_21km_s8_real	0
x1km_pos_tempo_s8	0

x1km_pos_vm_s8	0
queda_s8	0
x1km_fresco_tempo_s12	0
x1km_fresco_vm_s12	0
d_21km_s12_real	0
x1km_pos_tempo_s12	0
x1km_pos_vm_s12	0
queda_s12	0
x1km_fresco_tempo_s16	0
x1km_fresco_vm_s16	0
d_21km_s16_real_vm	0
x1km_pos_tempo_s16	0
x1km_pos_vm_s16	0
queda_s16	0
pres_s1	0
pres_s2	0
pres_s3	0
pres_s4	0
dif_s4	0
dif_s5	0
pres_s6	0
dif_s6	0
pres_s7	0
dif_s7	0
pres_s8	0
reali_s8	0
dif_s8	0
z1_s8	0
z2_s8	0
z3_s8	0
percent_z1_s8	0
percent_z2_s8	0
percent_z3_s8	0
pres_s9	0
reali_s9	0
dif_s9	0
z1_s9	0
z2_s9	0
z3_s9	0
pres_s10	0
reali_s10	0
dif_s10	0
z1_s10	0

z2_s10	0
z3_s10	0
pres_s11	0
reali_s11	0
dif_s11	0
z1_s11	0
z2_s11	0
z3_s11	0
percent_z1_s11	0
percent_z2_s11	0
percent_z3_s11	0
pres_s12	0
reali_s12	0
dif_s12	0
z1_s12	0
z2_s12	0
z3_s12	0
percent_z1_s12	0
percent_z2_s12	0
percent_z3_s12	0
pres_s13	0
reali_s13	0
dif_s13	0
z1_s13	0
z2_s13	0
z3_s13	0
percent_z1_s13	0
percent_z2_s13	0
percent_z3_s13	0
pres_s14	0
reali_s14	0
dif_s14	0
z1_s14	0
z2_s14	0
z3_s14	0
percent_z1_s14	0
percent_z2_s14	0
percent_z3_s14	0
pres_s15	0
reali_s15	0
dif_s15	0
z1_s15	0
z2_s15	0


z3_s15	0
percent_z1_s15	0
percent_z2_s15	0
percent_z3_s15	0
pres_s16	0
reali_s16	0
dif_s16	0
z1_s16	0
z2_s16	0
z3_s16	0
percent_z1_s16	0
percent_z2_s16	0
percent_z3_s16	0
l1_s0	0
l2_s0	0
l1_s8	0
l2_s8	0
l1_s16	0
l2_s16	0

2.0.7 Distribuição das variáveis mais importantes

```
dados_filtrados <- dados |>
  select_if(is.numeric) |>
  select(-contains(c("tempo_real", "pace")))
```

```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = maratona_km_h_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 1.0,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "maratona em km/h" em cada grupo') +
  xlab("") +
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_1_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Time trail de 21km - avaliação 1" em cada grupo')+
  labs(y = "Time trail de 21km - avaliação 1 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_2_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Time trail de 21km – avaliação 2" em cada grupo')+
  labs(y = "Time trail de 21km – avaliação 2 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_3_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Time trail de 21km – avaliação 3" em cada grupo')+
  labs(y = "Time trail de 21km – avaliação 3 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = z1_1_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "21km em Z1 – avaliação 2" em cada grupo')+
  labs(y = "21km em Z1 – avaliação 2 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```



```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = z1_2_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "21km em Z1 – avaliação 2" em cada grupo')+
  labs(y = "21km em Z1 – avaliação 2 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```


```
theme_minimal()+
xlab("")
```



```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t1000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 1km - Semana 4" em cada grupo')+
  labs(y = "Teste 1km - Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```




```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t2000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 2km – Semana 4" em cada grupo')+
  labs(y = "Teste 2km – Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t3000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = -0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 3km – Semana 4" em cada grupo')+
  labs(y = "Teste 3km – Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = vc_s4_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Velocidade crítica - Semana 4" em cada grupo')+
  labs(y = "Velocidade crítica - Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = d_s4_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle("Distância máxima que pode ser percorrida acima da velocidade crítica - Semana 4") +
  labs(y = "Distância (km/h)") +
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t1000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 1km - Semana 12" em cada grupo')+
  labs(y = "Teste 1km - Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t2000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 2km - Semana 12" em cada grupo')+
  labs(y = "Teste 2km - Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```

```
theme_minimal()+
xlab("")
```



```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t3000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Teste 3km – Semana 12" em cada grupo')+
  labs(y = "Teste 3km – Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```


```
theme_minimal()+
xlab("")
```



```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = vc_s12_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Velocidade crítica - Semana 12" em cada grupo')+
  labs(y = "Velocidade crítica - Semana 4 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
```




```
theme_minimal()+
xlab("")
```




```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = d_s12_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0.5,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle("Distância máxima que pode ser percorrida acima da velocidade crítica – Semana 12") +
  labs(y = "Distância (km/h)") +
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
```

```
theme_minimal()+
xlab("")
```



```
ggplot(data = dados)+
  geom_bar(mapping = aes(x = maratona_menos_4h), fill = "#A8CCC9")+
  theme_minimal()+
  xlab("")
```



3 Desempenho ao longo das semanas

3.1 TT (S0, S8 e S16)

```
df_21km <- dados %>%
  select(
    grupo,
    atleta = codigo,
    s0 = `tt_1_km_h_real`,
    s8 = `tt_2_km_h_real`,
    s16 = `tt_3_km_h_real`
  ) %>%
  drop_na(grupo)

df_long <- df_21km %>%
  pivot_longer(
    cols = starts_with("s"),
    names_to = "semana",
    values_to = "velocidade_media"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("s0", "s8", "s16"))
  )


resumo_exploratorio <- df_long %>%
  group_by(grupo, semana) %>%
  summarise(
    n = n(),
    media = mean(velocidade_media, na.rm = TRUE),
    mediana = median(velocidade_media, na.rm = TRUE),
    desvio_padrao = sd(velocidade_media, na.rm = TRUE),
    minimo = min(velocidade_media, na.rm = TRUE),
    maximo = max(velocidade_media, na.rm = TRUE),
    .groups = "drop"
```

grupo	semana	n	media	mediana	desvio_padrao	minimo	maximo
G1	s0	16	11.84313	11.885	1.762444	9.06	14.89
G1	s8	16	12.46687	12.265	1.857994	9.89	15.50
G1	s16	16	12.83250	12.910	1.854391	9.98	15.85
G2	s0	14	11.25571	11.010	1.362152	9.52	13.45
G2	s8	14	11.93643	12.035	1.679165	10.06	14.82
G2	s16	14	12.12786	12.710	1.653352	9.91	14.65

)


```
resumo_exploratorio |> gt()
```

```
ggplot(data = df_long, mapping = aes(x = semana, y = velocidade_media, fill = grupo))+
  geom_boxplot()+
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = -0.8,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  labs(y = "Velocidade do TT (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
  theme_minimal()+
  xlab("Semana")
```



```
p <- ggplot(df_long, aes(x = semana, y = velocidade_media, group = atleta, color = grupo))
  geom_line(alpha = 0.5, size = 0.8) +
  geom_point(size = 2, alpha = 0.7) +
  scale_color_manual(values = c("#c7d66d", "#75b9be")) +
  facet_wrap(~ grupo) +
  labs(
    title = "Trajetória individual nos 21km TT",
    x = "Semanas de treino",
    y = "velocidade média (km/h)"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

ggplotly(p, tooltip = c("atleta", "velocidade_media"))
```



3.2 Z1 (S4 e S12)

```
df_z1 <- dados %>%
  select(
    grupo,
    atleta = codigo,
    s4 = z1_1_km_h_real,
    s12 = z1_2_km_h_real
  ) %>%
  drop_na(grupo)

z1_long <- df_z1 %>%
  pivot_longer(
    cols = starts_with("s"),
    names_to = "semana",
    values_to = "velocidade_media"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("s4", "s12"))
  )

resumo_exploratorio_z1 <- z1_long %>%
  group_by(grupo, semana) %>%
  summarise(
    n = n(),
    media = mean(velocidade_media, na.rm = TRUE),
    mediana = median(velocidade_media, na.rm = TRUE),
    desvio_padrao = sd(velocidade_media, na.rm = TRUE),
    minimo = min(velocidade_media, na.rm = TRUE),
    maximo = max(velocidade_media, na.rm = TRUE),
    .groups = "drop"
  )

resumo_exploratorio_z1 |> gt()
```


```
ggplot(data = z1_long, mapping = aes(x = semana, y = velocidade_media, fill = grupo))+
  geom_boxplot()+
  stat_summary(
    fun = mean,
```


grupo	semana	n	media	mediana	desvio_padrao	minimo	maximo
G1	s4	16	10.72937	11.045	0.8594298	9.36	12.20
G1	s12	16	11.16188	11.475	1.1485946	9.21	12.57
G2	s4	14	10.53571	10.265	0.8534249	9.58	12.06
G2	s12	14	10.60000	10.240	1.5104202	7.11	12.53

```

geom = "text",
aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
labs(y = "Velocidade em Z1 (km/h)") +
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
theme_minimal() +
xlab("Semana")


```



O outlier é o atleta $G2_9$ que realizou a avaliação com velocidade media de 7.11 km/h

```
p <- ggplot(z1_long, aes(x = semana, y = velocidade_media, group = atleta, color = grupo)) +  
  geom_line(alpha = 0.5, size = 0.8) +  
  geom_point(size = 2, alpha = 0.7) +  
  scale_color_manual(values = c("#c7d66d", "#75b9be")) +  
  facet_wrap(~ grupo) +  
  labs(  
    title = "Trajetória individual nos 21km TT",  
    x = "Semanas de treino",  
    y = "velocidade média (km/h)"  
  ) +  
  theme_minimal() +  
  theme(legend.position = "none")  
  
ggplotly(p, tooltip = c("atleta", "velocidade_media"))
```

Trajetória individual nos 21km TT



4 Validação dos dados

4.0.1 Quantidade de atletas com o treino válido

$$L1_0 < L2_0 < VC_4$$

```
dados |> mutate(validade_s4 = ifelse(l1_s0 < l2_s0 & l2_s0 < vc_s4_real, "Válido", "Não Válido")) |> filter(validade_s4 == "Válido") |> nrow()
```

```
[1] 30
```

4.0.2 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S0

$$VM \text{ 1km fresco} < VM \text{ 1 km pós}$$

```
dados |> filter(x1km_fresco_vm_s0 < x1km_pos_vm_s0) |> select(1:3, maratona_tempo, x1km_fresco_vm_s0, x1km_pos_vm_s0) |> mutate(
  cols_label(
    grupo = "Grupo",
    codigo = "Código",
    nome = "Atleta",
    maratona_tempo = "Tempo da maratona",
    x1km_fresco_vm_s0 = "1 km fresco",
    x1km_pos_vm_s0 = "1 km pós"
  ) |>
  cols_align(
    align = "center",
    columns = everything()
  )
)
```

4.0.3 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S4

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_03	Amanda	04:08:30	12.10	12.30
G2	G2_06	Netto	03:30:58	18.56	18.75
G2	G2_07	Emerson Komuda	03:49:37	13.64	13.95
G2	G2_12	Mayara	03:10:29	15.65	15.79

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_04	Ana Munaro	03:00:28	17.31	17.58
G1	G1_13	Paula	04:01:06	12.33	13.16
G2	G2_14	Giulia	03:26:28	17.48	17.65

```
dados |> filter(x1km_fresco_vm_s4 < x1km_pos_vm_s4) |>select(1:3, maratona_tempo, x1km_fresco_vm_s4, x1km_pos_vm_s4)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s4 = "1 km fresco",
  x1km_pos_vm_s4 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.4 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S8

```
dados |> filter(x1km_fresco_vm_s8 < x1km_pos_vm_s8) |>select(1:3, maratona_tempo, x1km_fresco_vm_s8, x1km_pos_vm_s8)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s8 = "1 km fresco",
  x1km_pos_vm_s8 = "1 km pós"
) |>
```

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G2	G2_06	Netto	03:30:58	18	18.18

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G2	G2_06	Netto	03:30:58	18.29	18.35

```
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.5 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S12

```
dados |> filter(x1km_fresco_vm_s12 < x1km_pos_vm_s12) |>select(1:3, maratona_tempo, x1km_fresco_vm_s12, x1km_pos_vm_s12) |>
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s12 = "1 km fresco",
  x1km_pos_vm_s12 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.6 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S16

```
dados |> filter(x1km_fresco_vm_s16 < x1km_pos_vm_s16) |>select(1:3, maratona_tempo, x1km_fresco_vm_s16, x1km_pos_vm_s16) |>
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s16 = "1 km fresco",
  x1km_pos_vm_s16 = "1 km pós"
)
```

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_03	Amanda	04:08:30	12.86	13.16
G1	G1_13	Paula	04:01:06	13.39	13.66

```

nome = "Atleta",
maratona_tempo = "Tempo da maratona",
x1km_fresco_vm_s16 = "1 km fresco",
x1km_pos_vm_s16 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)

```

5 Perguntas

Abaixo, realizamos a leitura das bases brutas e aplicamos as rotinas de tratamento para padronização de separadores decimais, correção de escalas de peso e estruturação das variáveis.

```
library(tidyverse)
library(lubridate)
library(knitr)
library(lme4)
library(lmerTest)
library(kableExtra)

df_quant_bruto <- read_csv2("Book 2(Planilha1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

df_quali_bruto <- read_csv2("Quali(Planilha1) (1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

to_num <- function(x) {
  suppressWarnings(as.numeric(str_replace_all(as.character(x), ",", ".")))
}

fix_peso <- function(x) {
  sapply(x, function(val) {
    num <- suppressWarnings(as.numeric(str_replace_all(as.character(val), ",", ".")))
    if (is.na(num)) return(NA_real_)
    while (num > 150) { num <- num / 10 }
    return(round(num, 2))
  })
}

parse_md <- function(x) {
  x_str <- str_trim(as.character(x))
  case_when(
    str_detect(tolower(x_str), "^s|^1") ~ 1,
    str_detect(tolower(x_str), "^n|^0") ~ 0,
  )
}
```



```

    TRUE ~ NA_real_
  )
}

parse_likert_num <- function(x) {
  x_str <- str_trim(as.character(x))
  if_else(
    str_detect(x_str, "[0-9]"),
    suppressWarnings(as.numeric(str_sub(x_str, 1, 1))),
    suppressWarnings(as.numeric(str_replace_all(x_str, ",", ".")))
  )
}

names(df_quant_bruto)[names(df_quant_bruto) %in% c("Maratona_Km/h_REAL", "Maratona_Km.h_REAL")] <- "Maratona_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_1_Km/h_REAL", "TT_1_Km.h_REAL")] <- "TT_1_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_2_Km/h_REAL", "TT_2_Km.h_REAL")] <- "TT_2_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_3_Km/h_REAL", "TT_3_Km.h_REAL")] <- "TT_3_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_1_Km/h_REAL", "z1_1_Km.h_REAL")] <- "z1_1_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_2_Km/h_REAL", "z1_2_Km.h_REAL")] <- "z1_2_Km/h_REAL"

df_quant <- df_quant_bruto %>%
  mutate(
    Grupo = as.factor(Grupo),
    Maratona_Minutos = as.numeric(Maratona_Tempo) / 60,
    Maratona_Kmh = to_num(Maratona_Kmh_Original),
    TT_S0 = to_num(TT_1_Kmh_Original),
    TT_S8 = to_num(TT_2_Kmh_Original),
    TT_S16 = to_num(TT_3_Kmh_Original),
    Z1_S4 = to_num(z1_1_Kmh_Original),
    Z1_S12 = to_num(z1_2_Kmh_Original),
    VC_S4_limpa = if_else(to_num(VC_S4_REAL) > 30, to_num(VC_S4_REAL)/10, to_num(VC_S4_REAL)),
    VC_S12_limpa = if_else(to_num(VC_S12_REAL) > 30, to_num(VC_S12_REAL)/10, to_num(VC_S12_REAL)),
    Queda_1km_S0 = abs(to_num(Queda_S0)),
    Queda_1km_S4 = abs(to_num(Queda_S4)),
    Queda_1km_S8 = abs(to_num(Queda_S8)),
    Queda_1km_S12 = abs(to_num(Queda_S12)),
    Queda_1km_S16 = abs(to_num(Queda_S16)),
    Nome_clean = str_to_lower(str_trim(iconv(Nome, to = "ASCII//TRANSLIT")))
  )
}

```

```

df_quali_clean <- df_quali_bruto %>%
  mutate(
    across(starts_with("Peso_"), fix_peso),
    across(starts_with("MD_"), parse_md),
    across(c(starts_with("Sono_"), starts_with("Stress_"), starts_with("Fadiga_"), starts_wi
      Nome_clean = str_to_lower(str_trim(iconv(`Nome completo`, to = "ASCII//TRANSLIT")))
    )
  )

df_all <- df_quant %>%
  inner_join(df_quali_clean, by = "Nome_clean")

```

6 Bloco 1: Análises Perceptivas e Qualitativas ($N = 28$)

6.1 Pergunta 1: Como se comporta a percepção de desgaste entre os grupos?

O que faz o Teste de Mann-Whitney? É um teste estatístico não paramétrico utilizado para comparar duas amostras independentes. Ele avalia se uma distribuição tende a apresentar valores maiores do que a outra sem assumir que os dados seguem uma distribuição normal.

```
dominios <- c("Sono", "Stress", "Fadiga", "Dor", "MD")

res_p1 <- map_df(dominios, function(dom) {
  cols <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S"))]
  df_all$media_dom <- rowMeans(df_all[, cols], na.rm = TRUE)
  m_g1 <- mean(df_all$media_dom[df_all$Grupo == "G1"], na.rm = TRUE)
  m_g2 <- mean(df_all$media_dom[df_all$Grupo == "G2"], na.rm = TRUE)
  wt <- wilcox.test(media_dom ~ Grupo, data = df_all)
  tibble(
    Domínio = dom,
    `Média G1` = round(m_g1, 2),
    `Média G2` = round(m_g2, 2),
    `p-valor` = round(wt$p.value, 4),
    `Significância` = if_else(wt$p.value < 0.05, "Significativo (p < 0,05)", "Não Significativo")
  )
})

res_p1 %>%
  kable(caption = "Comparação das Médias Qualitativas Acumuladas entre os Grupos") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 6.1: Comparação das Médias Qualitativas Acumuladas entre os Grupos

Domínio	Média G1	Média G2	p-valor	Significância
---------	----------	----------	---------	---------------

Sono	3.14	3.71	0.0257	Significativo (p < 0,05)
Stress	3.50	4.22	0.0242	Significativo (p < 0,05)
Fadiga	3.45	3.71	0.4155	Não Significativo
Dor	3.22	3.37	0.6757	Não Significativo
MD	0.35	0.35	0.9227	Não Significativo


6.1.1 Gráfico da série temporal qualitativa

```
df_serie <- df_all %>%
  select(Grupo, Nome_clean, starts_with("Fadiga_S"), starts_with("Stress_S"), starts_with("Dor_S"), starts_with("MD_S")) %>%
  pivot_longer(cols = -c(Grupo, Nome_clean), names_to = "Variavel_Semana", values_to = "Escore") %>%
  separate(Variavel_Semana, into = c("Variavel", "Semana"), sep = "_S") %>%
  mutate(Semana = as.numeric(Semana))

ggplot(df_serie, aes(x = Semana, y = Escore, color = Grupo, group = Grupo)) +
  stat_summary(fun = mean, geom = "line", linewidth = 1) +
  stat_summary(fun = mean, geom = "point", size = 2) +
  facet_wrap(~Variavel, scales = "free_y") +
  labs(
    title = "Evolução Semanal da Percepção Qualitativa (S4 a S18)",
    subtitle = "Linhas representam a média semanal de cada grupo",
    x = "Semana de Treinamento",
    y = "Escore Médio Percebido",
    color = "Sequência de Treino"
  ) +
  theme_minimal() +
  scale_color_brewer(palette = "Set1")
```

Evolução Semanal da Percepção Qualitativa (S4 a S18)

Linhas representam a média semanal de cada grupo



O que os dados nos mostram: Iniciando a análise, observamos diferenças importantes no bem-estar percebido. Os maratonistas do Grupo 2 relataram um nível de estresse significativamente mais alto (4,22 contra 3,50, com p-valor igual a 0,0242) e uma qualidade de sono pior (3,71 contra 3,14, com p-valor igual a 0,0257) quando comparados ao Grupo 1. As variáveis de fadiga, dor e frequência de momentos difíceis mantiveram-se equivalentes entre ambos.

6.2 Pergunta 2: O mesmo atleta sente mais desgaste no 1º ou no 2º bloco de treinos?

O que faz o Teste de Wilcoxon Pareado? Avalia a diferença dentro do mesmo indivíduo em dois momentos temporais distintos. Ele verifica se a intervenção ao longo do tempo altera o comportamento da variável para cada sujeito.

```
res_p2 <- map_df(dominios, function(dom) {
  cols_p1 <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S[4-8]$"))]
  cols_p2 <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S(9|10|11|12|13|14|15)$"))]
  p1_m <- rowMeans(df_all[, cols_p1], na.rm = TRUE)
```

```

p2_m <- rowMeans(df_all[, cols_p2], na.rm = TRUE)
wt <- wilcox.test(p1_m, p2_m, paired = TRUE)
tibble(
  Domínio = dom,
  `Média 1º Bloco` = round(mean(p1_m, na.rm=T), 2),
  `Média 2º Bloco` = round(mean(p2_m, na.rm=T), 2),
  `p-valor` = round(wt$p.value, 4)
)
})

res_p2 %>%
  kable(caption = "Comparação Intrasujeito entre o 1º Bloco (S1-S8) e o 2º Bloco (S9-S16)") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))

```

Table 6.2: Comparação Intrasujeito entre o 1º Bloco (S1-S8) e o 2º Bloco (S9-S16)

Domínio	Média 1º Bloco	Média 2º Bloco	p-valor
Sono	3.45	3.37	0.9494
Stress	3.93	3.79	0.3486
Fadiga	3.53	3.73	0.1460
Dor	3.21	3.45	0.1059
MD	0.36	0.36	0.9645

O que os dados nos mostram: Analisando a resposta de cada atleta em relação a si mesmo, observamos estabilidade nos indicadores. Embora a fadiga percebida e a dor muscular apresentem elevação numérica do primeiro para o segundo bloco de treino, essa oscilação manteve-se estatisticamente estável, demonstrando que os atletas conseguiram assimilar o acúmulo de carga na segunda metade da preparação sem sofrer picos de desgaste perceptivo.

6.3 Pergunta 3: Quais fatores perceptivos se associam ao tempo da maratona?

O que faz a Correlação de Spearman (r_s)? Mede a força e a direção da associação entre duas variáveis. Varia de -1 a $+1$, onde valores próximos de zero indicam ausência de relação linear ou monotônica.

```

res_p3 <- map_df(dominios, function(dom) {
  cols <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S"))]
  media_dom <- rowMeans(df_all[, cols], na.rm = TRUE)
})

```

```

cor_res <- cor.test(media_dom, df_all$Maratona_Minutos, method = "spearman")
tibble(
  Domínio = dom,
  `Rho de Spearman (r_s)` = round(cor_res$estimate, 3),
  `p-valor` = round(cor_res$p.value, 4),
  `Significância` = if_else(cor_res$p.value < 0.05, "Significativo", "Não Significativo")
)
})

res_p3 %>%
  kable(caption = "Correlação entre Indicadores Qualitativos e Tempo Total de Maratona (minutos)",
        kable_styling(bootstrap_options = c("striped", "hover", "condensed")))

```

Table 6.3: Correlação entre Indicadores Qualitativos e Tempo Total de Maratona (minutos)

Domínio	Rho de Spearman (r_s)	p-valor	Significância
Sono	-0.246	0.2074	Não Significativo
Stress	-0.179	0.3616	Não Significativo
Fadiga	0.206	0.2929	Não Significativo
Dor	0.012	0.9515	Não Significativo
MD	-0.386	0.0427	Significativo

O que os dados nos mostram: A única variável perceptiva que apresentou associação significativa com o tempo total de maratona foi a presença de Momento Difícil ($r_s = -0,386$, com p-valor igual a 0,0427). Atletas que relataram encarar momentos desafiadores com clareza mantiveram maior disciplina na gestão do ritmo de prova durante a maratona.

7 Bloco 2: Análises de Desempenho Físico e Maratona ($N = 30$)

7.1 Perguntas 4 e 5: A ordem dos treinos altera o resultado da Maratona por nível de rendimento?

O que faz o Teste T de Welch? Compara as médias de dois grupos independentes sem exigir a premissa de que as populações tenham a mesma variância.

```
sub4 <- df_all %>% filter(Maratona_Minutos < 240)
sup4 <- df_all %>% filter(Maratona_Minutos >= 240)

t_sub4 <- t.test(Maratona_Minutos ~ Grupo, data = sub4)
t_sup4 <- t.test(Maratona_Minutos ~ Grupo, data = sup4)

res_subgrupos <- tibble(
  Subgrupo = c("Sub-4 Horas (< 240 min)", "Acima de 4 Horas (>= 240 min)"),
  `Média G1 (min)` = c(round(t_sub4$estimate[1], 1), round(t_sup4$estimate[1], 1)),
  `Média G2 (min)` = c(round(t_sub4$estimate[2], 1), round(t_sup4$estimate[2], 1)),
  `Diferença (min)` = c(round(t_sub4$estimate[1] - t_sub4$estimate[2], 1), round(t_sup4$estimate[1] - t_sup4$estimate[2], 1)),
  `p-valor` = c(round(t_sub4$p.value, 4), round(t_sup4$p.value, 4)),
  `Conclusão` = c("Significativo (G1 mais rápido)", "Não Significativo")
)


res_subgrupos %>%
  kable(caption = "Comparação do Tempo de Maratona por Subgrupo de Rendimento") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 7.1: Comparação do Tempo de Maratona por Subgrupo de Rendimento

Subgrupo	Média G1 (min)	Média G2 (min)	Diferença (min)	p-valor	Conclusão
Sub-4 Horas (< 240 min)	197.2	218.6	-21.4	0.0146	Significativo
Acima de 4 Horas (>= 240 min)	258.2	264.6	-6.4	0.4091	Não Significativo

7.1.1 Gráfico de desempenho na maratona

```
df_all %>%
  mutate(Categoria = if_else(Maratona_Minutos < 240, "Sub-4h (< 240 min)", "Acima de 4h (>= 240 min)")) +
  ggplot(aes(x = Categoria, y = Maratona_Minutos, fill = Grupo)) +
  geom_boxplot(alpha = 0.7, outlier.shape = NA) +
  geom_jitter(position = position_jitterdodge(jitter.width = 0.15), size = 2.5, alpha = 0.8) +
  labs(
    title = "Tempo de Conclusão da Maratona por Categoria de Rendimento",
    subtitle = "Destaque para a vantagem do Grupo 1 entre os atletas Sub-4 horas",
    x = "Categoria de Atleta",
    y = "Tempo Total em Minutos",
    fill = "Sequência"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Set1")
```



O que os dados nos mostram: Para os maratonistas mais rápidos (Sub-4h), a ordem de treinamento provocou diferença significativa ($p = 0,01458$). Os atletas do Grupo 1 completaram a prova com tempo médio de 197,2 minutos, aproximadamente 3 horas e 17 minutos, enquanto os do Grupo 2 registraram 218,6 minutos, cerca de 3 horas e 38 minutos. Isso representa uma vantagem de 21,4 minutos a favor da sequência A seguida de B. Para os atletas acima de 4 horas, a ordem não gerou variação significativa ($p = 0,4091$).

7.2 Perguntas 6 e 7: Como evolui o ritmo no 21km Time Trial e qual o impacto da ordem?

```
tt_resumo <- df_quant %>%
  group_by(Grupo) %>%
  summarise(
    `TT Semana 0 (Km/h)` = round(mean(TT_S0, na.rm=T), 2),
    `TT Semana 8 (Km/h)` = round(mean(TT_S8, na.rm=T), 2),
    `TT Semana 16 (Km/h)` = round(mean(TT_S16, na.rm=T), 2),
    `Ganho Acumulado (Km/h)` = round(mean(TT_S16 - TT_S0, na.rm=T), 2)
  )

tt_resumo %>%
  kable(caption = "Evolução da Velocidade Média no 21km Time Trial (Km/h)") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 7.2: Evolução da Velocidade Média no 21km Time Trial (Km/h)

Grupo	TT Semana 0 (Km/h)	TT Semana 8 (Km/h)	TT Semana 16 (Km/h)	Ganho Acumulado (Km/h)
G1	11.84	12.47	12.83	0.99
G2	11.26	11.94	12.13	0.87

7.2.1 Gráfico de Evolução de Todos os Atletas + Média Geral (Verde)


```
# Estruturação para gráfico de espagete com linha média em verde
df_tt_long <- df_quant %>%
  select(Codigo, Grupo, TT_S0, TT_S8, TT_S16) %>%
  pivot_longer(cols = starts_with("TT_"), names_to = "Semana", values_to = "Velocidade") %>%
  mutate(Semana_Num = case_when(
    Semana == "TT_S0" ~ 0,
```

```

    Semana == "TT_S8" ~ 8,
    Semana == "TT_S16" ~ 16
  ))

ggplot(df_tt_long, aes(x = Semana_Num, y = Velocidade)) +
  # Linhas individuais de cada um dos 30 atletas
  geom_line(aes(group =Codigo), color = "grey75", alpha = 0.6, linewidth = 0.6) +
  geom_point(color = "grey60", alpha = 0.5, size = 1.5) +
  # Linha da evolução média geral destacada em verde
  stat_summary(aes(group = 1), fun = mean, geom = "line", color = "#2ea043", linewidth = 1.8) +
  stat_summary(aes(group = 1), fun = mean, geom = "point", color = "#2ea043", size = 4) +
  scale_x_continuous(breaks = c(0, 8, 16), labels = c("Semana 0", "Semana 8", "Semana 16")) +
  labs(
    title = "Trajetória Individual dos 30 Atletas e Evolução Média Geral",
    subtitle = "Linhas cinzas representam os atletas individuais; linha verde representa a média",
    x = "Momento da Avaliação",
    y = "Velocidade Média no 21km TT (Km/h)"
  ) +
  theme_minimal()

```



O que os dados nos mostram: Ao observar a trajetória individual de cada um dos 30 atletas junto da média geral em verde, fica claro a tendência de ganho progressivo na velocidade média da meia maratona ao longo das 16 semanas. O Grupo 1 apresentou ganho acumulado de +0,99 Km/h e o Grupo 2 registrou +0,87 Km/h. O teste T na Semana 16 indicou p-valor igual a 0,2806, demonstrando que a velocidade final atingida no 21km TT foi equivalente entre as duas metodologias.

7.3 Pergunta 8: Como se comportam os limiares fisiológicos L_1 e L_2 ?

```
limiares_resumo <- df_quant %>%
  group_by(Grupo) %>%
  summarise(
    `L1 Início (Km/h)` = round(mean(L1_S0, na.rm=T), 2),
    `L1 Fim (Km/h)` = round(mean(L1_S16, na.rm=T), 2),
    `L2 Início (Km/h)` = round(mean(L2_S0, na.rm=T), 2),
```

```

  `L2 Fim (Km/h)` = round(mean(L2_S16, na.rm=T), 2)
)

limiares_resumo %>%
  kable(caption = "Deslocamento dos Limiares Aeróbio (L1) e Anaeróbio (L2)" ) %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))

```

Table 7.3: Deslocamento dos Limiares Aeróbio (L1) e Anaeróbio (L2)

Grupo	L1 Início (Km/h)	L1 Fim (Km/h)	L2 Início (Km/h)	L2 Fim (Km/h)
G1	11.47	12.35	12.60	13.38
G2	10.99	11.56	11.98	12.55

O que os dados nos mostram: Observa-se ganho de capacidade aeróbia. O limiar L_1 , correspondente à velocidade de rodagem confortável, subiu de 11,50 para 12,40 Km/h no Grupo 1 e de 11,00 para 11,60 Km/h no Grupo 2. O limiar L_2 , associado ao limiar anaeróbio, expandiu de forma semelhante em ambos os grupos, confirmando melhora nas zonas metabólicas.

7.4 Perguntas 9 e 10: Avaliação de Durabilidade e Perda de Velocidade Pós-Teste (TT vs Z1)

Entendendo o Teste de Durabilidade: Compara-se a velocidade de um tiro de 1km realizado em estado descansado com outro tiro de 1km feito imediatamente após completar o teste de 21km. Quanto maior a porcentagem de queda, maior a perda de durabilidade neuromuscular.

```

df_quant$Queda_TT_Med <- rowMeans(df_quant[, c("Queda_1km_S8", "Queda_1km_S16")], na.rm = TRUE)
df_quant$Queda_Z1_Med <- rowMeans(df_quant[, c("Queda_1km_S4", "Queda_1km_S12")], na.rm = TRUE)

res_queda <- wilcox.test(df_quant$Queda_TT_Med, df_quant$Queda_Z1_Med, paired = TRUE)

tibble(
  Condicao = c("21km Time Trial (Ritmo Máximo - S8/S16)", "21km Zona 1 (Ritmo Contínuo - S4/S12)"),
  Queda_Media = c(
    paste0(round(mean(df_quant$Queda_TT_Med, na.rm=TRUE), 2), "%"),
    paste0(round(mean(df_quant$Queda_Z1_Med, na.rm=TRUE), 2), "%")
  ),
  P_Valor = c(round(res_queda$p.value, 4), round(res_queda$p.value, 4)),
  Resultado = c("Significativo (p < 0,001)", "Significativo (p < 0,001)")
)

```

```

) %>%
  rename(
    `Condição de Esforço` = Condicao,
    `Queda Média no 1km` = Queda_Media,
    `p-valor` = P_Valor,
    `Conclusão` = Resultado
  ) %>%
  kable(caption = "Comparação do Impacto Neuromuscular do 21km TT contra 21km Z1") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))

```

Table 7.4: Comparação do Impacto Neuromuscular do 21km TT contra 21km Z1

Condição de Esforço	Queda Média no 1km	p-valor	Conclusão
21km Time Trial (Ritmo Máximo - S8/S16)	13.17%	1e-04	Significativo (p < 0,001)
21km Zona 1 (Ritmo Contínuo - S4/S12)	7.37%	1e-04	Significativo (p < 0,001)

7.4.1 Gráfico de Queda de Velocidade (Limite do Eixo Y em 30%)


```

df_quant %>%
  select(Codigo, Queda_TT_Med, Queda_Z1_Med) %>%
  pivot_longer(cols = c(Queda_TT_Med, Queda_Z1_Med), names_to = "Condicao", values_to = "Queda") %>%
  mutate(Condicao = if_else(Condicao == "Queda_TT_Med", "21km Time Trial (TT)", "21km Zona 1")) %>%
  ggplot(aes(x = Condicao, y = Queda, fill = Condicao)) +
  geom_boxplot(alpha = 0.7, outlier.shape = NA) +
  geom_point(position = position_jitter(width = 0.1), size = 2, alpha = 0.6) +
  coord_cartesian(ylim = c(0, 30)) +
  scale_y_continuous(breaks = seq(0, 30, by = 5)) +
  labs(
    title = "Perda de Velocidade Pós-Esforço: 21km TT vs 21km Z1",
    subtitle = "O esforço máximo do Time Trial causa quase o dobro de perda no tiro de 1km",
    x = "Condição do Treino de 21km",
    y = "Queda de Velocidade no Tiro (%)",
    fill = "Condição"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Dark2")

```

Perda de Velocidade Pós-Esforço: 21km TT vs 21km Z1

O esforço máximo do Time Trial causa quase o dobro de perda no tiro de 1km



O que os dados nos mostram: Não houve diferença na durabilidade na Semana 16 entre os dois grupos ($p = 0,9834$). Por outro lado, o formato do treino provocou efeito direto: o 21km TT gerou queda de velocidade de 13,17% no tiro de 1km pós-teste, em comparação a 7,37% no 21km em Zona 1 ($p = 0,0001$). Essa variação comprova o grau de fadiga neuromuscular acumulado pelas avaliações em ritmo máximo.

8 Modelo Linear Misto das Velocidades nos 21km

O que faz o Modelo Linear Misto (lmer)? Avalia a evolução contínua ao longo do tempo considerando que cada atleta possui seu próprio ponto de partida.

8.1 Cálculo do Modelo Misto

8.1.1 TT (S0, S8 e S16)

```
dados_longos_TT <- df_quant %>%
  select(Codigo, Grupo, TT_S0, TT_S8, TT_S16) %>%
  pivot_longer(
    cols = c(TT_S0, TT_S8, TT_S16),
    names_to = "semana",
    values_to = "velocidade_21k"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("TT_S0", "TT_S8", "TT_S16")),
    Grupo = factor(Grupo)
  )

modelo_misto_TT <- lmer(velocidade_21k ~ Grupo * semana + (1 | Codigo), data = dados_longos_TT)
anova_res_TT <- anova(modelo_misto_TT)

anova_res_TT %>%
  as.data.frame() %>%
  rownames_to_column("Efeito") %>%
  kable(caption = "Tabela ANOVA do Modelo Linear Misto de velocidade") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```



Table 8.1: Tabela ANOVA do Modelo Linear Misto de velocidade

Efeito	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
Grupo	0.1762761	0.1762761	1	28	0.9800001	0.3306770
semana	13.6321036	6.8160518	2	56	37.8935671	0.0000000
Grupo:semana	0.1178058	0.0589029	2	56	0.3274684	0.7221169

8.1.1.1 Gráfico do Modelo Misto

```
dados_longos_TT %>%
  group_by(Grupo, semana) %>%
  summarise(
    media = mean(velocidade_21k, na.rm = TRUE),
    se = sd(velocidade_21k, na.rm = TRUE) / sqrt(n()),
    .groups = 'drop'
  ) %>%
  ggplot(aes(x = semana, y = media, color = Grupo, group = Grupo)) +
  geom_line(linewidth = 1.2) +
  geom_point(size = 3) +
  geom_errorbar(aes(ymin = media - se, ymax = media + se), width = 0.15) +
  labs(
    title = "Evolução da Velocidade Média nos 21km TT por sequência de treino",
    subtitle = "Efeito significativo principal para o fator Semana (p < 0,0001)",
    x = "Avaliação / semana",
    y = "Velocidade média (Km/h)",
    color = "Sequência"
  ) +
  theme_minimal() +
  scale_color_brewer(palette = "Set1")
```

Evolução da Velocidade Média nos 21km TT por sequência de treino
 Efeito significativo principal para o fator Semana ($p < 0,0001$)



8.1.2 Z1 (S4 e S12)

```
dados_longos_Z1 <- df_quant %>%
  select(Codigo, Grupo, Z1_S4, Z1_S12) %>%
  pivot_longer(
    cols = c(Z1_S4, Z1_S12),
    names_to = "semana",
    values_to = "velocidade_21k"
  ) %>%
  mutate(
    semana = factor(semana, levels = c( "Z1_S4", "Z1_S12")),
    Grupo = factor(Grupo)
  )

modelo_misto_Z1 <- lmer(velocidade_21k ~ Grupo * semana + (1 | Codigo), data = dados_longos_Z1)
anova_res_Z1 <- anova(modelo_misto_Z1)


anova_res_Z1 %>%
```

```
as.data.frame() %>%
rownames_to_column("Efeito") %>%
kable(caption = "Tabela ANOVA do Modelo Linear Misto de Velocidade") %>%
kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 8.2: Tabela ANOVA do Modelo Linear Misto de Velocidade

Efeito	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
Grupo	0.3996639	0.3996639	1	28	1.012391	0.3229473
semana	0.9213719	0.9213719	1	28	2.333933	0.1378006
Grupo:semana	0.5061719	0.5061719	1	28	1.282187	0.2670969

```
dados_longos_Z1 %>%
group_by(Grupo, semana) %>%
summarise(
  media = mean(velocidade_21k, na.rm = TRUE),
  se = sd(velocidade_21k, na.rm = TRUE) / sqrt(n()),
  .groups = 'drop'
) %>%
ggplot(aes(x = semana, y = media, color = Grupo, group = Grupo)) +
geom_line(linewidth = 1.2) +
geom_point(size = 3) +
geom_errorbar(aes(ymin = media - se, ymax = media + se), width = 0.15) +
labs(
  title = "Evolução da Velocidade Média nos 21km Z1 por sequência de treino",
  subtitle = "Efeito significativo principal para o fator Semana (p < 0,0001)",
  x = "Avaliação / semana",
  y = "Velocidade média (Km/h)",
  color = "Sequência"
) +
theme_minimal() +
scale_color_brewer(palette = "Set1")
```



O que os dados nos mostram: A análise do modelo misto confirma que a Semana de Treinamento é a variável principal da evolução dos atletas no Time Trail ($F = 37.89$, com p-valor menor que 0,0001). Isso significa que a progressão planejada do macrociclo gerou ganhos contínuos no ritmo de corrida para a amostra geral dos 30 atletas.

9 Achados e Recomendações

1. **A Ordem importa para maratonistas rápidos:** Para corredores com tempo Sub-4 horas, iniciar com o Treino A no primeiro bloco proporcionou tempo de maratona mais rápido, representando uma economia de 21,4 minutos ($p = 0,01458$).
2. **Custo psicofisiológico diferenciado:** O Grupo 2 reportou maior nível de estresse ($p = 0,0242$) e pior qualidade de sono ($p = 0,0257$), recomendando atenção ao controle de carga nessa ordem de aplicação.
3. **Gerenciamento do cansaço pós-TT:** Testes em ritmo de Time Trial geram quase o dobro de queda na velocidade neuromuscular (13,17% contra 7,37%) quando comparados a corridas contínuas em Zona 1, exigindo maior tempo de recuperação programado após os testes de 21km TT.