

Relatório de análises - Movimenta UFPR

Ana Beatriz da Silva Marques

Alexandre Kobus

2026-08-12

Table of contents

Introdução	5
1 Análise exploratória de dados	6
2 Estrutura dos dados da primeira tabela	7
2.0.1 Quantidade de atletas	7
2.0.2 Número de variáveis	7
2.0.3 Primeiras 6 linhas dos dados	7
2.0.4 Variáveis e seus tipos	7
2.0.5 Número de variáveis	14
2.0.6 Número de valores faltantes	14
2.0.7 Distribuição das variáveis quantitativas mais importantes	19
3 Desempenho ao longo das semanas	37
3.1 TT (S0, S8 e S16)	37
3.2 Z1 (S4 e S12)	41
4 Validação dos dados	45
4.0.1 Quantidade de atletas com o treino válido	45
4.0.2 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S0	45
4.0.3 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S4	45
4.0.4 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S8	46
4.0.5 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S12	47
4.0.6 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S16	47
5 Estrutura dos dados da segunda tabela (quali)	49
5.0.1 Distribuição das variáveis qualitativas mais importantes	49
5.0.2 Quantidade de atletas	51
5.0.3 Número de variáveis	51
5.0.4 Primeiras 6 linhas dos dados	51
5.0.5 Variáveis e seus tipos	52

5.0.6	Número de valores faltantes	54
6	Teste de Shapiro-Wilk: testando a normalidade dos dados	60
7	Tabela de comparação das médias dos dois grupos	62
8	Perguntas	63
9	Teste de normalidade	66
10	Bloco 1: Análises Perceptivas e Qualitativas ($N = 28$)	67
10.1	Pergunta 1: Como se comporta a percepção de desgaste entre os grupos? . . .	67
10.1.1	Gráfico da série temporal qualitativa	68
10.2	Pergunta 2: O mesmo atleta sente mais desgaste no 1º ou no 2º bloco de treinos? . . .	69
10.3	Pergunta 3: Quais fatores perceptivos se associam ao tempo da maratona? . . .	70
11	Bloco 2: Análises de Desempenho Físico e Maratona ($N = 30$)	72
11.1	Perguntas 4 e 5: A ordem dos treinos altera o resultado da Maratona por nível de rendimento?	72
11.1.1	Gráfico de desempenho na maratona	73
11.2	Perguntas 6 e 7: Como evolui o ritmo no 21km Time Trial e qual o impacto da ordem?	74
11.2.1	Gráfico de Evolução de Todos os Atletas + Média Geral (Verde)	74
11.3	Pergunta 8: Como se comportam os limiares fisiológicos L_1 e L_2 ?	76
11.4	Perguntas 9 e 10: Avaliação de Durabilidade e Perda de Velocidade Pós-Teste (TT vs Z1)	77
11.4.1	Gráfico de Queda de Velocidade (Limite do Eixo Y em 30%)	78
12	Modelo Linear Misto das Velocidades nos 21km	80
12.1	Cálculo do Modelo Misto	80
12.1.1	TT (S0, S8 e S16)	80
12.1.2	Z1 (S4 e S12)	82
13	Achados e Recomendações	85
14	Decoupling Fisiológico e Ritmo de Corrida	86
15	Introdução e Contextualização Fisiológica	87
16	Carregamento e Preparação dos Dados	88
17	Mapeamento dos Limiares Fisiológicos (L2 e VC)	90
17.0.1	Propriedade Matemática da Magnitude do Decoupling	91
18	Extração e Estruturação das Métricas	93

19	Resumo dos 5 Valores de Tukey	94
19.0.1	Principais Insights da Distribuição:	95
20	Comparação entre os Grupos Pedagógicos (G1 vs G2)	96
20.0.1	Discussão dos Resultados:	97
21	Comportamento por Desempenho na Maratona (Sub-4h vs. Acima de 4h)	99
21.0.1	Discussão:	100
22	Dinâmica de Ritmo (Velocidade Km a Km) na Maratona	102
23	Conclusões e Síntese Prática	105

Introdução

O projeto Movimenta UFPR acompanhou atletas ao longo de um programa estruturado de preparação dividido em dois blocos principais de treinamento. O primeiro bloco compreende da Semana 1 a 8 e o segundo bloco abrange da Semana 9 a 16.

Os atletas foram divididos em duas sequências pedagógicas de treino:

- **Grupo 1 (G1):** Iniciou pela intervenção do Treino A no primeiro bloco e realizou o Treino B no segundo bloco.
- **Grupo 2 (G2):** Realizou a sequência inversa, aplicando o Treino B no primeiro bloco e o Treino A no segundo bloco.

Neste relatório, integramos os dados de desempenho quantitativo ($N = 30$ atletas) com os dados de percepção qualitativa semanal ($N = 28$ atletas com acompanhamento de questionários completo) para responder a **10 perguntas científicas norteadoras**.

1 Análise exploratória de dados

```
library(tidyverse)
library(janitor)
library(lme4)
library(lmerTest)
library(rstatix)
library(ggplot2)
library(readxl)
library(hms)
library(gt)
library(plotly)
library(scales)

dados <- read_xlsx("Dados_06.07.xlsx") %>% clean_names() %>%
  type.convert(as.is = TRUE) %>% drop_na(codigo) |> select(-c(
    maratona_pace_km1,
    maratona_fc_km1,
    maratona_percent_vc_fc,
    starts_with("fazer_as"))) |> mutate(maratona_tempo = as.double(maratona_tempo),
    maratona_tempo = as_hms(maratona_tempo * 86400),
    maratona_tempo = format(as.POSIXct(maratona_tempo),
      "%H:%M:%S"),
    maratona_tempo = as_hms(maratona_tempo),
    maratona_menos_4h = ifelse(as_hms(maratona_tempo) < 4, "Sim", "Não"))

dicionario <- read_excel("Dados_06.07.xlsx", sheet = 2)
```

2 Estrutura dos dados da primeira tabela

2.0.1 Quantidade de atletas

```
nrow(dados)
```

```
[1] 30
```

2.0.2 Número de variáveis

```
ncol(dados)
```

```
[1] 237
```

2.0.3 Primeiras 6 linhas dos dados

```
dados |> head() |> gt() |>  
  cols_align(  
    align = "center",  
    columns = everything()  
  )
```

2.0.4 Variáveis e seus tipos

```
glimpse(dados)
```

grupo	codigo	nome	maratona_tempo	maratona_km_h_real	tt_3_tempo
G1	G1_01	Alcione	15421	9.85	8.4560185185185183E-2
G1	G1_02	Alessandro	13444	11.30	6.8275462962962968E-2
G1	G1_03	Amanda	14910	10.19	8.1493055555555555E-2
G1	G1_04	Ana Munaro	10828	14.03	5.8611111111111114E-2
G1	G1_05	Andreia Rosa	16519	9.19	7.7187500000000006E-2
G1	G1_06	Carlos	13308	11.41	7.3888888888888893E-2

Rows: 30

Columns: 237

```

$ grupo          <chr> "G1", "G1", "G1", "G1", "G1", "G1", "G1", "G1"~
$ codigo         <chr> "G1_01", "G1_02", "G1_03", "G1_04", "G1_05", "~
$ nome          <chr> "Alcione", "Alessandro", "Amanda", "Ana Munaro~
$ maratona_tempo <time> 04:17:01, 03:44:04, 04:08:30, 03:00:28, 04:35~
$ maratona_km_h_real <dbl> 9.85, 11.30, 10.19, 14.03, 9.19, 11.41, 12.95,~
$ tt_3_tempo     <chr> "8.4560185185185183E-2", "6.8275462962962968E-
~
$ tt_3_km_h_real <dbl> 10.40, 12.88, 10.79, 15.00, 11.39, 11.90, 14.1~
$ tt_2_tempo     <chr> "1899-12-31 02:08:00", "1899-12-31 01:47:25", ~
$ tt_2_km_h_real <dbl> 9.89, 11.79, 10.29, 14.72, 11.08, 10.93, 13.87~
$ tt_1_tempo     <chr> "1899-12-31 02:11:10", "1899-12-31 01:49:06", ~
$ tt_1_km_h_real <dbl> 9.65, 11.60, 10.61, 14.10, 10.55, 9.06, 12.17,~
$ z1_2_tempo     <chr> "1899-12-31 02:10:21", "1899-12-31 01:47:25", ~
$ z1_2_km_h_real <dbl> 9.71, 11.79, 10.29, 12.57, 10.36, 9.71, 12.18,~
$ z1_1_tempo     <chr> "1899-12-31 02:14:00", "1899-12-31 01:54:32", ~
$ z1_1_km_h_real <dbl> 9.45, 11.05, 9.36, 12.20, 10.54, 9.42, 11.27, ~
$ t1000_s12_tempo_real <int> 265, 258, 281, 191, 271, 248, 199, 237, 204, 1~
$ t1000_s12_km_h <dbl> 13.33, 13.95, 12.81, 18.85, 13.28, 14.52, 18.0~
$ t1000_s12_pace <chr> "1899-12-31 04:25:00", "1899-12-31 04:18:00", ~
$ t2000_s12_tempo_real <int> 595, 528, 617, 419, 555, 570, 432, 531, 457, 4~
$ t2000_s12_km_h <dbl> 12.10, 13.64, 11.67, 17.18, 12.97, 12.63, 16.6~
$ t2000_s12_pace <chr> "1899-12-31 04:58:00", "1899-12-31 04:24:00", ~
$ t3000_s12_tempo_real <int> 927, 810, 848, 657, 855, 849, 655, 805, 704, 6~
$ t3000_s12_km_h <dbl> 11.65, 13.33, 12.74, 16.44, 12.63, 12.72, 16.4~
$ t3000_s12_pace <chr> "1899-12-31 05:09:00", "1899-12-31 04:30:00", ~
$ vc_s12_real    <dbl> 11.44, 13.40, 12.60, 15.40, 12.30, 12.40, 16.4~
$ d_s12_real     <dbl> 114.00, 72.80, 33.80, 182.10, 75.40, 171.80, 8~
$ r_s12          <dbl> 0.99980, 0.99984, 0.99786, 0.99996, 0.99992, 0~
$ rmse_s12       <dbl> 4.0, 2.8, 11.7, 1.3, 2.0, 4.6, 2.1, 2.1, 1.8, ~
$ t1000_s4_tempo_real <chr> "280", "253", "278", "208", "261", "271", "205~
$ t1000_s4_km_h  <dbl> 12.86, 14.23, 12.95, 17.31, 13.79, 13.28, 17.5~

```



```

$ t1000_s4_pace <chr> "1899-12-31 04:40:00", "1899-12-31 04:13:00", ~
$ t2000_s4_tempo_real <int> 617, 526, 593, 436, 574, 555, 444, 545, 465, 4~
$ t2000_s4_km_h <dbl> 11.67, 13.69, 12.14, 16.51, 12.54, 12.97, 16.2~
$ t2000_s4_pace <chr> "1899-12-31 05:09:00", "1899-12-31 04:23:00", ~
$ t3000_s4_tempo_real <int> 912, 810, 924, 676, 860, 845, 693, 822, 719, 6~
$ t3000_s4_km_h <dbl> 11.84, 13.33, 11.69, 15.98, 12.56, 12.78, 15.5~
$ t3000_s4_pace <chr> "1899-12-31 05:04:00", "1899-12-31 04:30:00", ~
$ vc_s4_real <dbl> 11.40, 12.90, 11.10, 15.40, 12.00, 12.54, 14.8~
$ d_s4_real <dbl> 94.6, 98.4, 140.0, 112.8, 124.8, 59.3, 158.4, ~
$ r_s4 <dbl> 0.99856, 0.99987, 0.99948, 0.99993, 0.99911, 0~
$ rmse_s4 <dbl> 9.9, 2.6, 6.3, 2.2, 7.1, 4.9, 2.9, 2.7, 2.5, 1~
$ x1km_fresco_tempo_s0 <int> 300, 251, 296, 199, 274, 301, 236, 255, 221, 2~
$ x1km_fresco_oficial_s0 <chr> "1899-12-31 05:00:00", "1899-12-31 04:11:00", ~
$ x1km_fresco_vm_s0 <dbl> 12.00, 14.35, 12.10, 18.07, 13.10, 11.98, 15.2~
$ d_21km_s0_real_tempo <chr> "1899-12-31 02:11:10", "1899-12-31 01:49:06", ~
$ d_21km_s0_real <dbl> 9.65, 11.60, 10.61, 14.10, 10.55, 9.06, 12.17,~
$ x1km_pos_tempo_s0 <int> 330, 316, 292, 236, 331, 316, 297, 287, 277, 2~
$ x1km_pos_original_s0 <chr> "1899-12-31 05:30:00", "1899-12-31 05:16:00", ~
$ x1km_pos_vm_s0 <dbl> 10.91, 11.39, 12.30, 15.25, 10.88, 11.39, 12.7~
$ queda_s0 <dbl> -9.1, -20.6, -1.7, -15.6, -17.0, -4.9, -
16.3, ~
$ x1km_fresco_tempo_s4 <int> 280, 253, 278, 208, 261, 271, 205, 255, 213, 1~
$ x1km_fresco_oficial_s4 <chr> "1899-12-31 04:40:00", "1899-12-31 04:13:00", ~
$ x1km_fresco_vm_s4 <dbl> 12.86, 14.23, 12.90, 17.31, 13.79, 13.28, 17.6~
$ d_21km_s4_real_tempo <chr> "1899-12-31 02:14:00", "1899-12-31 01:54:32", ~
$ d_21km_s4_real <dbl> 9.45, 11.05, 9.36, 12.20, 10.54, 9.42, 11.27, ~
$ x1km_pos_tempo_s4 <int> 297, 289, 296, 203, 289, 333, 209, 270, 234, 2~
$ x1km_pos_original_s4 <chr> "1899-12-31 04:57:00", "1899-12-31 04:49:00", ~
$ x1km_pos_vm_s4 <dbl> 12.12, 12.53, 12.10, 17.58, 12.53, 10.87, 17.2~
$ queda_s4 <dbl> -5.8, -11.9, -6.2, 2.0, -8.9, -17.9, -2.2, -
5.~
$ x1km_fresco_tempo_s8 <int> 271, 241, 278, 190, 263, 272, 196, 232, 203, 1~
$ x1km_fresco_oficial_s8 <chr> "1899-12-31 04:31:00", "1899-12-31 04:01:00", ~
$ x1km_fresco_vm_s8 <dbl> 13.25, 14.99, 12.90, 18.75, 13.62, 13.16, 18.2~
$ d_21km_s8_real_tempo <chr> "1899-12-31 02:08:00", "1899-12-31 01:47:25", ~
$ d_21km_s8_real <dbl> 9.89, 11.79, 10.29, 14.72, 11.08, 10.93, 13.87~
$ x1km_pos_tempo_s8 <int> 315, 313, 293, 216, 286, 293, 227, 264, 249, 2~
$ x1km_pos_original_s8 <chr> "1899-12-31 05:15:00", "1899-12-31 05:13:00", ~
$ x1km_pos_vm_s8 <dbl> 11.43, 11.51, 12.17, 16.67, 12.00, 12.22, 15.8~
$ queda_s8 <dbl> -13.7, -23.2, -5.7, -11.1, -11.9, -7.1, -
13.6,~
$ x1km_fresco_tempo_s12 <int> 265, 258, 281, 191, 271, 248, 199, 237, 204, 1~
$ x1km_fresco_oficial_s12 <chr> "1899-12-31 04:25:00", "1899-12-31 04:18:00", ~

```

```

$ x1km_fresco_vm_s12      <dbl> 13.33, 13.95, 12.84, 18.75, 13.30, 14.52, 17.4~
$ d_21km_s12_real_tempo  <chr> "1899-12-31 02:10:21", "1899-12-31 01:47:25", ~
$ d_21km_s12_real        <dbl> 9.71, 11.79, 10.29, 12.57, 10.36, 9.71, 12.18,~
$ x1km_pos_tempo_s12     <int> 303, 274, 296, 224, 297, 258, 226, 253, 227, 2~
$ x1km_pos_original_s12  <chr> "1899-12-31 05:03:00", "1899-12-31 04:34:00", ~
$ x1km_pos_vm_s12        <dbl> 11.95, 13.13, 12.10, 15.96, 12.12, 14.08, 15.5~
$ queda_s12              <dbl> -10.4, -5.9, -5.8, -14.9, -8.9, -3.0, -
11.2, --
$ x1km_fresco_tempo_s16  <int> 278, 249, 280, 201, 263, 247, 216, 258, 198, 1~
$ x1km_fresco_oficial_s16 <chr> "1899-12-31 04:38:00", "1899-12-31 04:09:00", ~
$ x1km_fresco_vm_s16     <dbl> 12.90, 14.46, 12.86, 17.91, 13.62, 14.62, 16.6~
$ d_21km_s16_real_tempo  <chr> "8.4560185185185183E-2", "6.8275462962962968E-
~
$ d_21km_s16_real_vm     <dbl> 10.40, 12.88, 10.79, 15.00, 11.39, 11.90, 14.1~
$ x1km_pos_tempo_s16     <int> 305, 279, 272, 218, 289, 255, 230, 275, 239, 2~
$ x1km_pos_original_s16  <chr> "1899-12-31 05:05:00", "1899-12-31 04:39:00", ~
$ x1km_pos_vm_s16        <dbl> 11.88, 13.64, 13.16, 17.31, 12.53, 14.12, 15.7~
$ queda_s16              <dbl> -7.9, -5.7, 2.3, -3.3, -8.0, -3.4, -5.3, -
5.7,~
$ pres_s1                <int> 44, 44, 44, 53, 44, 44, 53, 44, 44, 53, 53, 44~
$ reali_s1               <int> 0, 49, 39, 57, 36, 21, 56, 57, 54, 49, 62, 56,~
$ dif_s1                 <int> -44, 5, -5, 4, -8, -23, 3, 13, 10, -4, 9, 12, ~
$ z1_s1                  <int> 0, 42, 39, 50, 29, 21, 45, 50, 48, 42, 55, 49,~
$ z2_s1                  <int> 0, 6, 0, 6, 6, 0, 5, 6, 5, 6, 6, 6, 6, 0, 6~
$ z3_s1                  <int> 0, 1, 0, 1, 1, 0, 6, 1, 1, 1, 1, 1, 1, 5, 1~
$ percent_z1_s1          <int> NA, 86, 100, 88, 81, 100, 80, 88, 89, 86, 89, ~
$ percent_z2_s1          <int> NA, 12, 0, 11, 17, 0, 9, 11, 9, 12, 10, 11, 13~
$ percent_z3_s1          <int> NA, 2, 0, 2, 3, 0, 11, 2, 2, 2, 2, 2, 2, 10~
$ pres_s2                <int> 47, 47, 47, 56, 47, 47, 56, 47, 47, 56, 56, 47~
$ reali_s2               <int> 32, 57, 44, 65, 41, 65, 65, 33, 59, 65, 65, 57~
$ dif_s2                 <int> -15, 10, -3, 9, -6, 18, 9, -14, 12, 9, 9, 10, ~
$ z1_s2                  <int> 32, 40, 38, 48, 24, 48, 49, 16, 49, 48, 48, 40~
$ z2_s2                  <int> 0, 12, 6, 12, 12, 12, 11, 8, 8, 12, 12, 12, 12~
$ z3_s2                  <int> 0, 5, 0, 5, 5, 5, 5, 9, 2, 5, 5, 5, 5, 5, 11, ~
$ percent_z1_s2          <int> 100, 70, 86, 74, 59, 74, 76, 49, 82, 74, 74, 7~
$ percent_z2_s2          <int> 0, 21, 14, 19, 29, 19, 17, 24, 13, 19, 19, 21,~
$ percent_z3_s2          <int> 0, 8, 0, 7, 12, 7, 7, 27, 4, 7, 7, 8, 15, 7, 1~
$ pres_s3                <int> 50, 50, 50, 59, 50, 50, 59, 50, 50, 59, 59, 50~
$ reali_s3               <int> 68, 44, 29, 68, 68, 68, 56, 56, 65, 48, 68, 47~
$ dif_s3                 <int> 18, -6, -21, 9, 18, 18, -3, 6, 15, -11, 9, -
3,~
$ z1_s3                  <int> 51, 39, 16, 51, 51, 51, 37, 47, 51, 35, 51, 43~
$ z2_s3                  <int> 12, 0, 8, 12, 12, 12, 14, 4, 12, 8, 12, 4, 4, ~

```

\$ z3_s3	<int> 5, 5, 5, 5, 5, 5, 5, 5, 2, 5, 5, 0, 5, 5, 5, 0~
\$ percent_z1_s3	<int> 75, 89, 56, 75, 75, 75, 66, 84, 78, 73, 75, 91~
\$ percent_z2_s3	<int> 18, 0, 28, 18, 18, 18, 25, 7, 18, 17, 18, 9, 7~
\$ percent_z3_s3	<int> 7, 11, 17, 7, 7, 7, 9, 9, 3, 10, 7, 0, 9, 6, 8~
\$ pres_s4	<int> 37, 37, 37, 45, 37, 37, 45, 37, 37, 45, 45, 37~
\$ reali_s4	<int> 36, 37, 34, 37, 37, 36, 56, 37, 41, 37, 37, 37~
\$ dif_s4	<int> -1, 0, -3, -8, 0, -1, 11, 0, 4, -8, -8, 0, -
22~	
\$ z1_s4	<int> 29, 30, 27, 30, 30, 29, 49, 30, 34, 30, 30, 30~
\$ z2_s4	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
\$ z3_s4	<int> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 6, 7, 7, 7~
\$ percent_z1_s4	<int> 81, 81, 79, 81, 81, 81, 88, 81, 83, 81, 81, 81~
\$ percent_z2_s4	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0~
\$ percent_z3_s4	<int> 19, 19, 21, 19, 19, 19, 13, 19, 17, 19, 19, 19~
\$ pres_s5	<int> 51, 51, 51, 66, 51, 51, 66, 51, 51, 66, 66, 51~
\$ reali_s5	<int> 51, 51, 51, 66, 51, 51, 51, 51, 50, 66, 66, 51~
\$ dif_s5	<int> 0, 0, 0, 0, 0, 0, -15, 0, -1, 0, 0, 0, 0, 0, 0~
\$ z1_s5	<int> 39, 39, 39, 48, 39, 39, 18, 39, 38, 54, 54, 39~
\$ z2_s5	<int> 8, 8, 8, 13, 8, 8, 29, 8, 8, 8, 8, 8, 8, 13, 1~
\$ z3_s5	<int> 4, 4, 4, 5, 4, 4, 4, 4, 4, 4, 4, 4, 4, 5, 5, 4~
\$ percent_z1_s5	<int> 76, 0, 76, 73, 76, 76, 35, 76, 76, 82, 82, 76,~
\$ percent_z2_s5	<int> 16, 16, 16, 20, 16, 16, 57, 16, 16, 12, 12, 16~
\$ percent_z3_s5	<int> 8, 8, 8, 8, 8, 8, 8, 8, 8, 6, 6, 8, 8, 8, 8, 8~
\$ pres_s6	<int> 53, 53, 53, 68, 53, 53, 68, 53, 53, 68, 68, 53~
\$ reali_s6	<int> 53, 27, 52, 66, 53, 53, 53, 53, 35, 68, 68, 51~
\$ dif_s6	<int> 0, -26, -1, -2, 0, 0, -15, 0, -18, 0, 0, -
2, --	
\$ z1_s6	<int> 41, 15, 40, 51, 41, 41, 41, 41, 23, 53, 53, 39~
\$ z2_s6	<int> 8, 8, 8, 10, 8, 8, 8, 8, 8, 10, 10, 8, 8, 10, ~
\$ z3_s6	<int> 4, 4, 4, 5, 4, 4, 4, 4, 4, 5, 5, 4, 4, 0, 5, 4~
\$ percent_z1_s6	<int> 77, 56, 77, 77, 77, 77, 77, 77, 66, 78, 78, 76~
\$ percent_z2_s6	<int> 15, 30, 15, 15, 15, 15, 15, 15, 23, 15, 15, 16~
\$ percent_z3_s6	<int> 8, 15, 8, 8, 8, 8, 8, 8, 11, 7, 7, 8, 9, 0, 7,~
\$ pres_s7	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
\$ reali_s7	<int> 55, 12, 63, 70, 55, 22, 68, 55, 56, 55, 70, 45~
\$ dif_s7	<int> 0, -43, 8, 0, 0, -33, -2, 0, 1, -15, 0, -
10, --	
\$ z1_s7	<int> 43, 4, 51, 55, 43, 10, 48, 43, 44, 40, 55, 37,~
\$ z2_s7	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 8, 0, 10,~
\$ z3_s7	<int> 4, 0, 4, 5, 4, 4, 10, 4, 4, 5, 5, 0, 4, 5, 5, ~
\$ percent_z1_s7	<int> 78, 33, 81, 79, 78, 45, 71, 78, 79, 73, 79, 82~
\$ percent_z2_s7	<int> 15, 67, 13, 14, 15, 36, 15, 15, 14, 18, 14, 18~
\$ percent_z3_s7	<int> 7, 0, 6, 7, 7, 18, 15, 7, 7, 9, 7, 0, 24, 7, 7~

\$ pres_s8	<int> 37, 37, 37, 48, 37, 37, 48, 37, 37, 48, 48, 37~
\$ reali_s8	<int> 28, 35, 35, 39, 36, 33, 50, 35, 35, 39, 39, 7,~
\$ dif_s8	<int> -9, -2, -2, -9, -1, -4, 2, -2, -2, -9, -9, -
30~	
\$ z1_s8	<int> 7, 7, 7, 9, 7, 5, 20, 7, 7, 9, 9, 2, 7, 9, 9, ~
\$ z2_s8	<int> 20, 26, 26, 27, 26, 26, 27, 26, 26, 27, 27, 5,~
\$ z3_s8	<int> 1, 2, 2, 3, 3, 2, 3, 2, 2, 3, 3, 0, 2, 3, 2, 0~
\$ percent_z1_s8	<int> 25, 20, 20, 23, 19, 15, 40, 20, 20, 23, 23, 29~
\$ percent_z2_s8	<int> 71, 74, 74, 69, 72, 79, 54, 74, 74, 69, 69, 71~
\$ percent_z3_s8	<int> 4, 6, 6, 8, 8, 6, 6, 6, 6, 8, 8, 0, 6, 8, 5, 0~
\$ pres_s9	<int> 51, 51, 51, 66, 51, 51, 66, 51, 51, 66, 66, 51~
\$ reali_s9	<int> 51, 51, 51, 66, 51, 51, 68, 51, 43, 66, 46, 0,~
\$ dif_s9	<int> 0, 0, 0, 0, 0, 0, 2, 0, -8, 0, -20, -51, -
12, ~	
\$ z1_s9	<int> 39, 39, 39, 51, 39, 39, 48, 39, 31, 51, 41, 0,~
\$ z2_s9	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 5, 5, 0, 4, 5, 5, 0~
\$ z3_s9	<int> 8, 8, 8, 10, 8, 8, 15, 8, 8, 10, 0, 0, 0, 10, ~
\$ percent_z1_s9	<int> 76, 76, 76, 77, 76, 76, 71, 76, 72, 77, 89, NA~
\$ percent_z2_s9	<int> 8, 8, 8, 8, 8, 8, 7, 8, 9, 8, 11, NA, 10, 8, 7~
\$ percent_z3_s9	<int> 16, 16, 16, 15, 16, 16, 22, 16, 19, 15, 0, NA,~
\$ pres_s10	<int> 53, 53, 53, 68, 53, 53, 68, 53, 53, 68, 68, 53~
\$ reali_s10	<int> 53, 53, 53, 68, 53, 53, 70, 53, 54, 64, 73, 0,~
\$ dif_s10	<int> 0, 0, 0, 0, 0, 0, 2, 0, 1, -4, 5, -53, -
12, 0,~	
\$ z1_s10	<int> 41, 41, 41, 53, 41, 41, 55, 41, 42, 54, 58, 0,~
\$ z2_s10	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 0, 5, 0, 4, 5, 5, 4~
\$ z3_s10	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 0, 6, 10,~
\$ percent_z1_s10	<int> 77, 77, 77, 78, 77, 77, 79, 77, 78, 84, 79, NA~
\$ percent_z2_s10	<int> 8, 8, 8, 7, 8, 8, 7, 8, 7, 0, 7, NA, 10, 7, 7,~
\$ percent_z3_s10	<int> 15, 15, 15, 15, 15, 15, 14, 15, 15, 16, 14, NA~
\$ pres_s11	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
\$ reali_s11	<int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 8,~
\$ dif_s11	<int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, -47, 0, -
29, ~	
\$ z1_s11	<int> 43, 43, 43, 55, 43, 43, 55, 43, 43, 55, 55, 8,~
\$ z2_s11	<int> 4, 4, 4, 5, 4, 4, 5, 4, 4, 5, 5, 0, 4, 5, 5, 4~
\$ z3_s11	<int> 8, 8, 8, 10, 8, 8, 10, 8, 8, 10, 10, 0, 8, 6, ~
\$ percent_z1_s11	<int> 78, 78, 78, 79, 78, 78, 79, 78, 78, 79, 79, 10~
\$ percent_z2_s11	<int> 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 7, 0, 7, 12, 7, ~
\$ percent_z3_s11	<int> 15, 15, 15, 14, 15, 15, 14, 15, 15, 14, 14, 0,~
\$ pres_s12	<int> 37, 37, 37, 48, 37, 37, 48, 37, 37, 48, 48, 37~
\$ reali_s12	<int> 37, 37, 37, 48, 37, 37, 40, 37, 37, 48, 48, 37~
\$ dif_s12	<int> 0, 0, 0, 0, 0, 0, -8, 0, 0, 0, 0, 0, -7, -

```

10, ~
$ z1_s12 <int> 30, 30, 30, 36, 30, 30, 32, 30, 30, 36, 36, 30~
$ z2_s12 <int> 2, 2, 2, 4, 2, 2, 4, 2, 2, 4, 4, 2, 2, 0, 4, 2~
$ z3_s12 <int> 5, 5, 5, 8, 5, 5, 4, 5, 5, 8, 8, 5, 4, 5, 8, 5~
$ percent_z1_s12 <int> 81, 81, 81, 75, 81, 81, 80, 81, 81, 75, 75, 81~
$ percent_z2_s12 <int> 5, 5, 5, 8, 5, 5, 10, 5, 5, 8, 8, 5, 7, 0, 8, ~
$ percent_z3_s12 <int> 14, 14, 14, 17, 14, 14, 10, 14, 14, 17, 17, 14~
$ pres_s13 <int> 55, 55, 55, 70, 55, 55, 70, 55, 55, 70, 70, 55~
$ reali_s13 <int> 55, 55, 55, 70, 55, 55, 69, 53, 56, 33, 70, 47~
$ dif_s13 <int> 0, 0, 0, 0, 0, 0, -1, -2, 1, -37, 0, -8, 7, 6, ~
$ z1_s13 <int> 43, 43, 43, 55, 51, 43, 53, 43, 44, 33, 55, 35~
$ z2_s13 <int> 4, 4, 4, 5, 4, 4, 6, 4, 4, 0, 5, 4, 4, 5, 6, 4~
$ z3_s13 <int> 8, 8, 8, 10, 0, 8, 10, 6, 8, 0, 10, 8, 9, 13, ~
$ percent_z1_s13 <int> 78, 78, 78, 79, 93, 78, 77, 81, 79, 100, 79, 7~
$ percent_z2_s13 <int> 7, 7, 7, 7, 7, 7, 9, 8, 7, 0, 7, 9, 6, 7, 8, 7~
$ percent_z3_s13 <int> 15, 15, 15, 14, 0, 15, 14, 11, 14, 0, 14, 17, ~
$ pres_s14 <int> 57, 57, 57, 73, 57, 57, 73, 57, 57, 73, 73, 57~
$ reali_s14 <int> 55, 57, 57, 74, 57, 57, 78, 57, 57, 73, 65, 57~
$ dif_s14 <int> -2, 0, 0, 1, 0, 0, 5, 0, 0, 0, -8, 0, -
18, 0, ~
$ z1_s14 <int> 43, 45, 45, 61, 57, 45, 65, 45, 45, 60, 52, 45~
$ z2_s14 <int> 4, 4, 4, 5, 0, 4, 5, 4, 4, 5, 5, 4, 4, 5, 5, 4~
$ z3_s14 <int> 8, 8, 8, 8, 0, 8, 8, 8, 8, 8, 8, 8, 4, 8, 12, ~
$ percent_z1_s14 <int> 78, 79, 79, 82, 100, 79, 83, 79, 79, 82, 80, 7~
$ percent_z2_s14 <int> 7, 7, 7, 7, 0, 7, 6, 7, 7, 7, 8, 7, 10, 7, 9, ~
$ percent_z3_s14 <int> 15, 14, 14, 11, 0, 14, 10, 14, 14, 11, 12, 14,~
$ pres_s15 <int> 60, 60, 60, 77, 60, 60, 77, 60, 60, 77, 77, 60~
$ reali_s15 <int> 60, 60, 62, 77, 52, 60, 82, 53, 60, 77, 77, 60~
$ dif_s15 <int> 0, 0, 2, 0, -8, 0, 5, -7, 0, 0, 0, 0, 0, 0, -
2~
$ z1_s15 <int> 48, 48, 50, 64, 48, 48, 68, 49, 48, 64, 64, 48~
$ z2_s15 <int> 4, 4, 4, 5, 4, 4, 6, 4, 4, 5, 5, 4, 4, 5, 0, 4~
$ z3_s15 <int> 8, 8, 8, 8, 0, 8, 8, 0, 8, 8, 8, 8, 8, 8, 11, ~
$ percent_z1_s15 <int> 80, 80, 81, 83, 92, 80, 83, 92, 80, 83, 83, 80~
$ percent_z2_s15 <int> 7, 7, 6, 6, 8, 7, 7, 8, 7, 6, 6, 7, 7, 6, 0, 7~
$ percent_z3_s15 <int> 13, 13, 13, 10, 0, 13, 10, 0, 13, 10, 10, 13, ~
$ pres_s16 <int> 40, 40, 40, 51, 40, 40, 51, 40, 40, 51, 51, 40~
$ reali_s16 <int> 40, 39, 39, 51, 7, 40, 44, 40, 40, 45, 28, 40,~
$ dif_s16 <int> 0, -1, -1, 0, -33, 0, -7, 0, 0, -6, -23, 0, -
1~
$ z1_s16 <int> 35, 34, 34, 43, 7, 35, 37, 35, 35, 43, 26, 35,~
$ z2_s16 <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 4, 12, ~
$ z3_s16 <int> 5, 5, 5, 8, 0, 5, 7, 5, 5, 2, 2, 5, 4, 2, 2, 5~

```

```

$ percent_z1_s16      <int> 88, 87, 87, 84, 100, 88, 84, 88, 88, 96, 93, 8~
$ percent_z2_s16      <int> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 10, 25, ~
$ percent_z3_s16      <int> 13, 13, 13, 16, 0, 13, 16, 13, 13, 4, 7, 13, 1~
$ l1_s0               <dbl> 9.70, 11.25, 9.80, 13.55, 10.25, 9.10, 11.80, ~
$ l2_s0               <dbl> 10.55, 12.35, 10.85, 14.65, 11.35, 10.35, 13.0~
$ l1_s8               <dbl> 9.95, 11.45, 10.50, 14.05, 10.70, 10.15, 14.10~
$ l2_s8               <dbl> 10.75, 12.55, 11.65, 15.10, 11.80, 11.35, 15.2~
$ l1_s16              <dbl> 10.05, 11.80, 10.65, 14.35, 11.00, 11.10, 14.0~
$ l2_s16              <dbl> 10.95, 12.80, 11.60, 15.30, 12.10, 12.10, 15.2~
$ maratona_menos_4h   <chr> "4h ou mais", "menos de 4h", "4h ou mais", "me~

```

2.0.5 Número de variáveis

```
ncol(select_if(dados, is.numeric))
```

```
[1] 205
```

2.0.6 Número de valores faltantes

```

na_count <- sapply(select_if(dados, is.numeric), function(y) sum(is.na(y)))
na_count <- data.frame(na_count)
na_count |> arrange(desc(na_count))

```

	na_count
percent_z1_s1	2
percent_z2_s1	2
percent_z3_s1	2
percent_z1_s4	2
percent_z2_s4	2
percent_z3_s4	2
reali_s1	1
dif_s1	1
z1_s1	1
z2_s1	1
z3_s1	1
reali_s2	1
dif_s2	1
z1_s2	1

z2_s2	1
z3_s2	1
percent_z1_s2	1
percent_z2_s2	1
percent_z3_s2	1
reali_s3	1
dif_s3	1
z1_s3	1
z2_s3	1
z3_s3	1
percent_z1_s3	1
percent_z2_s3	1
percent_z3_s3	1
reali_s4	1
z1_s4	1
z2_s4	1
z3_s4	1
pres_s5	1
reali_s5	1
z1_s5	1
z2_s5	1
z3_s5	1
percent_z1_s5	1
percent_z2_s5	1
percent_z3_s5	1
reali_s6	1
z1_s6	1
z2_s6	1
z3_s6	1
percent_z1_s6	1
percent_z2_s6	1
percent_z3_s6	1
reali_s7	1
z1_s7	1
z2_s7	1
z3_s7	1
percent_z1_s7	1
percent_z2_s7	1
percent_z3_s7	1
percent_z1_s9	1
percent_z2_s9	1
percent_z3_s9	1
percent_z1_s10	1

percent_z2_s10	1
percent_z3_s10	1
maratona_km_h_real	0
tt_3_km_h_real	0
tt_2_km_h_real	0
tt_1_km_h_real	0
z1_2_km_h_real	0
z1_1_km_h_real	0
t1000_s12_tempo_real	0
t1000_s12_km_h	0
t2000_s12_tempo_real	0
t2000_s12_km_h	0
t3000_s12_tempo_real	0
t3000_s12_km_h	0
vc_s12_real	0
d_s12_real	0
r_s12	0
rmse_s12	0
t1000_s4_km_h	0
t2000_s4_tempo_real	0
t2000_s4_km_h	0
t3000_s4_tempo_real	0
t3000_s4_km_h	0
vc_s4_real	0
d_s4_real	0
r_s4	0
rmse_s4	0
x1km_fresco_tempo_s0	0
x1km_fresco_vm_s0	0
d_21km_s0_real	0
x1km_pos_tempo_s0	0
x1km_pos_vm_s0	0
queda_s0	0
x1km_fresco_tempo_s4	0
x1km_fresco_vm_s4	0
d_21km_s4_real	0
x1km_pos_tempo_s4	0
x1km_pos_vm_s4	0
queda_s4	0
x1km_fresco_tempo_s8	0
x1km_fresco_vm_s8	0
d_21km_s8_real	0
x1km_pos_tempo_s8	0

x1km_pos_vm_s8	0
queda_s8	0
x1km_fresco_tempo_s12	0
x1km_fresco_vm_s12	0
d_21km_s12_real	0
x1km_pos_tempo_s12	0
x1km_pos_vm_s12	0
queda_s12	0
x1km_fresco_tempo_s16	0
x1km_fresco_vm_s16	0
d_21km_s16_real_vm	0
x1km_pos_tempo_s16	0
x1km_pos_vm_s16	0
queda_s16	0
pres_s1	0
pres_s2	0
pres_s3	0
pres_s4	0
dif_s4	0
dif_s5	0
pres_s6	0
dif_s6	0
pres_s7	0
dif_s7	0
pres_s8	0
reali_s8	0
dif_s8	0
z1_s8	0
z2_s8	0
z3_s8	0
percent_z1_s8	0
percent_z2_s8	0
percent_z3_s8	0
pres_s9	0
reali_s9	0
dif_s9	0
z1_s9	0
z2_s9	0
z3_s9	0
pres_s10	0
reali_s10	0
dif_s10	0
z1_s10	0

z2_s10	0
z3_s10	0
pres_s11	0
reali_s11	0
dif_s11	0
z1_s11	0
z2_s11	0
z3_s11	0
percent_z1_s11	0
percent_z2_s11	0
percent_z3_s11	0
pres_s12	0
reali_s12	0
dif_s12	0
z1_s12	0
z2_s12	0
z3_s12	0
percent_z1_s12	0
percent_z2_s12	0
percent_z3_s12	0
pres_s13	0
reali_s13	0
dif_s13	0
z1_s13	0
z2_s13	0
z3_s13	0
percent_z1_s13	0
percent_z2_s13	0
percent_z3_s13	0
pres_s14	0
reali_s14	0
dif_s14	0
z1_s14	0
z2_s14	0
z3_s14	0
percent_z1_s14	0
percent_z2_s14	0
percent_z3_s14	0
pres_s15	0
reali_s15	0
dif_s15	0
z1_s15	0
z2_s15	0

z3_s15	0
percent_z1_s15	0
percent_z2_s15	0
percent_z3_s15	0
pres_s16	0
reali_s16	0
dif_s16	0
z1_s16	0
z2_s16	0
z3_s16	0
percent_z1_s16	0
percent_z2_s16	0
percent_z3_s16	0
l1_s0	0
l2_s0	0
l1_s8	0
l2_s8	0
l1_s16	0
l2_s16	0

2.0.7 Distribuição das variáveis quantitativas mais importantes

2.0.7.1 Média do tempo da maratona de cada grupo

```
dados |> group_by(grupo) |> summarise(
  media_do_grupo_tempo = as.hms(mean(as.numeric(maratona_
```

```
# A tibble: 2 x 2
  grupo media_do_grupo_tempo
  <chr> <time>
1 G1    03:36:17.500000
2 G2    03:51:57.714286
```


```
dados_filtrados <- dados |>
  select_if(is.numeric) |>
  select(-contains(c("tempo_real", "pace")))
```

```
ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = maratona_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
```

```

    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 1.0,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "maratona em km/h" em cada grupo')+
  xlab("")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
  theme_minimal()+
  xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_1_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,

```

```

    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = 0,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  ggtitle('Distribuição da variável "Time trail de 21km - avaliação 1" em cada grupo')+
  labs(y = "Time trail de 21km - avaliação 1 (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
  theme_minimal()+
  xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_2_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Time trail de 21km - avaliação 2" em cada grupo')+
labs(y = "Time trail de 21km - avaliação 2 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = tt_3_km_h_real, fill = grupo))
geom_boxplot() +
stat_summary(
  fun = mean,
  geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Time trail de 21km - avaliação 3" em cada grupo')+
labs(y = "Time trail de 21km - avaliação 3 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = z1_1_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "21km em Z1 - avaliação 2" em cada grupo')+
labs(y = "21km em Z1 - avaliação 2 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```

ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = z1_2_km_h_real, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",


```



```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "21km em Z1 - avaliação 2" em cada grupo')+
labs(y = "21km em Z1 - avaliação 2 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t1000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 1km - Semana 4" em cada grupo')+
labs(y = "Teste 1km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t2000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 2km - Semana 4" em cada grupo')+
labs(y = "Teste 2km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t3000_s4_km_h, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = -0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 3km - Semana 4" em cada grupo')+
labs(y = "Teste 3km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = vc_s4_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Velocidade crítica - Semana 4" em cada grupo')+
labs(y = "Velocidade crítica - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = d_s4_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle("Distância máxima que pode ser percorrida acima da velocidade crítica - Semana 4")+
labs(y = "Distância (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t1000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 1km - Semana 12" em cada grupo')+
labs(y = "Teste 1km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t2000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 2km - Semana 12" em cada grupo')+
labs(y = "Teste 2km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```

ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = t3000_s12_km_h, fill = grupo))
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",


```



```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Teste 3km - Semana 12" em cada grupo')+
labs(y = "Teste 3km - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = vc_s12_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle('Distribuição da variável "Velocidade crítica - Semana 12" em cada grupo')+
labs(y = "Velocidade crítica - Semana 4 (km/h)")+
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
theme_minimal()+
xlab("")

```



```


ggplot(data = dados, mapping = aes(x = maratona_menos_4h, y = d_s12_real, fill = grupo)) +
  geom_boxplot() +
  stat_summary(
    fun = mean,
    geom = "text",

```

```

aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0.5,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
ggtitle("Distância máxima que pode ser percorrida acima da velocidade crítica - Semana 12")
labs(y = "Distância (km/h)") +
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
theme_minimal() +
xlab("")


```



```

ggplot(data = dados) +
  geom_bar(mapping = aes(x = maratona_menos_4h), fill = "#A8CCC9") +
  theme_minimal() +
  xlab("")

```



3 Desempenho ao longo das semanas

3.1 TT (S0, S8 e S16)

```
df_21km <- dados %>%
  select(
    grupo,
    atleta = codigo,
    s0 = `tt_1_km_h_real`,
    s8 = `tt_2_km_h_real`,
    s16 = `tt_3_km_h_real`
  ) %>%
  drop_na(grupo)

df_long <- df_21km %>%
  pivot_longer(
    cols = starts_with("s"),
    names_to = "semana",
    values_to = "velocidade_media"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("s0", "s8", "s16"))
  )


resumo_exploratorio <- df_long %>%
  group_by(grupo, semana) %>%
  summarise(
    n = n(),
    media = mean(velocidade_media, na.rm = TRUE),
    mediana = median(velocidade_media, na.rm = TRUE),
    desvio_padrao = sd(velocidade_media, na.rm = TRUE),
    minimo = min(velocidade_media, na.rm = TRUE),
    maximo = max(velocidade_media, na.rm = TRUE),
    .groups = "drop"
```

grupo	semana	n	media	mediana	desvio_padrao	minimo	maximo
G1	s0	16	11.84313	11.885	1.762444	9.06	14.89
G1	s8	16	12.46687	12.265	1.857994	9.89	15.50
G1	s16	16	12.83250	12.910	1.854391	9.98	15.85
G2	s0	14	11.25571	11.010	1.362152	9.52	13.45
G2	s8	14	11.93643	12.035	1.679165	10.06	14.82
G2	s16	14	12.12786	12.710	1.653352	9.91	14.65

)


```
resumo_exploratorio |> gt()
```

```
ggplot(data = df_long, mapping = aes(x = semana, y = velocidade_media, fill = grupo))+
  geom_boxplot()+
  stat_summary(
    fun = mean,
    geom = "text",
    aes(label = sprintf("%.1f", after_stat(y))),
    vjust = -0.8,
    size = 3.5,
    pfontface = "bold",
    position = position_dodge(0.75)
  ) +
  labs(y = "Velocidade do TT (km/h)")+
  scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9"))+
  theme_minimal()+
  xlab("Semana")
```



```
p <- ggplot(df_long, aes(x = semana, y = velocidade_media, group = atleta, color = grupo))
  geom_line(alpha = 0.5, size = 0.8) +
  geom_point(size = 2, alpha = 0.7) +
  scale_color_manual(values = c("#c7d66d", "#75b9be")) +
  facet_wrap(~ grupo) +
  labs(
    title = "Trajetória individual nos 21km TT",
    x = "Semanas de treino",
    y = "velocidade média (km/h)"
  ) +
  theme_minimal() +
  theme(legend.position = "none")

ggplotly(p, tooltip = c("atleta", "velocidade_media"))
```



3.2 Z1 (S4 e S12)

```
df_z1 <- dados %>%
  select(
    grupo,
    atleta = codigo,
    s4 = z1_1_km_h_real,
    s12 = z1_2_km_h_real
  ) %>%
  drop_na(grupo)

z1_long <- df_z1 %>%
  pivot_longer(
    cols = starts_with("s"),
    names_to = "semana",
    values_to = "velocidade_media"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("s4", "s12"))
  )

resumo_exploratorio_z1 <- z1_long %>%
  group_by(grupo, semana) %>%
  summarise(
    n = n(),
    media = mean(velocidade_media, na.rm = TRUE),
    mediana = median(velocidade_media, na.rm = TRUE),
    desvio_padrao = sd(velocidade_media, na.rm = TRUE),
    minimo = min(velocidade_media, na.rm = TRUE),
    maximo = max(velocidade_media, na.rm = TRUE),
    .groups = "drop"
  )

resumo_exploratorio_z1 |> gt()
```


```
ggplot(data = z1_long, mapping = aes(x = semana, y = velocidade_media, fill = grupo))+
  geom_boxplot()+
  stat_summary(
    fun = mean,
```

grupo	semana	n	media	mediana	desvio_padrao	minimo	maximo
G1	s4	16	10.72937	11.045	0.8594298	9.36	12.20
G1	s12	16	11.16188	11.475	1.1485946	9.21	12.57
G2	s4	14	10.53571	10.265	0.8534249	9.58	12.06
G2	s12	14	10.60000	10.240	1.5104202	7.11	12.53

```

geom = "text",
aes(label = sprintf("%.1f", after_stat(y))),
vjust = 0,
size = 3.5,
pfontface = "bold",
position = position_dodge(0.75)
) +
labs(y = "Velocidade em Z1 (km/h)") +
scale_fill_manual(values = c("G1" = "#DCEAB2", "G2" = "#A8CCC9")) +
theme_minimal() +
xlab("Semana")


```



O outlier é o atleta $G2_9$ que realizou a avaliação com velocidade media de 7.11 km/h

```
p <- ggplot(z1_long, aes(x = semana, y = velocidade_media, group = atleta, color = grupo)) +  
  geom_line(alpha = 0.5, size = 0.8) +  
  geom_point(size = 2, alpha = 0.7) +  
  scale_color_manual(values = c("#c7d66d", "#75b9be")) +  
  facet_wrap(~ grupo) +  
  labs(  
    title = "Trajetória individual nos 21km TT",  
    x = "Semanas de treino",  
    y = "velocidade média (km/h)"  
  ) +  
  theme_minimal() +  
  theme(legend.position = "none")  
  
ggplotly(p, tooltip = c("atleta", "velocidade_media"))
```

Trajetória individual nos 21km TT



4 Validação dos dados

4.0.1 Quantidade de atletas com o treino válido

$$L1_0 < L2_0 < VC_4$$

```
dados |> mutate(validade_s4 = ifelse(l1_s0 < l2_s0 & l2_s0 < vc_s4_real, "Válido", "Não Válido")) |> filter(validade_s4 == "Válido") |> nrow()
```

```
[1] 30
```

4.0.2 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S0

$$VM \text{ 1km fresco} < VM \text{ 1 km pós}$$

```
dados |> filter(x1km_fresco_vm_s0 < x1km_pos_vm_s0) |> select(1:3, maratona_tempo, x1km_fresco_vm_s0, x1km_pos_vm_s0) |> mutate(
  cols_label(
    grupo = "Grupo",
    codigo = "Código",
    nome = "Atleta",
    maratona_tempo = "Tempo da maratona",
    x1km_fresco_vm_s0 = "1 km fresco",
    x1km_pos_vm_s0 = "1 km pós"
  ) |>
  cols_align(
    align = "center",
    columns = everything()
  )
)
```

4.0.3 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S4

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_03	Amanda	14910	12.10	12.30
G2	G2_06	Netto	12658	18.56	18.75
G2	G2_07	Emerson Komuda	13777	13.64	13.95
G2	G2_12	Mayara	11429	15.65	15.79

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_04	Ana Munaro	10828	17.31	17.58
G1	G1_13	Paula	14466	12.33	13.16
G2	G2_14	Giulia	12388	17.48	17.65

```
dados |> filter(x1km_fresco_vm_s4 < x1km_pos_vm_s4) |>select(1:3, maratona_tempo, x1km_fresco_vm_s4, x1km_pos_vm_s4)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s4 = "1 km fresco",
  x1km_pos_vm_s4 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.4 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S8

```
dados |> filter(x1km_fresco_vm_s8 < x1km_pos_vm_s8) |>select(1:3, maratona_tempo, x1km_fresco_vm_s8, x1km_pos_vm_s8)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s8 = "1 km fresco",
  x1km_pos_vm_s8 = "1 km pós"
) |>
```

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G2	G2_06	Netto	12658	18	18.18

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G2	G2_06	Netto	12658	18.29	18.35

```
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.5 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S12

```
dados |> filter(x1km_fresco_vm_s12 < x1km_pos_vm_s12) |>select(1:3, maratona_tempo, x1km_fresco_vm_s12, x1km_pos_vm_s12)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s12 = "1 km fresco",
  x1km_pos_vm_s12 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)
```

4.0.6 Quantidade de atletas que a velocidade média no 1km fresco foi menor que pós 21km em S16

```
dados |> filter(x1km_fresco_vm_s16 < x1km_pos_vm_s16) |>select(1:3, maratona_tempo, x1km_fresco_vm_s16, x1km_pos_vm_s16)
cols_label(
  grupo = "Grupo",
  codigo = "Código",
  nome = "Atleta",
  maratona_tempo = "Tempo da maratona",
  x1km_fresco_vm_s16 = "1 km fresco",
  x1km_pos_vm_s16 = "1 km pós"
)
```

Grupo	Código	Atleta	Tempo da maratona	1 km fresco	1 km pós
G1	G1_03	Amanda	14910	12.86	13.16
G1	G1_13	Paula	14466	13.39	13.66

```

nome = "Atleta",
maratona_tempo = "Tempo da maratona",
x1km_fresco_vm_s16 = "1 km fresco",
x1km_pos_vm_s16 = "1 km pós"
) |>
cols_align(
  align = "center",
  columns = everything()
)

```


5 Estrutura dos dados da segunda tabela (quali)

5.0.1 Distribuição das variáveis qualitativas mais importantes

```
library(tidyverse)
library(lubridate)
library(knitr)
library(lme4)
library(lmerTest)
library(kableExtra)

df_quant_bruto <- read_csv2("Book 2(Planilha1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

df_quali_bruto <- read_csv2("Quali(Planilha1) (1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

to_num <- function(x) {
  suppressWarnings(as.numeric(str_replace_all(as.character(x), ",", ".")))
}

fix_peso <- function(x) {
  sapply(x, function(val) {
    num <- suppressWarnings(as.numeric(str_replace_all(as.character(val), ",", ".")))
    if (is.na(num)) return(NA_real_)
    while (num > 150) { num <- num / 10 }
    return(round(num, 2))
  })
}

parse_md <- function(x) {
  x_str <- str_trim(as.character(x))
  case_when(
```

```

    str_detect(tolower(x_str), "^s|^1") ~ 1,
    str_detect(tolower(x_str), "^n|^0") ~ 0,
    TRUE ~ NA_real_
  )
}

parse_likert_num <- function(x) {
  x_str <- str_trim(as.character(x))
  if_else(
    str_detect(x_str, "[0-9]"),
    suppressWarnings(as.numeric(str_sub(x_str, 1, 1))),
    suppressWarnings(as.numeric(str_replace_all(x_str, ",", ".")))
  )
}

names(df_quant_bruto)[names(df_quant_bruto) %in% c("Maratona_Km/h_REAL", "Maratona_Km.h_REAL")] <- "Maratona_Km.h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_1_Km/h_REAL", "TT_1_Km.h_REAL")] <- "TT_1_Km.h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_2_Km/h_REAL", "TT_2_Km.h_REAL")] <- "TT_2_Km.h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_3_Km/h_REAL", "TT_3_Km.h_REAL")] <- "TT_3_Km.h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_1_Km/h_REAL", "z1_1_Km.h_REAL")] <- "z1_1_Km.h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_2_Km/h_REAL", "z1_2_Km.h_REAL")] <- "z1_2_Km.h_REAL"

df_quant <- df_quant_bruto %>%
  mutate(
    Grupo = as.factor(Grupo),
    Maratona_Minutos = as.numeric(Maratona_Tempo) / 60,
    Maratona_Kmh = to_num(Maratona_Kmh_Original),
    TT_S0 = to_num(TT_1_Kmh_Original),
    TT_S8 = to_num(TT_2_Kmh_Original),
    TT_S16 = to_num(TT_3_Kmh_Original),
    Z1_S4 = to_num(z1_1_Kmh_Original),
    Z1_S12 = to_num(z1_2_Kmh_Original),
    VC_S4_limpa = if_else(to_num(VC_S4_REAL) > 30, to_num(VC_S4_REAL)/10, to_num(VC_S4_REAL)),
    VC_S12_limpa = if_else(to_num(VC_S12_REAL) > 30, to_num(VC_S12_REAL)/10, to_num(VC_S12_REAL)),
    Queda_1km_S0 = abs(to_num(Queda_S0)),
    Queda_1km_S4 = abs(to_num(Queda_S4)),
    Queda_1km_S8 = abs(to_num(Queda_S8)),
    Queda_1km_S12 = abs(to_num(Queda_S12)),
    Queda_1km_S16 = abs(to_num(Queda_S16)),
    Nome_clean = str_to_lower(str_trim(iconv(Nome, to = "ASCII//TRANSLIT")))
  )
}

```

```
df_quali_clean <- df_quali_bruto %>%
  mutate(
    across(starts_with("Peso_"), fix_peso),
    across(starts_with("MD_"), parse_md),
    across(c(starts_with("Sono_"), starts_with("Stress_"), starts_with("Fadiga_"), starts_with("Foco_")),
      Nome_clean = str_to_lower(str_trim(iconv(`Nome completo`, to = "ASCII//TRANSLIT")))
    )
  )

df_all <- df_quant %>%
  inner_join(df_quali_clean, by = "Nome_clean")
```

5.0.2 Quantidade de atletas

```
nrow(df_quali_clean)
```

```
[1] 28
```

5.0.3 Número de variáveis

```
ncol(df_quali_clean)
```

```
[1] 92
```

5.0.4 Primeiras 6 linhas dos dados

```
df_quali_clean |> head() |> gt() |>
  cols_align(
    align = "center",
    columns = everything()
  )
```

Nome completo	Peso_S4	Peso_S5	Peso_S6	Peso_S7	Peso_S8	Peso_S9	Peso_S10	Peso_S11
Alcione	63.0	62.3	62.8	64.4	64.0	63.0	62.8	63.0
Alessandro	75.0	74.0	75.0	75.0	75.0	75.0	75.0	75.0
Amanda	55.0	55.0	55.0	54.0	54.0	54.0	54.0	54.0
Ana Munaro	53.7	53.4	53.2	53.0	52.5	52.5	52.3	52.4
Andreia Rosa	58.5	58.5	58.5	58.5	57.5	57.5	57.3	57.5
Carlos	68.0	66.0	66.7	66.0	66.5	67.3	66.0	66.0

5.0.5 Variáveis e seus tipos

```
glimpse(df_quali_clean)
```

```

Rows: 28
Columns: 92
$ `Nome completo` <chr> "Alcione", "Alessandro", "Amanda", "Ana Munaro", "Andr~
$ Peso_S4          <dbl> 63.0, 75.0, 55.0, 53.7, 58.5, 68.0, 62.0, 84.5, 77.2, ~
$ Peso_S5          <dbl> 62.3, 74.0, 55.0, 53.4, 58.5, 66.0, 61.8, 84.0, 77.1, ~
$ Peso_S6          <dbl> 62.80, 75.00, 55.00, 53.20, 58.50, 66.70, 61.50, 83.75~
$ Peso_S7          <dbl> 64.40, 75.00, 54.00, 53.00, 58.50, 66.00, 61.20, 81.95~
$ Peso_S8          <dbl> 64.00, 75.00, 54.00, 52.50, 57.50, 66.50, 61.40, 84.00~
$ Peso_S9          <dbl> 63.00, 75.00, 54.00, 52.50, 57.50, 67.30, 61.50, 82.95~
$ Peso_S10         <dbl> 62.8, 75.0, 54.0, 52.3, 57.3, 66.0, 61.2, 82.4, 76.2, ~
$ Peso_S11         <dbl> 63.00, 75.00, 54.00, 52.40, 57.50, 66.00, 60.80, 83.45~
$ Peso_S12         <dbl> 63.00, 75.00, 54.00, 52.50, 57.00, 66.00, 60.80, 83.45~
$ Peso_S13         <dbl> 63.00, 75.00, 54.00, 52.50, 56.20, 66.00, 59.80, 83.55~
$ Peso_S14         <dbl> 63.00, 74.00, 54.00, 52.30, 56.00, 66.00, 60.90, 81.95~
$ Peso_S15         <dbl> 63.00, 74.00, 55.00, 52.50, 56.00, 66.00, 60.45, 82.30~
$ Peso_S16         <dbl> 63.00, 74.00, 54.00, 52.50, 56.00, 65.50, 60.50, 82.25~
$ Peso_S17         <dbl> 62.00, 74.00, 54.00, 52.50, 55.50, 65.00, 61.10, 81.50~
$ Peso_S18         <dbl> 62.0, 75.0, 55.0, 52.5, 56.0, 65.0, 60.4, 81.6, 75.9, ~
$ Sono_S4          <dbl> 1, 4, 4, 3, 2, 3, 4, 3, 3, 7, 4, 4, 2, 3, 3, 3, 1, 4, ~
$ Sono_S5          <dbl> 3, 5, 4, 2, 1, 3, 6, 3, 3, 3, 1, 4, 2, 3, 3, 3, 2, 5, ~
$ Sono_S6          <dbl> 3, 4, 5, 3, 2, 3, 4, 2, 3, 2, 4, 4, 2, 3, 2, 3, 4, 4, ~
$ Sono_S7          <dbl> 2, 3, 3, 3, 2, 4, 5, 4, 3, 6, 2, 5, 2, 3, 2, 3, 1, 4, ~
$ Sono_S8          <dbl> 3, 3, 3, 4, 2, 3, 4, 3, 3, 6, 4, 3, NA, 4, 3, 5, 1, 4, ~
$ Sono_S9          <dbl> 3, 4, 3, 6, 2, 3, 3, 3, 3, 5, 1, 3, NA, 3, 2, 3, 1, 4, ~
$ Sono_S10         <dbl> 2, 4, 3, 4, 2, 3, 3, 2, 3, 6, 3, 3, 3, 3, 3, 3, 1, 4, ~
$ Sono_S11         <dbl> 3, 3, 3, 4, 2, 3, 3, 2, 3, 3, 3, 3, NA, 3, 2, 3, 2, 4, ~
$ Sono_S12         <dbl> 3, 4, 3, 4, 2, 3, 5, 2, 3, 4, 3, 3, 3, 3, 2, 4, 1, 5, ~
$ Sono_S13         <dbl> 3, 4, 3, 3, 2, 4, 3, 2, 3, 6, 4, 2, 3, 3, 2, 4, 2, 4, ~

```

\$ Sono_S14	<dbl> 3, 4, 3, 3, 2, 4, 2, 3, 3, 5, 4, 3, 3, 4, 2, 3, 1, 4, ~
\$ Sono_S15	<dbl> 3, 4, 3, 3, 2, 3, 3, 2, 3, 5, 4, 3, 3, 4, 2, 3, 1, 5, ~
\$ Sono_S16	<dbl> 2, 3, 3, 3, 2, 4, 3, 3, 3, 4, 4, 2, 3, 4, 2, 3, 1, 4, ~
\$ Sono_S17	<dbl> 2, 4, 3, 4, 2, 3, 4, 3, 3, 4, 3, 2, 3, 4, 4, 4, 2, 4, ~
\$ Sono_S18	<dbl> 3, 3, 3, 4, 3, 3, 3, 3, 3, 2, 3, 1, 3, 3, 3, 3, 1, 4, ~
\$ Stress_S4	<dbl> 2, 3, 3, 4, 4, 4, 2, 3, 3, 6, 6, 4, 4, 3, 4, 4, 3, 5, ~
\$ Stress_S5	<dbl> 4, 3, 2, 4, 3, 3, 3, 3, 3, 2, 1, 4, 4, 3, 4, 4, 4, 5, ~
\$ Stress_S6	<dbl> 3, 3, 3, 4, 4, 4, 5, 2, 2, 2, 4, 4, 3, 4, 6, 4, 5, 4, ~
\$ Stress_S7	<dbl> 3, 3, 3, 4, 3, 4, 5, 3, 1, 5, 2, 6, 3, 4, 6, 4, 3, 5, ~
\$ Stress_S8	<dbl> 5, 3, 3, 4, 3, 4, 5, 3, 1, 5, 4, 5, NA, 4, 5, 5, 4, 5, ~
\$ Stress_S9	<dbl> 4, 2, 3, 4, 4, 4, 2, 2, 1, 4, 4, 4, NA, 3, 3, 4, 4, 4, ~
\$ Stress_S10	<dbl> 4, 3, 3, 4, 3, 3, 4, 2, 1, 6, 5, 4, 3, 4, 4, 4, 4, 5, ~
\$ Stress_S11	<dbl> 4, 3, 4, 4, 3, 3, 3, 2, 1, 6, 5, 4, NA, 4, 3, 4, 4, 5, ~
\$ Stress_S12	<dbl> 4, 3, 3, 4, 3, 3, 4, 2, 1, 5, 5, 3, 3, 4, 3, 4, 4, 5, ~
\$ Stress_S13	<dbl> 3, 3, 3, 4, 3, 4, 3, 2, 2, 6, 4, 4, 3, 4, 4, 6, 4, 5, ~
\$ Stress_S14	<dbl> 5, 3, 3, 4, 4, 4, 3, 2, 2, 4, 4, 4, 3, 3, 4, 4, 4, 5, ~
\$ Stress_S15	<dbl> 6, 4, 3, 4, 4, 4, 3, 2, 2, 5, 4, 4, 2, 4, 4, 4, 3, 4, ~
\$ Stress_S16	<dbl> 4, 3, 3, 5, 4, 4, 3, 2, 1, 3, 4, 4, 3, 4, 6, 4, 4, 5, ~
\$ Stress_S17	<dbl> 4, 3, 3, 5, 4, 4, 3, 2, 2, 2, 2, 4, 3, 4, 3, 5, 4, 5, ~
\$ Stress_S18	<dbl> 4, 3, 3, 4, 4, 4, 3, 2, 2, 3, 3, 2, 3, 4, 3, 4, 3, 5, ~
\$ Fadiga_S4	<dbl> 3, 4, 4, 4, 4, 4, 3, 3, 2, 2, 3, 5, 4, 3, 1, 4, 4, 4, ~
\$ Fadiga_S5	<dbl> 4, 4, 4, 4, 3, 3, 4, 3, 2, 2, 2, 4, 5, 3, 3, 4, 3, 4, ~
\$ Fadiga_S6	<dbl> 3, 3, 5, 4, 4, 4, 4, 3, 1, 3, 4, 5, 3, 3, 2, 4, 5, 4, ~
\$ Fadiga_S7	<dbl> 2, 3, 5, 5, 4, 3, 3, 3, 1, 4, 4, 6, 3, 4, 3, 4, 4, 4, ~
\$ Fadiga_S8	<dbl> 4, 3, 4, 5, 3, 3, 2, 2, 2, 2, 5, 3, NA, 4, 3, 3, 4, 3, ~
\$ Fadiga_S9	<dbl> 4, 4, 3, 5, 4, 3, 4, 2, 4, 4, 4, 4, NA, 4, 2, 5, 4, 3, ~
\$ Fadiga_S10	<dbl> 3, 4, 4, 5, 4, 3, 4, 3, 2, 5, 5, 3, 3, 4, 3, 4, 4, 3, ~
\$ Fadiga_S11	<dbl> 5, 3, 4, 5, 5, 3, 5, 2, 2, 5, 5, 4, NA, 4, 3, 5, 4, 3, ~
\$ Fadiga_S12	<dbl> 4, 3, 4, 5, 4, 2, 3, 1, 3, 2, 5, 4, 4, 4, 3, 4, 4, 4, ~
\$ Fadiga_S13	<dbl> 4, 3, 4, 5, 4, 3, 3, 2, 3, 2, 4, 4, 5, 4, 2, 4, 4, 3, ~
\$ Fadiga_S14	<dbl> 6, 3, 5, 5, 4, 3, 3, 2, 3, 3, 4, 3, 4, 4, 3, 5, 4, 3, ~
\$ Fadiga_S15	<dbl> 5, 4, 4, 5, 4, 3, 3, 2, 3, 3, 4, 3, 3, 4, 4, 5, 4, 3, ~
\$ Fadiga_S16	<dbl> 4, 4, 4, 5, 3, 2, 5, 3, 2, 6, 4, 4, 3, 4, 3, 5, 4, 3, ~
\$ Fadiga_S17	<dbl> 2, 3, 4, 4, 3, 1, 2, 1, 2, 1, 4, 3, 3, 4, 3, 4, 3, 3, ~
\$ Fadiga_S18	<dbl> 3, 3, 4, 3, 3, 2, 2, 1, 3, 1, 3, 1, 3, 3, 2, 3, 3, 3, ~
\$ Dor_S4	<dbl> 3, 5, 4, 2, 3, 4, 3, 3, 3, 1, 3, 4, 3, 3, 1, 3, 2, 2, ~
\$ Dor_S5	<dbl> 2, 3, 3, 3, 3, 3, 3, 3, 2, 1, 3, 3, 3, 3, 2, 3, 3, 3, ~
\$ Dor_S6	<dbl> 3, 5, 3, 3, 3, 5, 3, 2, 1, 4, 4, 3, 4, 4, 2, 3, 3, 3, ~
\$ Dor_S7	<dbl> 3, 7, 5, 3, 4, 4, 4, 3, 1, 3, 4, 3, 2, 4, 3, 3, 3, 2, ~
\$ Dor_S8	<dbl> 2, 4, 3, 3, 4, 3, 2, 2, 3, 1, 4, 2, NA, 4, 3, 4, 3, 2, ~
\$ Dor_S9	<dbl> 3, 4, 4, 4, 4, 5, 4, 2, 4, 3, 5, 4, NA, 4, 2, 3, 3, 1, ~
\$ Dor_S10	<dbl> 3, 4, 4, 4, 4, 2, 4, 3, 3, 4, 5, 2, 3, 4, 3, 4, 3, 2, ~
\$ Dor_S11	<dbl> 3, 3, 4, 4, 5, 2, 4, 2, 3, 6, 6, 3, NA, 3, 5, 4, 3, 2, ~

```

$ Dor_S12      <dbl> 3, 3, 4, 5, 5, 2, 6, 1, 2, 1, 5, 3, 2, 4, 2, 4, 3, 2, ~
$ Dor_S13      <dbl> 4, 3, 4, 4, 5, 2, 5, 2, 2, 1, 4, 3, 5, 4, 3, 4, 3, 3, ~
$ Dor_S14      <dbl> 5, 3, 5, 5, 4, 2, 3, 3, 2, 1, 4, 2, 3, 4, 5, 3, 3, 2, ~
$ Dor_S15      <dbl> 4, 4, 4, 4, 5, 3, 3, 3, 2, 3, 4, 4, 3, 4, 5, 4, 3, 2, ~
$ Dor_S16      <dbl> 2, 4, 4, 5, 6, 2, 3, 3, 1, 2, 4, 4, 3, 4, 5, 3, 3, 2, ~
$ Dor_S17      <dbl> 2, 4, 3, 5, 4, 1, 1, 1, 1, 1, 1, 2, 3, 4, 2, 3, 3, 3, ~
$ Dor_S18      <dbl> 3, 3, 4, 3, 3, 1, 1, 2, 3, 1, 2, 1, 3, 4, 2, 3, 3, 2, ~
$ MD_S4        <dbl> 1, 0, 0, 1, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0, 1, ~
$ MD_S5        <dbl> 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 1, ~
$ MD_S6        <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 1, 0, 1, 1, ~
$ MD_S7        <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 1, 0, 0, 1, 0, 0, 1, ~
$ MD_S8        <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1, 1, NA, 0, 1, 0, 0, 1, ~
$ MD_S9        <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1, 1, NA, 0, 1, 0, 0, 1, ~
$ MD_S10       <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1, 1, 0, 0, 1, 0, 0, 1, ~
$ MD_S11       <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, NA, 0, 1, 0, 0, 1, ~
$ MD_S12       <dbl> 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 1, 0, 1, ~
$ MD_S13       <dbl> 1, 0, 0, 1, 0, 1, 1, 0, 0, 1, 1, 0, 0, 0, 1, 1, 0, 1, ~
$ MD_S14       <dbl> 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, ~
$ MD_S15       <dbl> 1, 0, 0, 1, 0, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 1, ~
$ MD_S16       <dbl> 1, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, ~
$ MD_S17       <dbl> 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, ~
$ MD_S18       <dbl> 1, 0, 0, 1, 0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, ~
$ Nome_clean   <chr> "alcione", "alessandro", "amanda", "ana munaro", "andr~

```

5.0.6 Número de valores faltantes

```

na_count <- sapply(df_quali_clean, function(y) sum(is.na(y)))
na_count <- data.frame(na_count)
na_count |> arrange(desc(na_count))

```

	na_count
Peso_S11	3
Peso_S18	3
Sono_S18	3
Stress_S18	3
Fadiga_S18	3
Dor_S18	3
MD_S18	3
Sono_S11	2
Stress_S11	2

Fadiga_S11	2
Dor_S11	2
MD_S11	2
Peso_S5	1
Peso_S8	1
Peso_S9	1
Peso_S14	1
Peso_S15	1
Sono_S8	1
Sono_S9	1
Sono_S14	1
Sono_S15	1
Stress_S8	1
Stress_S9	1
Stress_S14	1
Stress_S15	1
Fadiga_S8	1
Fadiga_S9	1
Fadiga_S14	1
Fadiga_S15	1
Dor_S8	1
Dor_S9	1
Dor_S14	1
Dor_S15	1
MD_S8	1
MD_S9	1
MD_S14	1
MD_S15	1
Nome completo	0
Peso_S4	0
Peso_S6	0
Peso_S7	0
Peso_S10	0
Peso_S12	0
Peso_S13	0
Peso_S16	0
Peso_S17	0
Sono_S4	0
Sono_S5	0
Sono_S6	0
Sono_S7	0
Sono_S10	0
Sono_S12	0

Sono_S13	0
Sono_S16	0
Sono_S17	0
Stress_S4	0
Stress_S5	0
Stress_S6	0
Stress_S7	0
Stress_S10	0
Stress_S12	0
Stress_S13	0
Stress_S16	0
Stress_S17	0
Fadiga_S4	0
Fadiga_S5	0
Fadiga_S6	0
Fadiga_S7	0
Fadiga_S10	0
Fadiga_S12	0
Fadiga_S13	0
Fadiga_S16	0
Fadiga_S17	0
Dor_S4	0
Dor_S5	0
Dor_S6	0
Dor_S7	0
Dor_S10	0
Dor_S12	0
Dor_S13	0
Dor_S16	0
Dor_S17	0
MD_S4	0
MD_S5	0
MD_S6	0
MD_S7	0
MD_S10	0
MD_S12	0
MD_S13	0
MD_S16	0
MD_S17	0
Nome_clean	0


Grupo	F	M
G1	7	9
G2	7	5

5.0.6.1 Número de homens e mulheres em cada grupo

```
df_all$sexo <- c(
  "F", # Alcione
  "M", # Alessandro
  "F", # Amanda
  "F", # Ana Munaro
  "F", # Andreia Rosa
  "M", # Carlos
  "F", # Djanine
  "M", # Eugênio
  "M", # Israel
  "M", # Neto Carvalho
  "M", # Patrick
  "F", # Paula
  "F", # Santina
  "M", # Sidnei
  "M", # Vinicius
  "M", # Wagner
  "F", # Adriana
  "F", # Ana Lúcia
  "F", # Cecília
  "M", # Deni (se for feminino no seu contexto, ajuste aqui)
  "M", # Netto
  "M", # Emerson Komuda
  "M", # Emerson Jubanski
  "F", # Lindsay
  "F", # Luciana
  "M", # Marcos Regly
  "F", # Mayara
  "F", # Morgana
)

df_all |> group_by(Grupo, sexo) |> summarise(n = n()) |>
  pivot_wider(names_from = sexo, values_from = n) |> as.data.frame() |> gt() |> cols_align(a
```

```
ggplot(data = df_all, mapping = aes(x = Grupo, fill = sexo))+
  geom_bar(position = "dodge")+
  scale_y_continuous(breaks = breaks_pretty())+
  theme_minimal()
```



5.0.6.2 Média de peso de cada grupo

```
df_all |> group_by(Grupo) |> summarise(media_peso_S4 = mean(Peso_S4))
```

```
# A tibble: 2 x 2
  Grupo media_peso_S4
  <fct>      <dbl>
1 G1        69.7
2 G2        69.8
```

Grupo	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16
G1	69.70	69.17	69.40	69.18	69.92	69.99	68.42	69.69	68.54	68.39	68.23	68.17	68.17
G2	69.82	70.05	69.38	69.35	69.58	69.81	69.50	70.66	69.61	69.42	69.99	70.36	69.17

```
tabela_semanas_peso <- function(semmana) {
  col_origem <- paste0("Peso_", semmana)

  df_all |>
    group_by(Grupo) |>
    summarise(
      media_peso := round(mean(.data[[col_origem]], na.rm = TRUE), 2),
      .groups = "drop"
    ) |> mutate(semmana = as.character(semmana))
}

semanas <- paste0("S", 4:18)
semanas_peso <- lapply(semanas, tabela_semanas_peso)

bind_rows(semanas_peso) |> pivot_wider(names_from = semmana, values_from = media_peso) |> gt()
```

6 Teste de Shapiro-Wilk: testando a normalidade dos dados

```
dados |>
  select(contains("km_h")) |>
  pivot_longer(everything(), names_to = "variaveis", values_to = "valor") |>
  group_by(variaveis) |>
  summarise(
    w_stat = shapiro.test(valor)$statistic,
    p_valor = round(shapiro.test(valor)$p.value, 4),
    normal = ifelse(p_valor >= 0.05, "Sim", "Não")
  ) |> gt() |> cols_align(columns = everything(), align = "center")
```

variaveis	w_stat	p_valor	normal
maratona_km_h_real	0.9343685	0.0642	Sim
t1000_s12_km_h	0.9323249	0.0566	Sim
t1000_s4_km_h	0.9177139	0.0234	Não
t2000_s12_km_h	0.9223702	0.0309	Não
t2000_s4_km_h	0.9343331	0.0641	Sim
t3000_s12_km_h	0.9398662	0.0902	Sim
t3000_s4_km_h	0.9178588	0.0236	Não
tt_1_km_h_real	0.9517741	0.1886	Sim
tt_2_km_h_real	0.9253313	0.0370	Não
tt_3_km_h_real	0.9393527	0.0874	Sim
z1_1_km_h_real	0.9444717	0.1201	Sim
z1_2_km_h_real	0.9103939	0.0152	Não

7 Tabela de comparação das médias dos dois grupos

```
dados |> group_by(grupo) |> summarise(maratona_km_h = mean(maratona_km_h_real),  
                                       d_21km_s0_real = mean(d_21km_s0_real, na.rm = TRUE),  
                                       )
```

```
# A tibble: 2 x 3  
  grupo maratona_km_h d_21km_s0_real  
  <chr>      <dbl>      <dbl>  
1 G1         12.0         11.8  
2 G2         11.1         11.3
```

8 Perguntas

Abaixo, realizamos a leitura das bases brutas e aplicamos as rotinas de tratamento para padronização de separadores decimais, correção de escalas de peso e estruturação das variáveis.

```
library(tidyverse)
library(lubridate)
library(knitr)
library(lme4)
library(lmerTest)
library(kableExtra)

df_quant_bruto <- read_csv2("Book 2(Planilha1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

df_quali_bruto <- read_csv2("Quali(Planilha1) (1).csv", locale = locale(decimal_mark = ",", encoding = "UTF-8"),
  slice(1:30))

to_num <- function(x) {
  suppressWarnings(as.numeric(str_replace_all(as.character(x), ",", ".")))
}

fix_peso <- function(x) {
  sapply(x, function(val) {
    num <- suppressWarnings(as.numeric(str_replace_all(as.character(val), ",", ".")))
    if (is.na(num)) return(NA_real_)
    while (num > 150) { num <- num / 10 }
    return(round(num, 2))
  })
}

parse_md <- function(x) {
  x_str <- str_trim(as.character(x))
  case_when(
    str_detect(tolower(x_str), "^s|^1") ~ 1,
    str_detect(tolower(x_str), "^n|^0") ~ 0,
  )
}
```

```

    TRUE ~ NA_real_
  )
}

parse_likert_num <- function(x) {
  x_str <- str_trim(as.character(x))
  if_else(
    str_detect(x_str, "[0-9]"),
    suppressWarnings(as.numeric(str_sub(x_str, 1, 1))),
    suppressWarnings(as.numeric(str_replace_all(x_str, ",", ".")))
  )
}

names(df_quant_bruto)[names(df_quant_bruto) %in% c("Maratona_Km/h_REAL", "Maratona_Km.h_REAL")] <- "Maratona_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_1_Km/h_REAL", "TT_1_Km.h_REAL")] <- "TT_1_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_2_Km/h_REAL", "TT_2_Km.h_REAL")] <- "TT_2_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("TT_3_Km/h_REAL", "TT_3_Km.h_REAL")] <- "TT_3_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_1_Km/h_REAL", "z1_1_Km.h_REAL")] <- "z1_1_Km/h_REAL"
names(df_quant_bruto)[names(df_quant_bruto) %in% c("z1_2_Km/h_REAL", "z1_2_Km.h_REAL")] <- "z1_2_Km/h_REAL"

df_quant <- df_quant_bruto %>%
  mutate(
    Grupo = as.factor(Grupo),
    Maratona_Minutos = as.numeric(Maratona_Tempo) / 60,
    Maratona_Kmh = to_num(Maratona_Kmh_Original),
    TT_S0 = to_num(TT_1_Kmh_Original),
    TT_S8 = to_num(TT_2_Kmh_Original),
    TT_S16 = to_num(TT_3_Kmh_Original),
    Z1_S4 = to_num(z1_1_Kmh_Original),
    Z1_S12 = to_num(z1_2_Kmh_Original),
    VC_S4_limpa = if_else(to_num(VC_S4_REAL) > 30, to_num(VC_S4_REAL)/10, to_num(VC_S4_REAL)),
    VC_S12_limpa = if_else(to_num(VC_S12_REAL) > 30, to_num(VC_S12_REAL)/10, to_num(VC_S12_REAL)),
    Queda_1km_S0 = abs(to_num(Queda_S0)),
    Queda_1km_S4 = abs(to_num(Queda_S4)),
    Queda_1km_S8 = abs(to_num(Queda_S8)),
    Queda_1km_S12 = abs(to_num(Queda_S12)),
    Queda_1km_S16 = abs(to_num(Queda_S16)),
    Nome_clean = str_to_lower(str_trim(iconv(Nome, to = "ASCII//TRANSLIT")))
  )
}

```



```

df_quali_clean <- df_quali_bruto %>%
  mutate(
    across(starts_with("Peso_"), fix_peso),
    across(starts_with("MD_"), parse_md),
    across(c(starts_with("Sono_"), starts_with("Stress_"), starts_with("Fadiga_"), starts_with("Stress_")),
      Nome_clean = str_to_lower(str_trim(iconv(`Nome completo`, to = "ASCII//TRANSLIT")))
    )
  )

df_all <- df_quant %>%
  inner_join(df_quali_clean, by = "Nome_clean")

```

9 Teste de normalidade

```
resultado <- shapiro.test(df_all$Maratona_Kmh_Original)
resultado
```

Shapiro-Wilk normality test

```
data:  df_all$Maratona_Kmh_Original
W = 0.92751, p-value = 0.05338
```

10 Bloco 1: Análises Perceptivas e Qualitativas

($N = 28$)

10.1 Pergunta 1: Como se comporta a percepção de desgaste entre os grupos?

O que faz o Teste de Mann-Whitney? É um teste estatístico não paramétrico utilizado para comparar duas amostras independentes. Ele avalia se uma distribuição tende a apresentar valores maiores do que a outra sem assumir que os dados seguem uma distribuição normal.

```
dominios <- c("Sono", "Stress", "Fadiga", "Dor", "MD")

res_p1 <- map_df(dominios, function(dom) {
  cols <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S"))]
  df_all$media_dom <- rowMeans(df_all[, cols], na.rm = TRUE)
  m_g1 <- mean(df_all$media_dom[df_all$Grupo == "G1"], na.rm = TRUE)
  m_g2 <- mean(df_all$media_dom[df_all$Grupo == "G2"], na.rm = TRUE)
  wt <- wilcox.test(media_dom ~ Grupo, data = df_all)
  tibble(
    Domínio = dom,
    `Média G1` = round(m_g1, 2),
    `Média G2` = round(m_g2, 2),
    `p-valor` = round(wt$p.value, 4),
    `Significância` = if_else(wt$p.value < 0.05, "Significativo (p < 0,05)", "Não Significativo")
  )
})

res_p1 %>%
  kable(caption = "Comparação das Médias Qualitativas Acumuladas entre os Grupos") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 10.1: Comparação das Médias Qualitativas Acumuladas entre os Grupos

Domínio	Média G1	Média G2	p-valor	Significância
---------	----------	----------	---------	---------------

Sono	3.14	3.71	0.0257	Significativo (p < 0,05)
Stress	3.50	4.22	0.0242	Significativo (p < 0,05)
Fadiga	3.45	3.71	0.4155	Não Significativo
Dor	3.22	3.37	0.6757	Não Significativo
MD	0.35	0.35	0.9227	Não Significativo


10.1.1 Gráfico da série temporal qualitativa

```
df_serie <- df_all %>%
  select(Grupo, Nome_clean, starts_with("Fadiga_S"), starts_with("Stress_S"), starts_with("Dor_S"), starts_with("MD_S")) %>%
  pivot_longer(cols = -c(Grupo, Nome_clean), names_to = "Variavel_Semana", values_to = "Escore") %>%
  separate(Variavel_Semana, into = c("Variavel", "Semana"), sep = "_S") %>%
  mutate(Semana = as.numeric(Semana))

ggplot(df_serie, aes(x = Semana, y = Escore, color = Grupo, group = Grupo)) +
  stat_summary(fun = mean, geom = "line", linewidth = 1) +
  stat_summary(fun = mean, geom = "point", size = 2) +
  facet_wrap(~Variavel, scales = "free_y") +
  labs(
    title = "Evolução Semanal da Percepção Qualitativa (S4 a S18)",
    subtitle = "Linhas representam a média semanal de cada grupo",
    x = "Semana de Treinamento",
    y = "Escore Médio Percebido",
    color = "Sequência de Treino"
  ) +
  theme_minimal() +
  scale_color_brewer(palette = "Set1")
```

Evolução Semanal da Percepção Qualitativa (S4 a S18)

Linhas representam a média semanal de cada grupo



O que os dados nos mostram: Iniciando a análise, observamos diferenças importantes no bem-estar percebido. Os maratonistas do Grupo 2 relataram um nível de estresse significativamente mais alto (4,22 contra 3,50, com p-valor igual a 0,0242) e uma qualidade de sono pior (3,71 contra 3,14, com p-valor igual a 0,0257) quando comparados ao Grupo 1. As variáveis de fadiga, dor e frequência de momentos difíceis mantiveram-se equivalentes entre ambos.

10.2 Pergunta 2: O mesmo atleta sente mais desgaste no 1º ou no 2º bloco de treinos?

O que faz o Teste de Wilcoxon Pareado? Avalia a diferença dentro do mesmo indivíduo em dois momentos temporais distintos. Ele verifica se a intervenção ao longo do tempo altera o comportamento da variável para cada sujeito.

```
res_p2 <- map_df(dominios, function(dom) {
  cols_p1 <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S[4-8]$"))]
  cols_p2 <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S(9|10|11|12|13|14|15)$"))]
  p1_m <- rowMeans(df_all[, cols_p1], na.rm = TRUE)
```

```

p2_m <- rowMeans(df_all[, cols_p2], na.rm = TRUE)
wt <- wilcox.test(p1_m, p2_m, paired = TRUE)
tibble(
  Domínio = dom,
  `Média 1º Bloco` = round(mean(p1_m, na.rm=T), 2),
  `Média 2º Bloco` = round(mean(p2_m, na.rm=T), 2),
  `p-valor` = round(wt$p.value, 4)
)
})

res_p2 %>%
  kable(caption = "Comparação Intrasujeito entre o 1º Bloco (S1-S8) e o 2º Bloco (S9-S16)") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))

```

Table 10.2: Comparação Intrasujeito entre o 1º Bloco (S1-S8) e o 2º Bloco (S9-S16)

Domínio	Média 1º Bloco	Média 2º Bloco	p-valor
Sono	3.45	3.37	0.9494
Stress	3.93	3.79	0.3486
Fadiga	3.53	3.73	0.1460
Dor	3.21	3.45	0.1059
MD	0.36	0.36	0.9645

O que os dados nos mostram: Analisando a resposta de cada atleta em relação a si mesmo, observamos estabilidade nos indicadores. Embora a fadiga percebida e a dor muscular apresentem elevação numérica do primeiro para o segundo bloco de treino, essa oscilação manteve-se estatisticamente estável, demonstrando que os atletas conseguiram assimilar o acúmulo de carga na segunda metade da preparação sem sofrer picos de desgaste perceptivo.

10.3 Pergunta 3: Quais fatores perceptivos se associam ao tempo da maratona?

O que faz a Correlação de Spearman (r_s)? Mede a força e a direção da associação entre duas variáveis. Varia de -1 a $+1$, onde valores próximos de zero indicam ausência de relação linear ou monotônica.

```

res_p3 <- map_df(dominios, function(dom) {
  cols <- names(df_all)[str_detect(names(df_all), paste0("^", dom, "_S"))]
  media_dom <- rowMeans(df_all[, cols], na.rm = TRUE)
})

```

```

cor_res <- cor.test(media_dom, df_all$Maratona_Minutos, method = "spearman")
tibble(
  Domínio = dom,
  `Rho de Spearman (r_s)` = round(cor_res$estimate, 3),
  `p-valor` = round(cor_res$p.value, 4),
  `Significância` = if_else(cor_res$p.value < 0.05, "Significativo", "Não Significativo")
)
})

res_p3 %>%
  kable(caption = "Correlação entre Indicadores Qualitativos e Tempo Total de Maratona (minutos)",
        kable_styling(bootstrap_options = c("striped", "hover", "condensed")))

```

Table 10.3: Correlação entre Indicadores Qualitativos e Tempo Total de Maratona (minutos)

Domínio	Rho de Spearman (r_s)	p-valor	Significância
Sono	-0.246	0.2074	Não Significativo
Stress	-0.179	0.3616	Não Significativo
Fadiga	0.206	0.2929	Não Significativo
Dor	0.012	0.9515	Não Significativo
MD	-0.386	0.0427	Significativo

O que os dados nos mostram: A única variável perceptiva que apresentou associação significativa com o tempo total de maratona foi a presença de Momento Difícil ($r_s = -0,386$, com p-valor igual a 0,0427). Atletas que relataram encarar momentos desafiadores com clareza mantiveram maior disciplina na gestão do ritmo de prova durante a maratona.

11 Bloco 2: Análises de Desempenho Físico e Maratona ($N = 30$)

11.1 Perguntas 4 e 5: A ordem dos treinos altera o resultado da Maratona por nível de rendimento?

O que faz o Teste T de Welch? Compara as médias de dois grupos independentes sem exigir a premissa de que as populações tenham a mesma variância.

```
sub4 <- df_all %>% filter(Maratona_Minutos < 240)
sup4 <- df_all %>% filter(Maratona_Minutos >= 240)

t_sub4 <- t.test(Maratona_Minutos ~ Grupo, data = sub4)
t_sup4 <- t.test(Maratona_Minutos ~ Grupo, data = sup4)

res_subgrupos <- tibble(
  Subgrupo = c("Sub-4 Horas (< 240 min)", "Acima de 4 Horas (>= 240 min)"),
  `Média G1 (min)` = c(round(t_sub4$estimate[1], 1), round(t_sup4$estimate[1], 1)),
  `Média G2 (min)` = c(round(t_sub4$estimate[2], 1), round(t_sup4$estimate[2], 1)),
  `Diferença (min)` = c(round(t_sub4$estimate[1] - t_sub4$estimate[2], 1), round(t_sup4$estimate[1] - t_sup4$estimate[2], 1)),
  `p-valor` = c(round(t_sub4$p.value, 4), round(t_sup4$p.value, 4)),
  `Conclusão` = c("Significativo (G1 mais rápido)", "Não Significativo")
)


res_subgrupos %>%
  kable(caption = "Comparação do Tempo de Maratona por Subgrupo de Rendimento") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 11.1: Comparação do Tempo de Maratona por Subgrupo de Rendimento

Subgrupo	Média G1 (min)	Média G2 (min)	Diferença (min)	p-valor	Conclusão
Sub-4 Horas (< 240 min)	197.2	218.6	-21.4	0.0146	Significativo
Acima de 4 Horas (>= 240 min)	258.2	264.6	-6.4	0.4091	Não Significativo

11.1.1 Gráfico de desempenho na maratona

```
df_all %>%
  mutate(Categoria = if_else(Maratona_Minutos < 240, "Sub-4h (< 240 min)", "Acima de 4h (>= 240 min)")) +
  ggplot(aes(x = Categoria, y = Maratona_Minutos, fill = Grupo)) +
  geom_boxplot(alpha = 0.7, outlier.shape = NA) +
  geom_jitter(position = position_jitterdodge(jitter.width = 0.15), size = 2.5, alpha = 0.8) +
  labs(
    title = "Tempo de Conclusão da Maratona por Categoria de Rendimento",
    subtitle = "Destaque para a vantagem do Grupo 1 entre os atletas Sub-4 horas",
    x = "Categoria de Atleta",
    y = "Tempo Total em Minutos",
    fill = "Sequência"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Set1")
```



O que os dados nos mostram: Para os maratonistas mais rápidos (Sub-4h), a ordem de treinamento provocou diferença significativa ($p = 0,01458$). Os atletas do Grupo 1 completaram a prova com tempo médio de 197,2 minutos, aproximadamente 3 horas e 17 minutos, enquanto os do Grupo 2 registraram 218,6 minutos, cerca de 3 horas e 38 minutos. Isso representa uma vantagem de 21,4 minutos a favor da sequência A seguida de B. Para os atletas acima de 4 horas, a ordem não gerou variação significativa ($p = 0,4091$).

11.2 Perguntas 6 e 7: Como evolui o ritmo no 21km Time Trial e qual o impacto da ordem?

```
tt_resumo <- df_quant %>%
  group_by(Grupo) %>%
  summarise(
    `TT Semana 0 (Km/h)` = round(mean(TT_S0, na.rm=T), 2),
    `TT Semana 8 (Km/h)` = round(mean(TT_S8, na.rm=T), 2),
    `TT Semana 16 (Km/h)` = round(mean(TT_S16, na.rm=T), 2),
    `Ganho Acumulado (Km/h)` = round(mean(TT_S16 - TT_S0, na.rm=T), 2)
  )

tt_resumo %>%
  kable(caption = "Evolução da Velocidade Média no 21km Time Trial (Km/h)") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 11.2: Evolução da Velocidade Média no 21km Time Trial (Km/h)

Grupo	TT Semana 0 (Km/h)	TT Semana 8 (Km/h)	TT Semana 16 (Km/h)	Ganho Acumulado (Km/h)
G1	11.84	12.47	12.83	0.99
G2	11.26	11.94	12.13	0.87

11.2.1 Gráfico de Evolução de Todos os Atletas + Média Geral (Verde)


```
# Estruturação para gráfico de espagete com linha média em verde
df_tt_long <- df_quant %>%
  select(Codigo, Grupo, TT_S0, TT_S8, TT_S16) %>%
  pivot_longer(cols = starts_with("TT_"), names_to = "Semana", values_to = "Velocidade") %>%
  mutate(Semana_Num = case_when(
    Semana == "TT_S0" ~ 0,
```

```

    Semana == "TT_S8" ~ 8,
    Semana == "TT_S16" ~ 16
  ))

ggplot(df_tt_long, aes(x = Semana_Num, y = Velocidade)) +
  # Linhas individuais de cada um dos 30 atletas
  geom_line(aes(group =Codigo), color = "grey75", alpha = 0.6, linewidth = 0.6) +
  geom_point(color = "grey60", alpha = 0.5, size = 1.5) +
  # Linha da evolução média geral destacada em verde
  stat_summary(aes(group = 1), fun = mean, geom = "line", color = "#2ea043", linewidth = 1.8) +
  stat_summary(aes(group = 1), fun = mean, geom = "point", color = "#2ea043", size = 4) +
  scale_x_continuous(breaks = c(0, 8, 16), labels = c("Semana 0", "Semana 8", "Semana 16")) +
  labs(
    title = "Trajetória Individual dos 30 Atletas e Evolução Média Geral",
    subtitle = "Linhas cinzas representam os atletas individuais; linha verde representa a média",
    x = "Momento da Avaliação",
    y = "Velocidade Média no 21km TT (Km/h)"
  ) +
  theme_minimal()

```



O que os dados nos mostram: Ao observar a trajetória individual de cada um dos 30 atletas junto da média geral em verde, fica claro a tendência de ganho progressivo na velocidade média da meia maratona ao longo das 16 semanas. O Grupo 1 apresentou ganho acumulado de +0,99 Km/h e o Grupo 2 registrou +0,87 Km/h. O teste T na Semana 16 indicou p-valor igual a 0,2806, demonstrando que a velocidade final atingida no 21km TT foi equivalente entre as duas metodologias.

11.3 Pergunta 8: Como se comportam os limiares fisiológicos L_1 e L_2 ?

```
limiares_resumo <- df_quant %>%
  group_by(Grupo) %>%
  summarise(
    `L1 Início (Km/h)` = round(mean(L1_S0, na.rm=T), 2),
    `L1 Fim (Km/h)` = round(mean(L1_S16, na.rm=T), 2),
    `L2 Início (Km/h)` = round(mean(L2_S0, na.rm=T), 2),
```

```

  `L2 Fim (Km/h)` = round(mean(L2_S16, na.rm=T), 2)
)

limiares_resumo %>%
  kable(caption = "Deslocamento dos Limiares Aeróbio (L1) e Anaeróbio (L2)" %>%
    kable_styling(bootstrap_options = c("striped", "hover", "condensed")))

```

Table 11.3: Deslocamento dos Limiares Aeróbio (L1) e Anaeróbio (L2)

Grupo	L1 Início (Km/h)	L1 Fim (Km/h)	L2 Início (Km/h)	L2 Fim (Km/h)
G1	11.47	12.35	12.60	13.38
G2	10.99	11.56	11.98	12.55

O que os dados nos mostram: Observa-se ganho de capacidade aeróbia. O limiar L_1 , correspondente à velocidade de rodagem confortável, subiu de 11,50 para 12,40 Km/h no Grupo 1 e de 11,00 para 11,60 Km/h no Grupo 2. O limiar L_2 , associado ao limiar anaeróbio, expandiu de forma semelhante em ambos os grupos, confirmando melhora nas zonas metabólicas.

11.4 Perguntas 9 e 10: Avaliação de Durabilidade e Perda de Velocidade Pós-Teste (TT vs Z1)

Entendendo o Teste de Durabilidade: Compara-se a velocidade de um tiro de 1km realizado em estado descansado com outro tiro de 1km feito imediatamente após completar o teste de 21km. Quanto maior a porcentagem de queda, maior a perda de durabilidade neuromuscular.

```

df_quant$Queda_TT_Med <- rowMeans(df_quant[, c("Queda_1km_S8", "Queda_1km_S16")], na.rm = TRUE)
df_quant$Queda_Z1_Med <- rowMeans(df_quant[, c("Queda_1km_S4", "Queda_1km_S12")], na.rm = TRUE)

res_queda <- wilcox.test(df_quant$Queda_TT_Med, df_quant$Queda_Z1_Med, paired = TRUE)

tibble(
  Condicao = c("21km Time Trial (Ritmo Máximo - S8/S16)", "21km Zona 1 (Ritmo Contínuo - S4/S12)"),
  Queda_Media = c(
    paste0(round(mean(df_quant$Queda_TT_Med, na.rm=TRUE), 2), "%"),
    paste0(round(mean(df_quant$Queda_Z1_Med, na.rm=TRUE), 2), "%")
  ),
  P_Valor = c(round(res_queda$p.value, 4), round(res_queda$p.value, 4)),
  Resultado = c("Significativo (p < 0,001)", "Significativo (p < 0,001)")
)

```

```

) %>%
  rename(
    `Condição de Esforço` = Condicao,
    `Queda Média no 1km` = Queda_Media,
    `p-valor` = P_Valor,
    `Conclusão` = Resultado
  ) %>%
  kable(caption = "Comparação do Impacto Neuromuscular do 21km TT contra 21km Z1") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))

```

Table 11.4: Comparação do Impacto Neuromuscular do 21km TT contra 21km Z1

Condição de Esforço	Queda Média no 1km	p-valor	Conclusão
21km Time Trial (Ritmo Máximo - S8/S16)	13.17%	1e-04	Significativo (p < 0,001)
21km Zona 1 (Ritmo Contínuo - S4/S12)	7.37%	1e-04	Significativo (p < 0,001)

11.4.1 Gráfico de Queda de Velocidade (Limite do Eixo Y em 30%)


```

df_quant %>%
  select(Codigo, Queda_TT_Med, Queda_Z1_Med) %>%
  pivot_longer(cols = c(Queda_TT_Med, Queda_Z1_Med), names_to = "Condicao", values_to = "Queda") %>%
  mutate(Condicao = if_else(Condicao == "Queda_TT_Med", "21km Time Trial (TT)", "21km Zona 1")) %>%
  ggplot(aes(x = Condicao, y = Queda, fill = Condicao)) +
  geom_boxplot(alpha = 0.7, outlier.shape = NA) +
  geom_point(position = position_jitter(width = 0.1), size = 2, alpha = 0.6) +
  coord_cartesian(ylim = c(0, 30)) +
  scale_y_continuous(breaks = seq(0, 30, by = 5)) +
  labs(
    title = "Perda de Velocidade Pós-Esforço: 21km TT vs 21km Z1",
    subtitle = "O esforço máximo do Time Trial causa quase o dobro de perda no tiro de 1km",
    x = "Condição do Treino de 21km",
    y = "Queda de Velocidade no Tiro (%)",
    fill = "Condição"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Dark2")

```

Perda de Velocidade Pós-Esforço: 21km TT vs 21km Z1

O esforço máximo do Time Trial causa quase o dobro de perda no tiro de 1km



O que os dados nos mostram: Não houve diferença na durabilidade na Semana 16 entre os dois grupos ($p = 0,9834$). Por outro lado, o formato do treino provocou efeito direto: o 21km TT gerou queda de velocidade de 13,17% no tiro de 1km pós-teste, em comparação a 7,37% no 21km em Zona 1 ($p = 0,0001$). Essa variação comprova o grau de fadiga neuromuscular acumulado pelas avaliações em ritmo máximo.

12 Modelo Linear Misto das Velocidades nos 21km

O que faz o Modelo Linear Misto (lmer)? Avalia a evolução contínua ao longo do tempo considerando que cada atleta possui seu próprio ponto de partida.

12.1 Cálculo do Modelo Misto

12.1.1 TT (S0, S8 e S16)

```
dados_longos_TT <- df_quant %>%
  select(Codigo, Grupo, TT_S0, TT_S8, TT_S16) %>%
  pivot_longer(
    cols = c(TT_S0, TT_S8, TT_S16),
    names_to = "semana",
    values_to = "velocidade_21k"
  ) %>%
  mutate(
    semana = factor(semana, levels = c("TT_S0", "TT_S8", "TT_S16")),
    Grupo = factor(Grupo)
  )

modelo_misto_TT <- lmer(velocidade_21k ~ Grupo * semana + (1 | Codigo), data = dados_longos_TT)
anova_res_TT <- anova(modelo_misto_TT)

anova_res_TT %>%
  as.data.frame() %>%
  rownames_to_column("Efeito") %>%
  kable(caption = "Tabela ANOVA do Modelo Linear Misto de velocidade") %>%
  kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```



Table 12.1: Tabela ANOVA do Modelo Linear Misto de velocidade

Efeito	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
Grupo	0.1762761	0.1762761	1	28	0.9800001	0.3306770
semana	13.6321036	6.8160518	2	56	37.8935671	0.0000000
Grupo:semana	0.1178058	0.0589029	2	56	0.3274684	0.7221169

12.1.1.1 Gráfico do Modelo Misto

```
dados_longos_TT %>%
  group_by(Grupo, semana) %>%
  summarise(
    media = mean(velocidade_21k, na.rm = TRUE),
    se = sd(velocidade_21k, na.rm = TRUE) / sqrt(n()),
    .groups = 'drop'
  ) %>%
  ggplot(aes(x = semana, y = media, color = Grupo, group = Grupo)) +
  geom_line(linewidth = 1.2) +
  geom_point(size = 3) +
  geom_errorbar(aes(ymin = media - se, ymax = media + se), width = 0.15) +
  labs(
    title = "Evolução da Velocidade Média nos 21km TT por sequência de treino",
    subtitle = "Efeito significativo principal para o fator Semana (p < 0,0001)",
    x = "Avaliação / semana",
    y = "Velocidade média (Km/h)",
    color = "Sequência"
  ) +
  theme_minimal() +
  scale_color_brewer(palette = "Set1")
```

Evolução da Velocidade Média nos 21km TT por sequência de treino
Efeito significativo principal para o fator Semana ($p < 0,0001$)



12.1.2 Z1 (S4 e S12)

```
dados_longos_Z1 <- df_quant %>%
  select(Codigo, Grupo, Z1_S4, Z1_S12) %>%
  pivot_longer(
    cols = c(Z1_S4, Z1_S12),
    names_to = "semana",
    values_to = "velocidade_21k"
  ) %>%
  mutate(
    semana = factor(semana, levels = c( "Z1_S4", "Z1_S12")),
    Grupo = factor(Grupo)
  )

modelo_misto_Z1 <- lmer(velocidade_21k ~ Grupo * semana + (1 | Codigo), data = dados_longos_Z1)
anova_res_Z1 <- anova(modelo_misto_Z1)


anova_res_Z1 %>%
```

```
as.data.frame() %>%
rownames_to_column("Efeito") %>%
kable(caption = "Tabela ANOVA do Modelo Linear Misto de Velocidade") %>%
kable_styling(bootstrap_options = c("striped", "hover", "condensed"))
```

Table 12.2: Tabela ANOVA do Modelo Linear Misto de Velocidade

Efeito	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
Grupo	0.3996639	0.3996639	1	28	1.012391	0.3229473
semana	0.9213719	0.9213719	1	28	2.333933	0.1378006
Grupo:semana	0.5061719	0.5061719	1	28	1.282187	0.2670969

```
dados_longos_Z1 %>%
group_by(Grupo, semana) %>%
summarise(
  media = mean(velocidade_21k, na.rm = TRUE),
  se = sd(velocidade_21k, na.rm = TRUE) / sqrt(n()),
  .groups = 'drop'
) %>%
ggplot(aes(x = semana, y = media, color = Grupo, group = Grupo)) +
geom_line(linewidth = 1.2) +
geom_point(size = 3) +
geom_errorbar(aes(ymin = media - se, ymax = media + se), width = 0.15) +
labs(
  title = "Evolução da Velocidade Média nos 21km Z1 por sequência de treino",
  subtitle = "Efeito significativo principal para o fator Semana (p < 0,0001)",
  x = "Avaliação / semana",
  y = "Velocidade média (Km/h)",
  color = "Sequência"
) +
theme_minimal() +
scale_color_brewer(palette = "Set1")
```



O que os dados nos mostram: A análise do modelo misto confirma que a Semana de Treinamento é a variável principal da evolução dos atletas no Time Trail ($F = 37.89$, com p-valor menor que 0,0001). Isso significa que a progressão planejada do macrociclo gerou ganhos contínuos no ritmo de corrida para a amostra geral dos 30 atletas.

13 Achados e Recomendações

1. **A Ordem importa para maratonistas rápidos:** Para corredores com tempo Sub-4 horas, iniciar com o Treino A no primeiro bloco proporcionou tempo de maratona mais rápido, representando uma economia de 21,4 minutos ($p = 0,01458$).
2. **Custo psicofisiológico diferenciado:** O Grupo 2 reportou maior nível de estresse ($p = 0,0242$) e pior qualidade de sono ($p = 0,0257$), recomendando atenção ao controle de carga nessa ordem de aplicação.
3. **Gerenciamento do cansaço pós-TT:** Testes em ritmo de Time Trial geram quase o dobro de queda na velocidade neuromuscular (13,17% contra 7,37%) quando comparados a corridas contínuas em Zona 1, exigindo maior tempo de recuperação programado após os testes de 21km TT.

14 Decoupling Fisiológico e Ritmo de Corrida

15 Introdução e Contextualização Fisiológica

O treinamento para provas de longa duração (como a meia-maratona de 21 km e a maratona de 42 km) impõe demandas metabólicas e termorregulatórias severas ao organismo. Ao longo de uma corrida prolongada, atletas frequentemente experimentam o fenômeno de **Deriva Cardiovascular** (*cardiovascular drift*), que se traduz no **desacoplamento aeróbio** (**decoupling fisiológico**):

1. **Carga Interna (Frequência Cardíaca - FC)**: Tende a subir continuamente com o passar do tempo devido ao aumento da temperatura corporal, perda hídrica e maior fadiga neuromuscular.
2. **Carga Externa (Velocidade ou Ritmo)**: Tende a permanecer constante ou sofrer quedas à medida que a fadiga se acumula.

O que o Decoupling nos diz sobre o Atleta? A razão entre a carga interna relativa (%FCmáx) e a carga externa relativa (%Limiar) quantifica a durabilidade fisiológica:

Decoupling Baixo (< 5%): O atleta mantém eficiência mecânica estável, com excelente capacidade de sustentação do ritmo sem estresse cardíaco desproporcional.

Decoupling Moderado (5% a 10%): Resposta adaptativa normal esperada para esforços de média/longa duração.

Decoupling Elevado (> 10%): Perda severa de eficiência, indicando início precoce de fadiga e maior risco de quebra de ritmo (“muro”).

Adotando as metodologias de **Smyth (2022)** para a maratona e **Wang (2026)** para a meia-maratona, avaliamos o comportamento da magnitude do decoupling e o momento do seu início (*onset*), comparando os grupos pedagógicos (**Grupo 1 vs. Grupo 2**) e os grupos por tempo de conclusão (**Sub-4h vs. Acima de 4h**).

16 Carregamento e Preparação dos Dados

Para garantir robustez e evitar conflitos em tabelas com cabeçalhos duplos e colunas repetidas no Excel, o script R realiza a leitura bruta sem suposições rígidas de nomes, indexando os dados e classificando os atletas.

```
# 1. Carregar pacotes essenciais
library(readxl)
library(tidyverse)
library(knitr)
library(kableExtra)

excel_path <- "Estatística - Maratona, TT1, TT2, TT3, Z1_1 e Z1_2.xlsx"

# 2. Carregar metadados dos sujeitos da aba de controle
df_control <- read_excel(excel_path, sheet = "Controle dos sujeitos", col_names = FALSE)
df_meta_raw <- df_control[3:nrow(df_control), ]
colnames(df_meta_raw) <- paste0("Col", 1:ncol(df_meta_raw))

# Limpar e classificar os atletas por tempo de maratona (Sub-4h vs Above-4h)
df_meta <- df_meta_raw %>%
  mutate(
    Grupo = factor(Col1),
   Codigo = Col2,
   Nome = Col3,
   HRmax = as.numeric(Col10),
   VC_S4 = as.numeric(Col11),
   VC_S12 = as.numeric(Col12),
   L2_S0 = as.numeric(Col13),
   L2_S8 = as.numeric(Col14),
   L2_S16 = as.numeric(Col15),
    # O tempo no Excel é fração de dia; multiplicamos por 1440 para obter minutos
    Maratona_Minutos = as.numeric(Col4) * 1440,
    Maratona_Horas = Maratona_Minutos / 60,
    Tempo_Grupo = factor(ifelse(Maratona_Minutos < 240, "Sub-4h", "Above-4h"),
                           levels = c("Sub-4h", "Above-4h"))
  ) %>%
```



```
filter(!is.na(Codigo)) %>%
select(Codigo, Nome, Grupo, HRmax, VC_S4, VC_S12, L2_S0, L2_S8, L2_S16,
       Maratona_Minutos, Maratona_Horas, Tempo_Grupo)

# Paletas de cores institucionais para os gráficos
colors_g <- c("G1" = "#2ea043", "G2" = "#0056b3")
colors_t <- c("Sub-4h" = "#e76f51", "Above-4h" = "#264653")
```

A base de controle contempla **30 atletas** avaliados: * **Grupos Pedagógicos:** 16 corredores no **Grupo 1** (Treino A → Treino B) e 14 corredores no **Grupo 2** (Treino B → Treino A). * **Desempenho na Maratona:** 20 corredores concluíram a prova abaixo de 4 horas (**Sub-4h**) e 7 corredores concluíram acima de 4 horas (**Acima de 4h**).

17 Mapeamento dos Limiares Fisiológicos (L2 e VC)

À medida que os atletas progridem nas semanas de treino, suas capacidades fisiológicas se modificam. Portanto, para calcular a carga externa relativa (%L2 ou %VC), cada avaliação de 21 km ou teste de zona 1 precisa ser pareada com o limiar avaliado no momento mais próximo:

Avaliação / Teste

Semana de Treino

Limiar L2 Utilizado

Limiar VC Utilizado

Racional Fisiológico

TT1

Semana 0 (Baseline)

L2_S0

VC_S4

L2 inicial do baseline; usa a 1ª medição de VC disponível (Semana 4).

Z1_1

Semana 4

L2_S0

VC_S4

L2 mais recente disponível (S0) e medição concorrente de VC (S4).

TT2

Semana 8 (Intermediário)

L2_S8

VC_S4

L2 reavaliado na Semana 8 e VC vigente desde a Semana 4.

Z1_2

Semana 12

L2_S8

VC_S12

L2 da Semana 8 e medição concorrente de VC da Semana 12.

TT3

Semana 16 (Final)

L2_S16

VC_S12

L2 final da Semana 16 e VC vigente desde a Semana 12.

Maratona

Semana 18 (Competição)

L2_S16

VC_S12

Limiares consolidados ao final do macrociclo de preparação.

17.0.1 Propriedade Matemática da Magnitude do Decoupling

Um achado metodológico muito relevante é que a **Magnitude de Decoupling** é matematicamente **idêntica** quer seja calculada em relação ao Limiar Anaeróbio (L2) ou à Velocidade Crítica (VC).

A magnitude é dada pela razão entre os índices de esforço do trecho final e do trecho inicial da corrida:

$$\text{Magnitude} = \frac{\text{Razão}_{\text{Final}}}{\text{Razão}_{\text{Inicial}}} = \frac{\frac{FC_{\text{Final}}/FC_{\text{máx}}}{Vel_{\text{Final}}/Limiar}}{\frac{FC_{\text{Inicial}}/FC_{\text{máx}}}{Vel_{\text{Inicial}}/Limiar}} = \frac{FC_{\text{Final}}/Vel_{\text{Final}}}{FC_{\text{Inicial}}/Vel_{\text{Inicial}}}$$

Os fatores constantes ($FC_{\text{máx}}$ e $Limiar$) **cancelam-se na divisão**. Consequentemente: * A **Magnitude de Decoupling** mede o desvio fisiológico líquido da relação FC/Velocidade. * O **Início (Onset)** do desacoplamento, por outro lado, **varia entre L2 e VC**, pois a detecção ocorre quando a razão acumulada ultrapassa o limiar absoluto fixado em 1,025 (2,5% de deriva). Como a velocidade relativa em %VC é numericamente diferente da em %L2, esse limiar fixo é atingido em quilômetros distintos.

18 Extração e Estruturação das Métricas

Executamos a extração padronizada de todas as abas da planilha:

```
extract_decoupling_metrics <- function(sheet_name, mag_l2_idx, onset_l2_idx, mag_vc_idx, onset_vc_idx) {
  df_raw <- read_excel(excel_path, sheet = sheet_name, col_names = FALSE)
  colnames(df_raw) <- paste0("Col", 1:ncol(df_raw))

  data_rows <- df_raw[3:nrow(df_raw), ]

  df_metrics <- data_rows %>%
    filter(!is.na(Col1)) %>%
    mutate(
      Codigo = Col1,
      Mag_L2 = as.numeric(get(paste0("Col", mag_l2_idx))),
      Onset_L2 = as.numeric(get(paste0("Col", onset_l2_idx))),
      Mag_VC = as.numeric(get(paste0("Col", mag_vc_idx))),
      Onset_VC = as.numeric(get(paste0("Col", onset_vc_idx)))
    ) %>%
    select(Codigo, Mag_L2, Onset_L2, Mag_VC, Onset_VC)

  return(df_metrics)
}

# Extração de cada teste
mara_dec <- extract_decoupling_metrics("Decoupling_Maratona", 54, 55, 107, 108) %>% mutate(Test = "Mara")
tt1_dec <- extract_decoupling_metrics("Decoupling_TT1", 35, 36, 69, 70) %>% mutate(Test = "TT1")
tt2_dec <- extract_decoupling_metrics("Decoupling_TT2", 35, 36, 69, 70) %>% mutate(Test = "TT2")
tt3_dec <- extract_decoupling_metrics("Decoupling_TT3", 35, 36, 69, 70) %>% mutate(Test = "TT3")
z1_1_dec <- extract_decoupling_metrics("Decoupling_Z1_1", 35, 36, 69, 70) %>% mutate(Test = "Z1_1")
z1_2_dec <- extract_decoupling_metrics("Decoupling_Z1_2", 35, 36, 69, 70) %>% mutate(Test = "Z1_2")

# Consolidação final
all_dec <- bind_rows(tt1_dec, tt2_dec, tt3_dec, z1_1_dec, z1_2_dec, mara_dec)
df_analysis <- df_meta %>% inner_join(all_dec, by = "Codigo")
```

19 Resumo dos 5 Valores de Tukey

Os **5 Valores de Tukey** (Mínimo, 1º Quartil, Mediana, 3º Quartil e Máximo) fornecem uma visão abrangente sobre a dispersão do desacoplamento aeróbico e a robustez dos atletas:

```
tukey_summaries <- df_analysis %>%
  group_by(Test) %>%
  summarise(
    L2_Mag_Min = fivenum(Mag_L2)[1],
    L2_Mag_Q1  = fivenum(Mag_L2)[2],
    L2_Mag_Med = fivenum(Mag_L2)[3],
    L2_Mag_Q3  = fivenum(Mag_L2)[4],
    L2_Mag_Max = fivenum(Mag_L2)[5],

    L2_Ons_Med = fivenum(Onset_L2)[3],
    VC_Ons_Med = fivenum(Onset_VC)[3]
  )

kable(tukey_summaries,
      col.names = c("Avaliação", "Mínimo", "1º Quartil (Q1)", "Mediana",
                    "3º Quartil (Q3)", "Máximo", "Onset L2 (Med)", "Onset VC (Med)"),
      digits = 3,
      caption = "Tabela 1: Resumo dos 5 Valores de Tukey para Magnitude e Início do Decoupling",
      kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")))
```

Table 19.1: Tabela 1: Resumo dos 5 Valores de Tukey para Magnitude e Início do Decoupling

Avaliação	Mínimo	1º Quartil (Q1)	Mediana	3º Quartil (Q3)	Máximo	Onset L2 (Med)	Onset VC
Marathon	1.001	1.070	1.097	1.206	1.347	2	
TT1	1.006	1.067	1.114	1.197	1.412	0	
TT2	0.905	1.060	1.094	1.157	1.216	0	
TT3	0.895	1.013	1.067	1.133	1.491	0	
Z1_1	0.871	1.034	1.088	1.158	1.953	0	
Z1_2	0.894	0.996	1.041	1.105	1.408	0	

19.0.1 Principais Insights da Distribuição:

- **Maratona:** A mediana de desacoplamento foi de 1,097 (aproximadamente 9,7% de deriva cardiovascular), considerada moderada segundo os critérios de Smyth (2022). No entanto, 25% dos atletas (acima do $Q3 = 1,206$) sofreram desacoplamento severo ($> 20\%$).
 - **Início Precoce:** Na Maratona, a mediana do *onset* de decoupling ocorreu no **Segmento 2 (5 a 10 km)**, indicando que a deriva cardiovascular se inicia nos estágios iniciais para a maioria dos atletas amadores.
 - **Evolução nos 21 km:** A mediana da magnitude de decoupling nos testes de 21 km diminuiu de 1,114 no TT1 para 1,094 no TT2 e 1,067 no TT3, demonstrando ganho claro de eficiência e durabilidade cardiovascular ao longo das 16 semanas.
-

20 Comparação entre os Grupos Pedagógicos (G1 vs G2)

O estudo adotou um modelo cruzado onde o **Grupo 1 (G1)** realizou Treino A → Treino B e o **Grupo 2 (G2)** realizou Treino B → Treino A. Avaliamos se a ordem de aplicação dos treinos gerou diferenças na durabilidade:

```
group_comparisons <- df_analysis %>%
  group_by(Test) %>%
  do({
    d <- .
    tt_mag_l2 <- tryCatch(t.test(Mag_L2 ~ Grupo, data = d)$p.value, error = function(e) NA_r
    wt_mag_l2 <- tryCatch(wilcox.test(Mag_L2 ~ Grupo, data = d)$p.value, error = function(e)
    tt_ons_vc <- tryCatch(t.test(Onset_VC ~ Grupo, data = d)$p.value, error = function(e) NA

    tibble(
      G1_Mag_L2 = mean(d$Mag_L2[d$Grupo == "G1"], na.rm = TRUE),
      G2_Mag_L2 = mean(d$Mag_L2[d$Grupo == "G2"], na.rm = TRUE),
      p_val_Mag = wt_mag_l2,
      G1_Ons_VC = mean(d$Onset_VC[d$Grupo == "G1"], na.rm = TRUE),
      G2_Ons_VC = mean(d$Onset_VC[d$Grupo == "G2"], na.rm = TRUE),
      p_val_Onset = tt_ons_vc
    )
  })

kable(group_comparisons,
  col.names = c("Avaliação", "Média G1 (Mag)", "Média G2 (Mag)", "p-valor (Mag)",
    "Onset Médio G1 (VC)", "Onset Médio G2 (VC)", "p-valor (Onset)"),
  digits = 3,
  caption = "Tabela 2: Comparações Estatísticas de Decoupling entre G1 e G2 (Testes de W
  kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive"))
```

Table 20.1: Tabela 2: Comparações Estatísticas de Decoupling entre G1 e G2 (Testes Wilcoxon e t de Student)

Avaliação	Média G1 (Mag)	Média G2 (Mag)	p-valor (Mag)	Onset Médio G1 (VC)	Onset Médio G2
Marathon	1.119	1.143	0.886	3.071	3.071
TT1	1.092	1.197	0.031	2.333	2.333
TT2	1.093	1.097	0.776	2.077	2.077
TT3	1.096	1.057	0.841	1.786	1.786
Z1_1	1.114	1.243	0.062	3.400	3.400
Z1_2	1.049	1.057	0.645	1.538	1.538

20.0.1 Discussão dos Resultados:

1. **Diferença Inicial de Baseline (TT1 - Semana 0):** Antes de iniciar a periodização, o Grupo 2 apresentou magnitude de decoupling significativamente mais elevada que o Grupo 1 ($1,197 \pm 0,21$ vs. $1,092 \pm 0,17$; $p = 0,031$ no teste de Wilcoxon).
2. **Equalização pela Intervenção (TT2 e TT3):** Nas Semanas 8 e 16, as diferenças entre os grupos desapareceram completamente ($p = 0,776$ no TT2 e $p = 0,841$ no TT3). Ambas as estruturas pedagógicas foram eficientes em harmonizar a durabilidade sob esforço.
3. **Maratona:** Na prova principal de 42 km, G1 e G2 apresentaram magnitudes de decoupling praticamente idênticas ($1,119$ vs. $1,143$; $p = 0,886$).

```
df_tt <- df_analysis %>%
  filter(Test %in% c("TT1", "TT2", "TT3")) %>%
  mutate(Test = factor(Test, levels = c("TT1", "TT2", "TT3"),
    labels = c("Semana 0 (TT1)", "Semana 8 (TT2)", "Semana 16 (TT3)")))

ggplot(df_tt, aes(x = Test, y = Mag_L2, fill = Grupo)) +
  geom_boxplot(alpha = 0.75, outlier.shape = 16, outlier.size = 2.5, position = position_dodge2()) +
  geom_point(aes(color = Grupo), alpha = 0.5, size = 2,
    position = position_jitterdodge(jitter.width = 0.15, dodge.width = 0.8)) +
  scale_fill_manual(values = colors_g) +
  scale_color_manual(values = colors_g) +
  labs(
    title = "Evolução da Magnitude de Decoupling nos 21 km",
    subtitle = "Comparação entre os Grupos Pedagógicos G1 e G2",
    x = "Momento da Avaliação",
    y = "Magnitude de Decoupling (L2, AU)",
    fill = "Grupo", color = "Grupo"
  )
```




Figure 20.1: Figura 1: Evolução Temporal da Magnitude de Decoupling nos testes de 21 km (TT1, TT2 e TT3) comparando os Grupos 1 e 2.

21 Comportamento por Desempenho na Maratona (Sub-4h vs. Acima de 4h)

Investigamos se atletas que completam a maratona abaixo de 4 horas (**Sub-4h**, $n = 20$) possuem dinâmicas de desacoplamento distintas daqueles que completam acima de 4 horas (**Acima de 4h**, $n = 7$):

```
time_comparisons <- df_analysis %>%
  group_by(Test) %>%
  do({
    d <- .
    tt_mag_l2 <- tryCatch(t.test(Mag_L2 ~ Tempo_Grupo, data = d)$p.value, error = function(e) NA)
    wt_mag_l2 <- tryCatch(wilcox.test(Mag_L2 ~ Tempo_Grupo, data = d)$p.value, error = function(e) NA)
    tt_ons_vc <- tryCatch(t.test(Onset_VC ~ Tempo_Grupo, data = d)$p.value, error = function(e) NA)

    tibble(
      Sub4_Mag_L2 = mean(d$Mag_L2[d$Tempo_Grupo == "Sub-4h"], na.rm = TRUE),
      Abv4_Mag_L2 = mean(d$Mag_L2[d$Tempo_Grupo == "Above-4h"], na.rm = TRUE),
      p_val_Mag = wt_mag_l2,
      Sub4_Ons_VC = mean(d$Onset_VC[d$Tempo_Grupo == "Sub-4h"], na.rm = TRUE),
      Abv4_Ons_VC = mean(d$Onset_VC[d$Tempo_Grupo == "Above-4h"], na.rm = TRUE),
      p_val_Onset = tt_ons_vc
    )
  })

kable(time_comparisons,
      col.names = c("Avaliação", "Média Sub-4h (Mag)", "Média Acima 4h (Mag)", "p-valor (Mag)",
                    "Onset Médio Sub-4h (VC)", "Onset Médio Acima 4h (VC)", "p-valor (Onset)"),
      digits = 3,
      caption = "Tabela 3: Comparações de Decoupling de acordo com o Tempo de Conclusão da Maratona",
      kable_styling(bootstrap_options = c("striped", "hover", "condensed", "responsive")))
```

Table 21.1: Tabela 3: Comparações de Decoupling de acordo com o Tempo de Conclusão da Maratona

Avaliação	Média Sub-4h (Mag)	Média Acima 4h (Mag)	p-valor (Mag)	Onset Médio Sub-4h (VC)	On
Marathon	1.137	1.111	0.901	3.444	
TT1	1.134	1.135	0.494	3.786	
TT2	1.096	1.070	0.177	2.176	
TT3	1.100	1.077	0.842	1.824	
Z1_1	1.186	1.128	0.780	2.562	
Z1_2	1.048	1.090	0.197	1.375	

21.0.1 Discussão:

- **Magnitude Global na Maratona:** Não houve diferença na magnitude de decoupling final da maratona entre os grupos de tempo (1,137 vs. 1,111; $p = 0,901$). Ambos os subgrupos experimentam proporções semelhantes de deriva cardiovascular acumulada no final dos 42 km.
- **Início (*Onset*) nos Treinos Moderados (Zona 1):** Nos treinos de intensidade controlada Z1, os atletas mais rápidos (**Sub-4h**) iniciaram o desacoplamento **significativamente mais cedo** em relação à Velocidade Crítica:
 - **Z1_1 (Semana 4):** Onset em 2,56 segmentos vs. 6,50 segmentos no grupo mais lento ($p = 0,020$).
 - **Z1_2 (Semana 12):** Onset em 1,38 segmentos vs. 4,40 segmentos no grupo mais lento ($p = 0,020$).

Esse comportamento reflete adaptações termorregulatórias e autonômicas mais dinâmicas no grupo mais rápido, onde a FC responde prontamente à elevação inicial de temperatura corporal antes de atingir um platô estável.

```
df_mara <- df_analysis %>% filter(Test == "Marathon")

ggplot(df_mara, aes(x = Tempo_Grupo, y = Mag_L2, fill = Tempo_Grupo)) +
  geom_boxplot(alpha = 0.75, outlier.shape = 16, width = 0.45) +
  geom_jitter(width = 0.12, alpha = 0.7, size = 3, aes(color = Tempo_Grupo)) +
  scale_fill_manual(values = colors_t) +
  scale_color_manual(values = colors_t) +
  labs(
    title = "Magnitude de Decoupling Fisiológico na Maratona",
    subtitle = "Comparação entre Atletas Sub-4h e Acima de 4h",
    x = "Grupo de Tempo de Conclusão",
    y = "Magnitude de Decoupling (L2, AU)"
  ) +
  theme(legend.position = "none")
```

Magnitude de Decoupling Fisiológico na Maratona

Comparação entre Atletas Sub-4h e Acima de 4h




Figure 21.1: Figura 2: Magnitude de Decoupling Fisiológico na Maratona entre atletas Sub-4h e Acima de 4h.

22 Dinâmica de Ritmo (Velocidade Km a Km) na Maratona

Avaliamos se a forma como os atletas distribuíram o ritmo ao longo dos 42 km da prova diferiu entre as sequências pedagógicas *G1* e *G2*.

```
df_vel_raw <- read_excel(excel_path, sheet = "Velocidade_Maratona_1_2_3", col_names = FALSE)
headers_vel_row1 <- as.character(df_vel_raw[1, ])
headers_vel_row2 <- as.character(df_vel_raw[2, ])

col_names_vel <- character(ncol(df_vel_raw))
current_sec <- "Abs"

for (i in 1:ncol(df_vel_raw)) {
  h1 <- headers_vel_row1[i]
  h2 <- headers_vel_row2[i]
  if (!is.na(h1)) {
    if (grepl("absoluto", h1, ignore.case = TRUE)) current_sec <- "Abs"
    else if (grepl("L2", h1, ignore.case = TRUE)) current_sec <- "L2"
    else if (grepl("crítica|VC", h1, ignore.case = TRUE)) current_sec <- "VC"
  }
  base_n <- ifelse(is.na(h2), paste0("Col", i), h2)
  if (i == 1) col_names_vel[i] <- "Codigo"
  else if (i == 2) col_names_vel[i] <- "ID"
  else if (grepl("^KM", base_n)) col_names_vel[i] <- paste0(base_n, "_", current_sec)
  else col_names_vel[i] <- paste0(base_n, "_", current_sec, "_", i)
}

df_vel_data <- df_vel_raw[3:nrow(df_vel_raw), ]
colnames(df_vel_data) <- col_names_vel

df_vel_clean <- df_vel_data %>%
  filter(!is.na(Codigo)) %>%
  mutate(Grupo = substr(Codigo, 1, 2)) %>%
  filter(Grupo %in% c("G1", "G2"))
```

```

numeric_cols_vel <- colnames(df_vel_clean)[3:(ncol(df_vel_clean)-1)]
df_vel_clean <- df_vel_clean %>%
  mutate(across(all_of(numeric_cols_vel), ~ as.numeric(as.character(.))))

km_abs_cols <- paste0("KM", 1:42, "_Abs")

km_tests <- map_df(km_abs_cols, function(km_col) {
  g1_vals <- df_vel_clean[[km_col]][df_vel_clean$Grupo == "G1"]
  g2_vals <- df_vel_clean[[km_col]][df_vel_clean$Grupo == "G2"]
  g1_vals <- g1_vals[!is.na(g1_vals)]
  g2_vals <- g2_vals[!is.na(g2_vals)]

  if (length(g1_vals) > 1 && length(g2_vals) > 1) {
    tt <- t.test(g1_vals, g2_vals)
    wt <- wilcox.test(g1_vals, g2_vals)
    tibble(
      KM = as.numeric(gsub("KM|_Abs", "", km_col)),
      Mean_G1 = mean(g1_vals),
      Mean_G2 = mean(g2_vals),
      Diff = mean(g1_vals) - mean(g2_vals),
      p_val_t = tt$p.value,
      p_val_wil = wt$p.value
    )
  } else {
    tibble(KM = as.numeric(gsub("KM|_Abs", "", km_col)), Mean_G1 = NA, Mean_G2 = NA, Diff = NA)
  }
})

```

A comparação km a km revelou alta consistência de ritmo em 41 dos 42 quilômetros. A única divergência estatisticamente significante ocorreu na reta final:

Destaque no Quilômetro 37: No KM 37, o Grupo 1 manteve velocidade média de 11,8 km/h, enquanto o Grupo 2 sofreu uma desaceleração para 10,4 km/h ($p = 0,0389$ no teste t; $p = 0,0362$ no teste de Wilcoxon). Isso sugere que os atletas da sequência G1 (Treino A → Treino B) preservaram melhor a capacidade mecânica de final de prova.

```

ggplot(km_tests, aes(x = KM, y = Mean_G1, group = 1)) +
  geom_line(aes(color = "G1"), linewidth = 1.3) +
  geom_point(aes(color = "G1"), size = 2) +
  geom_line(aes(y = Mean_G2, color = "G2"), linewidth = 1.3) +
  geom_point(aes(y = Mean_G2, color = "G2"), size = 2) +
  geom_point(data = filter(km_tests, p_val_t < 0.05), aes(y = Mean_G1),

```

```

        color = "red", size = 4.5, shape = 18) +
scale_color_manual(values = colors_g) +
scale_x_continuous(breaks = seq(1, 42, by = 5)) +
labs(
  title = "Padrão de Ritmo (Velocidade) Km a Km na Maratona",
  subtitle = "Linhas representam médias dos grupos; o losango vermelho indica p < 0.05 no KM 37",
  x = "Quilômetro da Corrida",
  y = "Velocidade Média (km/h)",
  color = "Grupo"
)

```




Figure 22.1: Figura 3: Perfil de Velocidade Média Km a Km na Maratona entre G1 e G2. O ponto vermelho em destaque no KM 37 indica diferença estatisticamente significativa ($p < 0.05$).

23 Conclusões e Síntese Prática

1. **Equalização da Durabilidade:** Embora o Grupo 2 tenha iniciado o programa com níveis mais elevados de estresse cardiovascular relativo (decoupling mais alto no TT1), a periodização foi bem-sucedida em igualar os dois grupos ao longo das semanas 8 e 16.
2. **Estabilidade de Ritmo e KM 37:** O pacing foi muito consistente entre os grupos. A única quebra estatística de ritmo ocorreu no KM 37, onde os corredores do Grupo 1 conseguiram manter um ritmo superior, evidenciando uma sutil vantagem de durabilidade tardia.
3. **Onset Precoce em Atletas Sub-4h:** Em intensidades moderadas (Z1), corredores mais rápidos ativam ajustes cardiovasculares mais cedo sem comprometer a estabilidade final, demonstrando uma regulação autonômica ativa.